

面向 Loop Engineering 的 Qoder 托管运行时实践

让 Agent 的长循环在生产里跑得住

演讲人：屈立威（安陈）

阿里巴巴 Qoder · 高级产品专家

AiCon
全球人工智能开发与应用大会

01

Loop Engineering 与挑战

■ 杠杆点四层外迁：Loop Engineering 成为新共识



■ 业界与学界的共识：把「可靠的长循环」变成可度量的科学

1 能力 $\neq$ 可靠

单次跑通不代表生产可靠；长任务要看「反复跑都稳」，需要专门的可靠性度量。

2 失败可被定位

长任务在哪崩、为何崩可被诊断，关键解法是「执行期校验与修复」+ 更强的记忆。

3 验证有成本

验证越严越安全、但越拖性能；所以验证应做成运行时可托管的能力，而非各自硬编。

能跑住的 loop 难在哪：三个公认的硬问题

验证

幻觉式「完成」、删掉失败测试让 CI 变绿

✓ 运行时可托管

终止

永不停止、围着死胡同烧 token

✓ 运行时可托管

上下文

越跑越长、注意力涣散、越跑越不准

• 与模型协同

从「能跑」到「规模化跑在生产」：这是运行时要解的问题

生产所需

本地 / 单点

托管运行时

无人值守 7 × 24

✗ 进程随机器停

✓ 云端常驻

事件驱动唤醒

✗ 需人主动发起

✓ 定时 / Webhook / IM 触发

规模并行隔离循环

✗ 一台机器跑不动

✓ 各自隔离、用完即收

多租户隔离环境

✗ 无此概念

✓ 终端用户体系 + 隔离

02

行业实践

Cursor: 把云端 Agent 跑成生产力

《What we've learned building cloud agents》

- 开发环境就是产品：云端要从零重建整套环境
- 持久化执行迁移到工作流引擎，跨天跨周扛节点故障
- Agent / 机器 / 会话三解耦，会话可重放、失败可回退

5000 万+

每天执行的 actions

40%+

内部 PR 来自 Cloud Agent

1 → 2 个 9+

可靠性提升

Anthropic: 如何可靠地跑长任务 / 托管 Agent

《Effective harnesses...》 《Scaling Managed Agents》

- 「轮班工程师」：长任务跨多个上下文窗口接力
- 脑 / 手 / 会话三解耦，无状态 harness 可从最后事件恢复
- 凭证进 vault，harness 永不接触；浏览器端到端验证

p50 ↓ 60%

首 token 时延

p95 ↓ 90%

首 token 时延

脑手分离

行业范式

Qoder 自己的实践：Coding 场景已把 harness 跑通

30 分钟 → 2 分钟

CLI + Harness 构建 7×24 无人值守反馈系统，单问题根因分析提速

93.5%

曾被无效工具定义占用的上下文——按需注入是解法

400 万行 / 3 周

在存量巨型工程上新增 50 万行，用 Qoder 开发 Qoder

三端原生隔离

终端沙箱守住 Agent 执行边界

03

Qoder Cloud Agents

QCA 是什么：Agent 运行时即服务

把经 Coding 场景规模验证的引擎，以 API 开放的全托管运行时。



能力是对着难题长出来的

持久 · 长跑 / 断流

长时会话 + 执行连接分离 + 断点续传

验证

Outcomes: 独立评分, 达标才算完成

终止 · 安全

状态机 + 工具权限 + 人审闸门 + 凭证隔离

可观测

全链路 Span trace, 且作为计量单点

组合 · 触发 · 自进化

多 Agent 协作 + 定时 / Webhook + 记忆自进化

■ 执行与连接分离，断了能续



SSE 只是「观察窗口」

断网 / 退后台 / 关页面：任务在服务端照常跑完。

重连：从上次位置继续，不丢不重。 全程无人盯着：结果存下来，事后可取回。

Self-hosted —— 脑在云、手在客户

QCA 云端（脑）

规划 · 编排 · 模型 · 验收 · 观测

↓ 单向出站 · 永不拨入客户内网

自托管 Worker（手）

部署在客户 VPC 内

领任务 → 本地执行 → 回传，代码与数据不出域

MCP 隧道

出站通道

够得着客户内网服务，无需开放任何入站端口

凭证经保险库注入、不进沙箱、模型不可见；高危动作可审批、全程可审计。

高弹性、高扩展的执行层

ELASTICITY 高弹性

沙箱秒级拉起 / 用完即收，0 常备算力。

SCALABILITY 高扩展

单集群并行承载数万隔离循环，规模越大单 loop 越省。

以 **AMD EPYC** 为代表的现代CPU服务器，满足规模化隔离循环的算力要求：

高核心密度

数万隔离循环

Chiplet 线性

加核不掉性能

大内存带宽

长上下文并发

高主频 / IPC

秒级冷启、单步快

Forward: 更完整的交付形式

对于希望尽量减少自建的企业，Forward 帮你托管起来。

终端用户身份

给每个 C 端用户隔离身份与令牌，不用自建多租户

IM 渠道

企微 / 钉钉 / 飞书，@ 即对话，不写一行对接

定时任务

按用户的周期任务，到点自动起会话执行

三级用量分摊

租户 → 用户 → 会话，看账与内部分摊

用 Forward，秒级建一个「你自己的」AI 同事

Claude Tag (Slack 里常驻的 AI 同事)

- 一个频道一个 AI，多人共享、可接力
- @ 它派活，它拆阶段执行
- 主动跟进、自排定时，自主推进数小时到数天
- 管理员授权工具、设预算、留审计

用 Forward，你能秒级拥有它

- 在企微 / 钉钉 / 飞书里 @ 一个懂业务的 Agent
- 终端用户隔离、可治理、按用户计费
- 模型中立，不绑定单一模型
- 数据可不出域，面向中国 IM 落地

三类落地：同一套运行时，三种用法

1

嵌入内部 loop

把 Agent 嵌入内部 AI 工作流 / 数字员工：事件触发 → 执行 → 验收 → 回写系统

2

存量应用 AI 化

把循环能力嵌入自有产品，从「逻辑型软件」升级为「智能型软件」

3

交付给终端用户

平台型 / 行业软件商把 Agent 交付给自己的 C 端用户（用 Forward）

端到端案例：一个 AI 投研助手

某金融场景下，QCA 把「检索 → 研判 → 执行 → 持续跟踪」整条链路托管下来。

查数据 全市场数据一句话查询

QCA: 工具 / MCP 接入数据底座 + 沙箱执行

诊个股 几分钟出全景诊断报告

QCA: 多 Agent 协同 + 验收报告质量 + 产出取回

智能选股 口语化需求拆成多维因子

QCA: 规划 + 工具编排，落成可执行任务

自动盯盘 7 × 24 盯盘、条件触发推送

QCA: 原生定时 + 长时常驻 + IM 推送

客户不用自建 agent loop / 沙箱 / 调度 / 多租户，专注业务本身。

THANKS

探索 AI 应用边界

Explore the limits of AI applications

AiCon
全球人工智能开发与应用大会