

AI神盾平台在金融生态中的智能风控实践

演讲人：黄佳豪

平安人寿 / 金管家基础平台研发组副经理

AiCon

全球人工智能开发与应用大会

目录

一、风控系统演进

二、AI神盾平台架构


三、AI巡检智能体

四、风控场景深度实践

五、未来展望

活动风控缺失案例：缺乏触点，错失窗口，造成资损

背景：某营销活动涉及到奖品发放奖励，常规风控平台仅支持规则风控、日志告警、库存管理等基础能力，因无法及时发现并阻断奖品发放导致资损。






如何搭建安全高效的智能风控系统？

01 风控系统演进

从规则引擎到智能风控系统

风控系统演进：风控体系从传统风控演进到智能风控时代





风控系统演进：AI神盾平台风控策略提升演进

规则引擎

基于静态阈值、条件脚本，对已知模式的异常交易、高频请求等确定性风险实现毫秒级实时拦截与处置

数据建模

引入用户画像、设备指纹等特征，构建统计与规则复合模型

PAPM告警体系

建立多源告警采集、分级与聚合机制，实现风险可主动感知、观测

神盾平台

统一各渠道资产、策略与执行触点，形成中心化风控中台

风控智能体建设

加入AI巡检智能体，赋予平台自主归纳、预测与进化的能力



基础风控规则体系



结合数据引擎建模



集成告警触达能力



全面收拢风控场景



结合AI建设智能风控

规则迈向智能

数据驱动管理

行业风控建设现状：行业AI建设在架构设计、记忆建设、模型投入上出现分级

保险行业AI建设现状			
维度	头部机构	中小型机构	行业基准
核心架构	多Agent协同 workflow	单点AI+规则引擎	以单点Agent为主
记忆机制	长记忆链路	对话上下文	-
模型建设	分级管理模型	小规模开源模型	开源模型
多模态能力	音频+基础文本	基础文本分析	基础文本分析
数据模型	私有自建	依赖共享	数据私域
拦截率	-	-	72%
高价值欺诈率	-	-	2%
长记忆能力的风控系统 MTTR（平均修复时间）	-	-	15min

行业风控趋势：AI智能风控时代的风险呈现复杂性增高、对抗性增强的特点，风控系统的识别治理经验需与时俱进

传统业务 TRADITION

INNOVATION 智能风控

2022年~2026年

风险类型

● 单点静态风险

动态复杂风险 ●

风险特征

● 规则化、可预测

自适应、对抗性 ●

风险识别

● 规则驱动、人工判断

多模态感知、智能推理、辅助决策 ●

决策经验

● 规则经验文档化

动态分级记忆 ●

合规重点

● 流程合规

生成式、算法合规 ●

责任边界

● 人工决策责任明确

AI决策责任界定模糊 ●



风控系统痛点：风控体系存在架构设计缺陷、外部风险升级、内控能力缺失的三大核心痛点



02 AI神盾平台架构

面向金融生态的统一风控底座

价值维度：建设四维全面监控平台，覆盖152个业务场景



四维协同，构建从发现到处置、从阻断到通知的闭环能力，实现智能化事前防御。

AI神盾平台

统一资金、奖品、权益资产的实时风控中台

152
场景数

+42%
阻断风险效率

85%
问题发现精确度

+50%
问题解决效率


目标维度：建立告警指标体系，双维度监测运营情况




平台功能：拆解五大垂域风控功能，从接入到治理搭建神盾平台

神盾平台功能矩阵					
	资金风控S1	营销风控S2	账户风控S3	内容风控S4	业务风控S5
运营治理L5	对账监控平台	CMS管理平台	AI巡检	UGC系统	商户开放平台
	混淆矩阵计算	库存管控平台	客户声音平台	内容审核平台	合规审计跟踪
决策执行L4	收银台风控	资质管理	二次加验	生成式审核	API权限管理
	人工审核	流程风控	黑名单管理	脱敏过滤	商户入驻管理
智能分析L3	交易行为画像	链路模型识别	行为特征分析	敏感词识别	商户风险画像
	欺诈特征分析	聚类分析	设备环境分析	多模态分析	入驻审核管理
数据处理L2	行为日志聚合	频次数据统计	统一信息构建	数据清洗	指标计算
接入管理L1	数据标准化	拦截触点接入	SDK集成	渠道统一	协议适配

■ ■ 平台架构：搭建规则、数据、AI三大引擎，打通从问题发现、根因分析到工单闭环的全链路，实现资金安全零资损




平台流程：搭建从数据采集、智能分析、分级告警及自动熔断到工单闭环的全链路风险管控




03 AI巡检智能体

发现/分析/解决风险问题的智能体建设

AI巡检架构：Agent + workflow 协同与分析，实现根因准确率超 85%，处理周期缩短 50%



Agent流程：以 AI Agent 多维分析为核心，打通数据汇聚、分级告警、工单闭环与知识自学习全链路，构建持续演进的智能巡检体系



Agent调用选择：明确流程要求，以定义角色判断调用方式

•Workflow:


像一条高度自动化的工业流水线，每一步都是预设的、可追溯的。它追求的是**可靠性、低时延、强合规**。

•AgenticAgent:

像一个经验丰富但思维活跃的分析师，它能感知环境、调用工具、动态规划路径。它追求的是**灵活性、深度推理、应对未知**。



知识体系：形成向下沉淀与向上召回的知识闭环，提高诊断效率




长记忆链路建设：数据归类与知识沉淀，把每一次风控决策的推理过程、证据链、上下文和事后归因，沉淀为可持续演化的、且即时调用的知识资产

没有记忆的智能，只是应激反应。必须有一套能持续积累、理解、融合、复用全域数据的认知中枢。





生成与验证引擎双驱动：基于Agent Harness建设验证引擎，辅助决策生成





04 风控场景深度实践

场景驱动，工具赋能


运营问题案例：通过基线预测风控拦截红包活动配置异常问题

背景：运营人员配置红包金额异常，经配置页双限提醒（红包覆盖率/大额占比）后仍发布上线，活动中通过历史基线预测发现异常，收到告警后快速调整恢复




开发缺陷案例：通过实时对账风控拦截活动红包发放异常问题

背景：因活动红包发放代码存在漏洞，导致黑产可通过修改地区绕过限制刷取红包；通过实时对账发现红包发放与交易对应流水不匹配，告警触发**自动化下线对应活动**，避免资损扩大



实时对账

分钟滚动窗口内，同步校验天平两端的笔数差率和金额差率。达到阈值触发首次告警，T+5 分钟二次复核确认。



外部黑产案例：通过AI分析客诉问题拦截黑产套取权益问题

背景：每月进行客诉AI分析过程中发现部分客户投诉权益无故被使用，经AI分析后发现存在某地域及机型特征（被远程操控），进而风控对应人群避免问题进一步扩散。



客户声音平台

通过多渠道采集客诉问题，用于产线体验治理并提前发现风险问题



AI巡检智能体


通过AI巡检定期汇总分类，根据客诉描述判断风险问题提供建议，核查后打标



标签人群风控

针对打标人群，进行风控策略下发，避免对应客户二次出现资产问题


建设策略：基于投产进行智能风控系统建设四象限分析




05 未来展望

技术演进与生态共建

风控生态共建：维护私有规则及触点，共建模型及工具复用，结合Harness思想，提升知识体系建设



风控智能体趋势：记忆机制决定智能体能力上限，从数据治理向上建设数据分类统一本体至应用



THANKS

探索 AI 应用边界

Explore the limits of AI applications

AiCon

全球人工智能开发与应用大会