

MinerU

—面向Agent时代的文档解析基础设施演进与实践

演讲人：何聪辉

上海人工智能实验室 / 青年科学家

AiCon

全球人工智能开发与应用大会

目录

01 背景

02 MinerU 整体演进

03 MinerU 生态建设

04 未来展望与探索

01 背景

从 OCR 到智能文档理解的演进历程

文档解析的四个发展阶段

2015



传统 OCR 时代

单一任务 纯文本提取

- ✓ 聚焦街景文字识别和扫描文档
- ≡ 代表：CRNN, EAST, PaddleOCR
- ⚠ 复杂排版解析能力有限

2024



大模型团队觉醒

知识载体 RAG 检索

- ≡ LLM 预训练高质量数据供给
- 🔍 解析精度决定 RAG 答案可靠性
- 🏦 金融/法律/医疗场景需求爆发

2025



百家争鸣

标配维度 评测基准

- 🧠 文档解析成为大模型基础能力标配
- 🔗 代表：Gemini 3 Pro, GPT-5, DeepSeek
- 📊 OmniDocBench 成为共识基准

2026




应用爆发

智能体办公 生产力场景

- 🖥️ AI 办公与智能体时代全面兴起
- ✂️ 代表：Claude Code, OpenClaw
- 📁 覆盖合同审查、研报分析等场景

大模型时代文档解析的核心地位

场景一：LLM 预训练数据管线



90%+

学术论文 PDF 占比


TB 级

未挖掘高质量文档数据

❗ **互联网数据瓶颈：**网页数据已不足以支撑模型持续进化，高质量语料日益稀缺。

🔗 **解析质量决定数据质量：**文档解析的准确性直接影响预训练数据的质量，进而影响 LLM 能力上限。

场景二：RAG 系统精准检索



✓ **解析精度 = 答案可靠性**

🔗 **误差传播效应：**解析阶段的微小误差会在后续环节（分块、向量化）被放大，最终影响生成质量。

🎯 **领域特化需求：**不同领域解析精度要求不同，金融研报要求数据极高准确性，法律合同要求条理清晰，医疗病历关乎生命安全。

02 MinerU 整体演进

三个阶段的技术飞跃：Pipeline → 解耦式VLM → 数据驱动新范式

智能数据提取引擎-MinerU



大模型时代 数据提取/转换神器

支持格式：

PDF

Word

网页

Excel

更多


应用场景：

大模型语料生产

RAG

Agent 构建

更多



官方网站 mineru.net

开源社区 github.com/opendatalab/mineru

MinerU v1: Pipeline方法-2024年初

⚠ 背景与动机

🤖 端到端大模型

如 Nougat, 仅支持英文、速度慢、幻觉严重

🧩 传统拼凑方案


如 Marker, 简单拼凑已有方法, 效果很差

📖 Library 解析

如 PyMuPDF, 无法处理扫描件

🔍 OCR 直接提取

丢失文档结构, 表格/公式噪声大



√x 公式识别与评测

CVPR 2026

CVPR 2025

- ✓ UniMERNet 公式识别: 提出百万级多样性公式数据集, 性能对标 Mathpix 商用软件。
- 📈 CDM 公式评测指标: 针对 LaTeX 表达多样性, 提出图像渲染级对比, 解决 Edit Distance 不合理问题。




🍱 布局检测

SOTA

- ⚡ DocLayout-YOLO: 结合 YOLO 速度优势与 Mesh-candidate BestFit 数据合成技术。
- 🏆 极致性能: 基于 DocSynth-300K 训练, 检测速度比 LayoutLMv3 快一个数量级。

🚀 发布两个月内多次登顶 GitHub Trending Python 榜首

MinerU Pipeline总览



📄 学术论文

📄 考试试卷

📄 报纸期刊

📄 教材

📈 财务报告

...

Text

Title

Image

Table

Equation

■ MinerU v2.5: 解耦式多模态大模型-2025年9月

OmniDocBench 评测基准

在优化模型之前，我们发现社区缺乏统一的评测体系。OmniDocBench 成为**首个**多样性文档解析评测基准：

9

文档类型

4

版式类型

3

语言

细粒度标注

文本、公式、表格、阅读顺序等多维度评测

行业认可


后续被 Gemini 3 Pro、GPT-5、Qwen、DeepSeek 等采用为基准



■ MinerU v2.5: 解耦式多模态大模型-2025年9月

从 Pipeline 到解耦式VLM

- × Pipeline 根本问题：多模块各自维护，更新迭代成本极高
- × 泛化瓶颈：无法有效借助大模型生态的泛化能力提升
- ❗ 端到端痛点：复杂文档幻觉严重，速度慢无法满足实时需求




关键任务专项优化

布局




21类细粒度标签+ PageloU指标

公式



ADR原子解耦与无损重组

表格



OTSL格式优化结构化输出

挖掘



IMIC推理一致性交叉验证



MinerU v2.5 框架架构

Step2


- ✓ 基于Stage I 定位框
- ✓ 裁剪原生分辨率区域
- ✓ 并行处理各类元素
- ✓ 文本/公式/表格
- ✓ 避免 $O(N^2)$ Token 复杂度

Step1


- ✓ 输入下采样缩略图
- ✓ 类别+旋转方向
- ✓ 高效全局分析
- ✓ 阅读顺序
- ✓ 输出 Bounding Box



Stage I: Layout Analysis



Stage II: Content Recognition



MinerU2.5 二阶段解耦架构, Stage I 低分辨率全局布局分析 + Stage II 原生分辨率局部内容识别

■ 关键任务专项优化

1 统一标签体系 + PageloU

扩展到 **21** 个细粒度类别: text, title, phonetic, image_caption, image_footnote, table_caption, code, algorithm, reference, list 等

多任务范式: 单次推理同时预测 Position、Class、Rotation、Reading Order

PageloU: 页面级覆盖率指标, 对分割粒度不敏感, 比 mAP 更贴近人类感知

2 ADR 原子解耦与重组

核心思想: 复合公式 = 多行原子公式的垂直排列

四步流程:

- ① Formula Detection → ② Atomic Decomposition
- ③ Formula Recognition → ④ Structural Reconstruction

优势: 将复合公式拆解为原子行分别识别, 降低长序列解码难度, 利用布局位置信息还原完整公式

3 OTSL 表格识别格式

OTSL (Optimized Table Structure Language): 将 HTML 的 28 种结构 token 压缩到仅 5 种

50% **2D**

序列长度缩短 直观矩阵映射

流程: 先检测旋转 → 矫正几何 → 再识别, 有效处理旋转表格


4 IMIC 推理一致性挖掘

核心原理: 如果模型已充分学习某特征, 多次推理应高度一致

流程: 同一输入三次推理 → 计算成对一致性 (PageloU / TEDS / CDM) → 低一致性 = Hard Case → 人工标注

洞察: 推理结果差异大 → 样本在模型决策边界附近 → 最有价值的标注目标

PageIoU指标



PageIoU示例图

页面级

覆盖率评估

粒度无关

不惩罚细粒度

人类感知

更贴近主观评价

ADR原子解耦与重组框架

技术优势

- ✓ 降低解码难度：避免长序列导致的结构性幻觉
- ✓ 提升识别精度：原子行更易准确识别
- ✓ 保持结构完整：布局信息指导重组过程
- ✓ 复杂公式友好：多行、嵌套公式处理能力强


核心理念

- ✓ 复合公式 = 多行原子公式的垂直排列
- ✓ 解耦策略：将复杂的多行公式拆解为独立的原子行
- ✓ 独立识别：每行原子公式单独进行 LaTeX 识别
- ✓ 位置感知：利用布局位置信息还原完整公式结构


1 Formula Detection




2 Atomic Decomposition



3 Formula Recognition




4 Structural Reconstruction



ADR 四步流程：检测 → 解耦 → 识别 → 结构拼接

表格识别流水线



表格识别流水线

Table & Rotation Detection → Crop & Rotation Correction → OTSL Recognition → OTSL to HTML Rendering

OTSL 格式优势

28→5

token 种类

-50%

序列长度

- ✓ 将 HTML 的 28 种结构 token 压缩到仅 5 种
- ✓ 平均序列长度缩短约 50%
- ✓ 直观映射到表格的 2D 矩阵结构

旋转表格处理

先检测旋转 → 再识别

旋转检测


识别表格的旋转角度 (0°、90°、180°、270°)

OTSL 识别

在矫正后的图像上进行表格结构识别

- ✓ 有效处理旋转表格，提升复杂场景识别能力

IMIC推理一致性挖掘策略



布局检测

度量指标: PageIoU

计算方式: 三次推理的页面级覆盖率对比

筛选标准: 低 PageIoU = 布局边界模糊

表格识别

度量指标: TEDS

计算方式: 三次推理的表格结构相似度对比

筛选标准: 低 TEDS = 表格结构不确定

公式识别

度量指标: CDM

计算方式: 三次推理的视觉特征对比

筛选标准: 低 CDM = 公式识别困难

核心洞察

充分学习 → 高度一致

如果模型已充分学习某特征，多次推理应高度一致

差异大 → 决策边界

推理结果差异大 → 样本在模型决策边界附近

Data Engine 总览



MinerU v2.5 性能排行

首个 OmniDocBench 突破 90 分的模型，1.2B 参数超越 Gemini-2.5 Pro、Qwen2.5-VL-72B、GPT-4o

模型	参数量	Overall ↑	Text Edit ↓	Formula CDM ↑
MinerU2.5	1.2B	90.67	0.047	88.46
Gemini-2.5 Pro	-	88.03	0.075	85.82
Qwen2.5-VL-72B	72B	88.91	0.048	85.67
GPT-4o	-	75.02	0.217	79.70
InternVL3.5-241B	-	82.67	0.142	87.23

90.67

Overall Score

首个突破 90 分

1.2B

Parameters

小模型大能力

1M+

HF Downloads/月

社区影响力

■ MinerU v2.5-Pro: 数据驱动的新范式-2026年4月

核心洞察

跨架构分析发现

不同架构、不同参数规模的 SOTA 模型在相同困难样本上表现出高度一致的失败模式。

- 性能瓶颈不在模型架构，在训练数据
- 保持 MinerU2.5 的 1.2B 架构完全不变
- 纯粹通过数据工程提升性能

92.98 → 95.69

核心突破

+2.71

同架构同参数，纯数据工程带来 +2.71 分提升

数据瓶颈的三个维度



1 覆盖度不足 (Coverage)

MinerU2.5 训练数据 <10M 页，分布集中在高频类别（学术论文、单栏报告），复杂嵌套表格、密集公式版式严重不足。



2 信息量不均 (Informativeness)


Easy 样本占主导，模型已充分学习；Medium/Hard 样本稀缺但训练价值最高



3 标注质量问题 (Accuracy)


Hard 样本恰恰是自动标注最不可靠的——无模型能正确解析的样本，其自动标注噪声会直接传播到训练中。

OmniDocBench V1.6 性能对比



OmniDocBench v1.6 上 Base/Hard/Full 三维性能对比 + 单任务对比

Data Engine 总览




闭环流程：PDF Pool → Balanced Sampling → Annotation

三维协同优化系统——DDAS（采样）+ CMCV（验证）+ Annotation Pipeline（标注）


DDAS 双层采样

1 Page-level sampling



~60M
页面级候选

2 Element-level sampling



~65.5M
最终数据量

多样性维度

大 cluster 降权、小 cluster 升权

难度维度

Medium 和 Hard 样本升权

质量控制

Invalid cluster 过滤

CMCV跨模型一致性验证

三个异构模型

MinerU2.5

Decoupled VLM

1.2B

PaddleOCR-VL

Decoupled VLM

0.9B

Qwen3-VL-30B

General VLM

30B

E Easy

标准： MinerU2.5 与至少一个外部模型高度一致

含义： 模型共识 → 直接用输出作为标注

角色： 基础能力建设的骨干数据

M Medium

标准： 两个外部模型一致但 MinerU2.5 不一致

含义： MinerU2.5 的能力短板 → 外部共识作为伪标签

角色： 训练价值最高

H Hard

标准： 所有模型都不一致

含义： 普遍困难样本 → 需要 Judge-and-Refine + 专家标注

角色： 突破性能天花板的关键

vs 单模型方案 (IMIC / UACS)

✗ 单模型自检只能捕获自身不确定性

✗ 无法区分"模型特定弱点"和"普遍困难样本"

✓ CMCV 使用三个异构模型交叉验证

✓ 提供更可靠的难度分级

三阶段渐进式训练

阶段	Base ↑	Hard ↑	Full ↑	ΔFull	Text ↓	CDM ↑	TEDS ↑
MinerU2.5 (baseline)	93.23	91.65	92.98	—	0.045	95.59	87.88
+ Stage 1: Large-Scale SFT	94.54	93.10	94.29	+1.31	0.039	96.40	90.37
+ Stage 2: Hard-Sample SFT	95.60	93.84	95.25	+0.96	0.036	96.48	92.87
+ Stage 3: GRPO	96.12	94.08	95.69	+0.45	0.036	97.29	93.42

Stage 1 大规模预训练

数据：65.5M 样本（text 21M + layout 14M + formula 13M + table 11.5M + image 6M）

规模：比 MinerU2.5 Stage 1 扩大近 10 倍（6.9M → 65.5M）

贡献最大：+1.31 Overall

Stage 2 高质量困难样本 SFT

数据：3.9M（含 192K 专家标注 Hard 样本 + Stage 1 回放数据）

回放：防止灾难性遗忘，混合比例按子任务差异化设定

表格提升最显著：TEDS 90.37 → 92.87 (+2.50)

Stage 3 GRPO 强化学习

方法：GRPO (Group Relative Policy Optimization)，无需单独训练 reward model

Reward：直接使用评测指标（Edit Distance / CDM / TEDS / IoU）

公式提升最明显：CDM 96.48 → 97.29 (+0.81)

OmniDocBench v1.6升级

问题一：匹配策略偏差

解决方案 — MGAM

Multi-Granularity Adaptive Matching

阶段 1: 原始粒度直接匹配

阶段 2: 预测侧按 LaTeX 分隔符细分后重匹配

阶段 3: 枚举所有可能的合并方案取最优

问题二：Hard 样本覆盖不足

解决方案

Hard Subset

296 页，从 Data Engine 难度分级中选取复杂嵌套表格、密集公式版式、非常规布局等

三层评测体系

1,355

Base: 保持向后兼容


296

Hard: 难样本专项评测

1,651

Full: 综合评估

匹配偏差示例：粒度差异



匹配偏差示例：表达差异



核心结果

模型	参数	Overall ↑	Text Edit ↓	Formula CDM ↑	Table TEDS ↑	Read Order ↓
MinerU2.5-Pro	1.2B	95.69	0.036	93.42	95.92	0.120
MinerU2.5	1.2B	92.98	0.045	87.88	—	0.044
Gemini 3 Pro	—	92.85	0.064	89.15	92.96	0.165
GLM-OCR	0.9B	95.15	0.044	96.99	95.39	0.133
Qwen3-VL-235B	235B	89.78	0.063	92.53	83.07	0.166

95.69

Overall

92.98 → 95.69 (+2.71)

94.08

Hard Subset

领先约 2 分

1.2B

Parameters

小模型大能力

纯数据

工程提升

架构完全不变

🏆 超越所有 specialized models (含 GLM-OCR 95.15、PaddleOCR-VL-1.5 94.87) 和 general VLMs (含 Gemini 3 Pro 92.85、GPT-5.2 86.52)

03 MinerU 生态建设

开源社区影响力、用户规模、生态集成与行业认可

生态影响力



6万

开源系项目GitHub 星标数



900万

VLM 模型累积下载量



19亿次

累计解析文档页数



10万

各在线产品端 MAU



20+款


支持主流应用/Agent/框架



7种

提供GUI /API /CLI 等产品形态


应用案例：中国医学科学院药物研究所



研发核心挑战

- 结构多样性不足，性质权衡矛盾突出
- 专家经验驱动，迭代周期长
- 🔄 AI数据匮乏，无法学习结构-性质映射

MinerU.Chem 全流程自动化管线



首个

大规模光敏剂结构-性质数据集

5x+


效率提升
(vs 开源方案)

6,000+

光敏剂数据条目
(最大规模数据集)

应用案例：中国科学院上海有机化学研究所


MinerU.Chem 人机协同解析管线



自动提取 15 类字段



首个光催化去芳构化反应数据集



10x+

效率提升
vs 人工标注

4,000+

反应条目
最大规模数据集

90+

文献处理
光催化论文

15

提取字段类型
细粒度解析

社区用户高度评价



量子位

7-30 09:50 来自 微博视频号


#开源数据提取工具# 推荐一款一站式、开源、高质量的数据提取工具-- **MinerU**。
它由两个主要部分组成：
1.Magic-PDF 负责PDF文档提取... [查看](#)



Gradio

@Gradio · Nov 15

MinerU is a tool that converts PDFs into machine-readable formats (e.g., markdown, JSON), allowing for easy extraction into any format.
🔥Trending on GitHub on top! Learn more about the ...



Tom Huang

@tuturetom · Jul 17

商用级水准！ RAG 数据清洗关键组件，独创 PDF 内容抽取的「布局识别」和「公式识别」模型，达到 SOTA！
PDF-Extract-Kit 开源
- 在学术论文、电子书、研究报告、金融报告等领域取得...

最新开源的解析效果非常好的PDF解析工具MinerU (pdf2md pdf2json)



毫不夸张的说 PDF解析工具MinerU是照进RAG黑暗中的一道光——这是我对它的评价。我测过太多了文档解析工具!最近在做文档解析的工作。看了很多的开源的文档解析的工具，版面分析的工具，其中包括paddelpaddle这样30k+star的明星工具，但是效果都...



Sofo

@sofolum · Sep 4

最近在构建本地知识库，推荐个很好用的PDF转Mrakdown的工具
MinerU可以快速将PDF转换为Markdown、JSON等格式，而且处理复杂文档结构，如公式、表格、图片等



heycc

@ihaycc · Nov 19

MinerU——开源的最佳 PDF Text、Image、Table、LaTex 公式的提取工具。来自上海人工智能实验室。近期star 数暴涨。
今天仔细研究了一番，项目用到了 OCR、layout、Table...



欧opacity Sun

@Victor84035514 · Aug 1

分享一个我自己用的开源工具 MinerU 可以将 PDF 文档，网页，电子书转换为 Markdown 格式的工具。做一些浏览器插件还是AI应用（提取信息）都很有帮助



蚁工厂

07-21 15:35 来自 微博网页版

MinerU系列工具数据提取工具
[网页链接](#)
包括两块：
Magic-PDF PDF文档转 markdown 格式文档，Magic-...



斌叔OKmath

11-15 08:10 来自 微博网页版

MinerU 是一个将 PDF 转换为机器可读格式(例如 markdown、JSON)的工具，可以轻松提取为任何格式
🔥 Github 上的热门话题！详细了解该项目以及如何...



AbleGPT

@AbleGPT · Nov 17

MinerU：开源PDF内容提取
诞生于书生-浦语的预训练过程中，能保留原PDF文档结构，提取文字、图片、图片描述、表格等内容，自动识别并转换LaTeX格式、HTML格式，自动OCR，支持多语言



R&Dアカ

@RD6862066 · Nov 18

MinerU：高品質データ抽出ツール
PDFから機械可読形式に情報を抽出するツール。
StructTable-InternVL2-1Bを活用した高精度な結果を提供



关木

@ZeroZ_JQ · Nov 30

MinerU
一站式开源高质量数据提取工具，将PDF转换成Markdown和JSON格式



プログラマー@ブログ連続更新中

@selfdevelop2019 · Dec 21

MinerUで実現する高精度PDF解析：Windows + GPU環境構築の完全ガイド



Tom Huang

@tuturetom · Jul 17

商用级水准！ RAG 数据清洗关键抽取的「布局识别」和「公式识别」
PDF-Extract-Kit 开源
- 在学术论文、电子书、研究报告



斌叔OKmath

11-15 08:10 来自 微博网页版

MinerU 是一个将 PDF 转换为机器可读格式(例如 markdown、JSON)的工具，可以轻松提取为任何格式
🔥 Github 上的热门话题！详细了解该项目以及如何使用...



Gorden Sun

@Gorden_Sun · Nov 16

MinerU：开源PDF内容提取
诞生于书生-浦语的预训练过程中，能保留原PDF文档结构，提取文字、图片、图片描述、表格等内容，自动识别并转换LaTeX格式、HTML格式，自动OCR，支持多语言。



欧opacity Sun

@Victor84035514 · Aug 1

分享一个我自己用的开源工具 MinerU 可以将 PDF 文档，网页，电子书转换为 Markdown 格式的工具。做一些浏览器插件还是AI应用（提取信息）都很有帮助



量子位

7-30 09:50 来自 微博视频号

#开源数据提取工具# 推荐一款一站式、开源、高质量的数据提取工具-- **MinerU**。
它由两个主要部分组成：
1.Magic-PDF 负责PDF文档提取... [查看](#)



AbleGPT

@AbleGPT · Nov 17

MinerU：开源PDF内容提取
诞生于书生-浦语的预训练过程中，能保留原PDF文档结构，提取文字、图片、图片描述、表格等内容，自动识别并转换LaTeX格式、HTML格式，自动OCR，支持多语言。

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 8月 📍 深圳 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海 🧑 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

AiCon

全球人工智能开发与应用大会

深圳站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 8 月 21-22 日 / 深圳湾万丽酒店



参会咨询

专题: Harness Engineering: 模型之外的智能体工程

专题出品人: 柴思远

智谱 / 副总裁



专题: 超级个体与蜂群智能的共生进化

专题出品人: 张昊阳

EvoMap / 创始人



专题: AI Agent 高价值商业场景实战

专题出品人: 李响 博士

平安科技 / 智能两核 AI 部总经理



专题: 超级 App 的 AI 原生化: 端智能、端云协同与用户体验重构

专题出品人: 黎三平

京东 / 端技术负责人



专题: AI 原生新范式: Coding Agent 重构软件研发全流程

专题出品人: 林香鑫

网易游戏 / 高级技术经理



专题: 智能体时代的数据供给与治理

专题出品人: 陈廷梁 (王赟)


数新智能 / 创始人兼 CEO



04 未来展望与探索

前沿方向与创新探索

未来研究方向



语义等价评测

核心问题：不同格式（HTML vs Markdown）表达同一内容，不同结构（行内列表 vs 两列表格）表示同一布局

解决方案：需要 semantic-equivalence-aware 评测方法，关注语义内容而非表面形式

垂直领域适配

领域特化训练数据 → 精度大幅提升

金融领域 财报表格、K线图、财务指标提取

法律领域 合同条款、引用格式、法律条文解析

医疗领域 病历、检验报告、医学影像配准



数据工程深化


Data Engine 理念扩展至更多视觉-语言任务

图像描述生成

视觉问答VQA

文档视觉理解

多模态预训练



探索一：AgenticOCR按需动态解析

核心理念

范式转变


OCR 从"静态全文处理"转变为"按需动态解析"

人类阅读类比

- 先快速浏览全文，把握整体结构
- 定位感兴趣的区域
- 放大、旋转、仔细查看细节
- 提取关键信息，忽略无关内容

模型行为

模型自主分析文档布局，选择性地 zoom 和 rotate 感兴趣的区域



MMLongBench-Doc

超越人类专家水平

按需解析

信息需求与检索粒度解耦

AgenticOCR概览

训练流程

1

SFT Trajectory Distillation
从专家轨迹学习工具使用策略

2

GRPO 优化
强化学习优化工具使用策略

目标: 学习何时 zoom、何时 rotate、关注哪些区域

Zoom

放大感兴趣区域

Rotate

旋转调整视角

推理流程

1

Visual RAG Pipeline
集成到 Embedding + Reranking

2

动态解析
根据查询需求选择性解析文档区域

优势: 避免全文解析, 提升效率和相关性

Select

选择性解析

Efficient

高效精准

探索二：MinerU-Diffusion 扩散式并行解码

核心思想

逆渲染视角


将文档 OCR 重新理解为逆渲染 (Inverse Rendering) 过程

关键洞察

左到右的因果生成是序列化的人为约束，文档内容在页面上是空间分布的，而非严格序列依赖

扩散模型替代

用扩散模型替代自回归解码：从全 masked token 出发，迭代并行去噪



3.26×

最高加速比

99.9%

2.12× 加速精度

技术创新

Block-wise Diffusion Decoder


- 块内双向注意力：并行扩散优化
- 块间因果注意力：保持粗粒度结构

Uncertainty-driven Curriculum Learning

两阶段训练：先学全局结构，再学细粒度恢复

置信度阈值控制

低阈值 → 更多并行更快但稍损精度；高阈值 → 接近自回归质量



98.8%

3.01× 加速精度




扩散式 vs 自回归式

块间因果注意力

保持粗粒度结构

块内双向注意力

并行扩散优化



扩散式 vs 自回归式解码范式对比

THANKS

探索 AI 应用边界

Explore the limits of AI applications

AiCon

全球人工智能开发与应用大会