

迈向情境智能

MOSS多模态模型的交互新范式

邱锡鹏

复旦大学、上海创智学院、模思智能

2026 年 6 月 26 日

AiCon

全球人工智能开发与应用大会

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 8月 📍 深圳 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海 🧑 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

AiCon

全球人工智能开发与应用大会

深圳站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 8 月 21-22 日 / 深圳湾万丽酒店



参会咨询

专题: Harness Engineering: 模型之外的智能体工程

专题出品人: 柴思远

智谱 / 副总裁



专题: 超级个体与蜂群智能的共生进化

专题出品人: 张昊阳

EvoMap / 创始人



专题: AI Agent 高价值商业场景实战

专题出品人: 李响 博士

平安科技 / 智能两核 AI 部总经理



专题: 超级 App 的 AI 原生化: 端智能、端云协同与用户体验重构

专题出品人: 黎三平

京东 / 端技术负责人



专题: AI 原生新范式: Coding Agent 重构软件研发全流程

专题出品人: 林香鑫

网易游戏 / 高级技术经理



专题: 智能体时代的数据供给与治理

专题出品人: 陈廷梁 (王赟)

数新智能 / 创始人兼 CEO



目录

01 背景

02 MOSS-VL

03 MOSS-Audio

04 MOSS-TTS

05 总结

01

背景

多模态需求、情境智能与总体能力格局

■ 情境智能时代：交互回到最自然的方式

碳基生物交互的信息传递渠道（%）

视觉

空间信息：
只进不出的单向交互

55%

听觉

声音：
边进边出的双工交互

38%

文本

语言内容：人类压缩的信息

7%

人与人之间最自然的交互方式

视觉 55，听觉 38，文字只占 7——纯文本模型，恰好漏掉了那 93%

特性

拓展下沉与未来市场

- 拓展下沉用户群体
- 面向新一代人群，更酷的交互

不受屏幕限制


- 无GUI交互流程预设
- 天然适配多任务并行

信息含量更高

- 语气、语调、真实情感信息
- 环境、空间等情境信息

交互智能

早期尝试：SpeechGPT —— 原生跨模态语音对话（2023）



SpeechGPT 把语音转换为**离散词元**，统一进 LLM、再还原为语音

早期首创

首个端到端模型，把语音离散成词元、纳入 LLM 词表，实现原生跨模态对话


统一离散建模

语音与文本共享同一自回归框架，跨模态对话内生于模型，无需 ASR→LLM→TTS 级联。

离散 token 统一建模"路线

延展出 AnyGPT（万物皆 token）与 MOSS-Speech（真·语音到语音）。

早期尝试： AnyGPT： 任意模态的统一离散建模（2024）



四种模态各自离散成 token，经统一 LLM 实现任意模态互转

万物皆词元

文本、语音、图像、音乐各用专属 tokenizer 离散成词元，统一进同一个 LLM。

Any-to-Any 生成

任意模态输入、任意模态输出；基于 LLaMA-2 仅扩词表、不改 LLM 架构，训练稳定。

AnyInstruct-108k

构建 10.8 万条多模态交错指令数据，支撑跨模态指令对话。

MOSS多模态能力总览

VL: 看得懂

图像与视频理解
时序定位与空间推理
面向长视频和实时交互

Audio: 听得清

通用音频理解
ASR、说话人、环境声、音乐、问答与推理
面向复杂真实场景

TTS: 说得自然

语音与音频生成
零样本音色克隆、低延迟本地生成
支撑智能体交互闭环

VL、Audio、TTS 是同一多模态基础模型体系的三类能力面

■ 机遇与挑战：多模态模型进入情境智能阶段

机遇

- **视频与音频成为下一代交互入口**
真实场景天然包含画面、声音、说话人和环境信息，单文本模型难以完整承载。
- **长上下文让模型理解过程与因果**
长视频、长音频和多轮对话把模型从静态识别推向事件追踪、状态变化和时序推理。
- **端侧与实时部署打开应用空间**
低延迟语音生成、视频问答和音频理解可以进入会议、教育、智能体与具身场景。

挑战

- **多模态 token 量急剧膨胀**
视频帧、音频片段和图文交错输入会显著增加 prefill 成本和显存占用。
- **跨模态对齐与时间建模更难**
模型需要同时处理空间位置、绝对时间、说话节奏和多源事件之间的依赖关系。
- **推理系统必须和模型协同优化**
mm_features 生命周期、cross-attention、流式解码和本地小模型需要一体化设计。

MOSS多模态：用 VL / Audio / TTS 三条能力链，支撑统一的情境智能系统

多模态模型的发展轨迹

从看懂单图，到读懂视频——每一代都在给模型加一个维度；现在，轮到实时交互。



MOSS多模态聚焦实时交互

02

MOSS-VL

视觉/视频理解、训练评测、Demo 与 VL 推理优化

■ 视频理解：多模态的核心赛道

信息密度高

一段短视频也包含数十至数百帧；视觉 token 量级远超长文档与单图，对模型架构与推理效率都提出极高要求。

时序推理是新维度

动作识别、事件因果、状态变化、过程拆解这些任务，仅靠帧级理解无法解答，必须跨帧、跨秒地连贯推理。

实时交互是核心场景

直播分析 · 监控异常 · 互动陪伴 · 第一视角辅助 · 机器人决策；对延迟敏感、对长上下文有刚需。

MOSS-VL 把视频理解作为第一性能力——从架构、数据到推理，逐项专门优化。

多模态模型的现状与挑战

实时交互延迟

视觉编码与生成串行执行，首 token 等待显著；动态视频流场景对延迟高度敏感，需尽量压低首 token/首帧等待。

长视频理解

数小时素材 token 量动辄数十万；时序一致性与精准动作定位难以兼得。

动态分辨率与帧率

传统位置编码假定固定尺寸、均匀采样；真实素材的分辨率、帧率、宽高比千差万别。

推理效率与显存

多图、多轮、多模态场景下 KV 急剧膨胀，现有推理框架在显存占用与吞吐效率上均承受极大压力。

■ MOSS-VL：解耦式开源多模态大模型

OpenMOSS 生态中专注视觉理解的核心系列 · 11B 参数


采用 cross-attention 架构实现视觉编码与认知推理解耦，原生支持图像与视频任意交错。

里程碑



github.com/OpenMOSS/MOSS-VL · huggingface.co/OpenMOSS-Team/MOSS-VL-Instruct-0408

整体架构



图：MOSS-VL 整体架构示意

Vision Encoder

高分辨率视觉抽取，统一处理图像与视频帧；与下游 LLM 解耦，可独立演化。

Cross-attention Bridge

视觉特征以 K/V 注入；文本侧 Q 通过 XRoPE 直接对齐时空坐标，跨模态信息按需检索。

LLM Backbone

保留主流 LLM 推理与文本能力；视觉信息通过 cross-attention 按层注入，不污染原文本流。

■ 创新一 Cross-attention 解耦

动机：为什么要把视觉与语言通道分开

- 视觉 token 远多于文本 token
视频帧成百上千，直接拼入同一序列会让自注意力复杂度快速放大。
- KV cache 随解码持续膨胀
多模态序列的 K/V 需要逐步常驻，长视频请求显存压力很高。
- 实时场景需要独立通道
视觉持续更新，语言按需回答；观察和推理解耦后更容易做流式处理。

直接收益：推理优化不再只靠工程补丁

KV Cache 大幅减少

视觉 token 仅在 cross-attention 层作为 K/V 注入；文本侧 self-attention 只缓存语言状态。

解码计算显著加速

生成阶段不再被海量视觉 token 拖慢，自注意力计算量只随文本长度增长。

天然契合实时视频理解

可持续接收新帧并按需回答，避免每次重算完整视觉历史。

核心思想：视觉特征通过 cross-attention 进入语言模型，文本侧仍保留高效、稳定的自回归推理路径

■ 创新二 绝对时间戳

输入表示

```
<|vision_start|>  
  <|time_start|>0.0s<|time_end|>  
  <|image_pad|>  
  <|time_start|>1.2s<|time_end|>  
  <|image_pad|>  
  <|time_start|>2.3s<|time_end|>  
  <|image_pad|>  
  ...  
<|vision_end|>
```

视频显示了一个具有连续动作的动态场景 ...

三大用途

可变帧率适配

显式时间戳允许非均匀采样，不丢失时序上下文

精准动作定位

把绝对时间作为一维坐标，可锚定到具体秒级事件


运动动力学分析

估算速度、加速度与轨迹，支持物理推理

关键做法：每帧前注入专用 time_start / time_end token，让模型显式感知时间

创新三 XRoPE 三维位置编码

XRoPE 在 MOSS-VL 中的注入位置



图：XRoPE 在 MOSS-VL 中的注入位置



设计要点与核心价值

- **视觉 K：注入 XRoPE**
增强位置感知，让视觉 key 携带时空坐标。
- **视觉 V：保持不变**
确保视觉特征保真，避免值向量被位置编码污染。
- **文本 Q：直接对齐坐标**
文本查询通过 XRoPE 对齐 patch 与瞬间，实现精准锚定。

统一模态建模
精准时空锚定
动态输入适配





核心价值：图像、视频和文本都落到同一三维坐标系中，提升时空推理稳定性

■ ■ 训练总览



图：MOSS-VL 训练数据总分布（左 Token 分布、右 Sample 分布）

四阶段预训练数据分布



Stage 1: 视觉-语言对齐

Stage 2: 大规模预训练


Stage 3: 高质量预训练

Stage 4: 退火+长上下文

Stage 1 起步对齐, Stage 2 扩规模引入视频, Stage 3 提质量, Stage 4 退火并扩展长上下文。

SFT 与 RLHF

SFT 数据组成



Total Samples 7.7M

训练对齐路径

SFT

在 PT 模型基础上做有监督微调，对齐人类意图；
兼顾多轮对话与图视频交错输入。


RLHF（进行中）

围绕长视频理解、多轮交互与安全对齐构建偏好数据集，后续持续更新。

训练框架：transformers.Trainer，支持全参与 LoRA

目标：在保留视觉能力的同时，让模型更会对话、更会遵循复杂多模态指令

评测全景 视频理解领先，整体表现稳健



视频理解领先

65.8

vs Qwen3-VL-8B 63.8

VSI-Bench +8.3 pts

VideoMME · MLVU · EgoSchema · VSI-Bench 全面突出

全维稳居第一或第二

多模态感知（MMBench、BLINK）与视觉推理（CVBench、VisuLogic）在 30+ 子任务上与 Qwen 系列贴身竞争。

OCR 文档兼优

83.9

结构化信息处理稳定可靠（DocVQA / ChartQA / OCRBench）

视频理解专项亮点

视频空间推理

+8.3 pts

VSI-Bench

vs Qwen3-VL-8B-Instruct

多模态长视频理解

+6.3 pts

MLVU

vs Qwen3-VL-8B-Instruct

时序逻辑推理

+6.7 pts

TempCompass-MC

vs Qwen3-VL-8B-Instruct

动作时刻定位

+3.7 pts

TimeLens-Charades

vs Qwen3-VL-8B-Instruct

时序、空间、动作定位——三大视频子赛道全面领先，长视频理解尤其突出。

综合对比 MOSS-VL vs Qwen 系列

		 MOSS-VL	Qwen3-VL-8B Instruct	Qwen2.5-VL-7B Instruct	LLaVA-OneVision-1.5 8B-Instruct	MOSS-Video-Preview Realtime-SFT	MOSS-Video-Preview SFT
Multimodal Perception	MMBench-EN	94.4	87.6	<u>87.8</u>	84.1	84.0	83.1
	MMBench-CN	92.0	<u>88.9</u>	86.1	81.0	83.0	82.0
	MMStar	<u>67.9</u>	70.9	63.9	67.7	53.1	49.0
	SeedBench	<u>75.4</u>	75.8	74.0	55.3	69.4	50.1
	RealWorldQA	66.5	71.5	<u>69.3</u>	68.1	60.9	59.5
	MMERealWorld	65.5	59.7	54.6	<u>62.3</u>	44.3	51.9
	BLINK	72.1	<u>69.1</u>	55.1	49.7	--	--
	POPE	88.0	89.9	87.7	<u>89.2</u>	88.2	87.9
	MMMU_val	53.9	69.6	54.9	<u>55.4</u>	47.4	45.3
	CountBench	<u>87.2</u>	80.5	87.0	88.2	74.8	17.5
	CVBench	<u>84.9</u>	85.7	80.1	80.8	73.0	70.2
	V*	84.8	90.1	71.7	73.3	49.7	62.8
Multimodal Reasoning	VLMsAreBlind	<u>69.2</u>	74.0	52.3	51.1	50.2	47.5
	VisuLogic	28.8	28.0	25.9	27.0	28.6	<u>28.7</u>
	ZeroBench_Sub	11.8	22.8	9.0	<u>12.0</u>	7.8	8.5
	AI2D	83.5	85.7	83.0	<u>84.2</u>	77.3	75.1
Document / OCR	DocVQA	91.0	96.1	<u>95.7</u>	95.0	64.9	80.1
	ChartQA	77.5	89.6	<u>87.3</u>	86.5	67.9	68.2
	OCRBench	84.7	89.6	<u>86.4</u>	82.9	67.7	70.5
	TextVQA	82.6	79.5	84.9	79.6	70.9	74.2
Video Understanding	VSI-Bench	67.7	<u>59.4</u>	28.3	--	36.2	33.5
	VideoMME	<u>69.4</u>	71.4	65.1	--	62.5	59.8
	MLVU_dev	84.4	<u>78.1</u>	70.2	--	61.8	60.3
	LongVideoBench	66.3	<u>66.3</u>	54.7	--	51.6	54.1
	LVBench	52.6	58.0	45.3	--	38.9	39.7
	EgoSchema_subset	<u>66.2</u>	70.4	63.8	--	54.8	47.4
	TempCompass-MC	76.3	69.6	<u>72.5</u>	--	59.7	61.7
	TempCompass-YorN	78.1	73.9	<u>74.4</u>	--	72.0	70.7
	TimeLens-Charades(mIoU)	52.0	<u>48.3</u>	39.3	--	--	--
	TimeLens-ActivityNet(mIoU)	48.6	<u>46.8</u>	31.4	--	--	--
	TimeLens-QVHighlights(mIoU)	61.8	<u>59.4</u>	31.6	--	--	--

Note: All scores normalized to 0-100. Bold + red = SOTA. Underline = 2nd best.

典型场景

 **毫秒级**
边看边说


 **持续观察**
全天候观察

 **自主策略**
真正自主语境交互

 **动态纠错**
可立刻中断并纠正

Gemini 3.1 Flash Live Preview

MOSS-Video



基于异步实时视频流传输和时序位置编码技术
实现文本生成流解耦的实时自适应主动交互能力和长时序一致性

02

MOSS-VL 推理优化

Cross-attention mask、mm_features 显存释放与 SGLang 部署

■ SGLang: 高性能 LLM 推理框架

极高吞吐

RadixAttention + CUDA Graph +
PagedAttention
端到端吞吐显著优于主流推理框架。

灵活后端

原生支持 FA3、FlashInfer、Triton 三种
attention 后端，可按 prefill / decode
阶段独立选择。

多模态完备

图像、视频、音频统一抽象
配套缓存、并发、长上下文等关键机制。

但落到 MOSS-VL，还要专门优化

SGLang 主分支不原生支持 cross-attention 架构；长请求下 mm_features 仍会持续占用显存。下面展开我们的两项针对性优化与最终性能效果。

■ 优化 ① FlashInfer Cross-attention Mask

问题：社区缺失高效方案

● 特定 mask 形态

文本 Q 对视觉 K/V 的可见性，在多层对话与视频流中有特殊约束。

● 现有 backend 难以表达

FlashAttention / FA3 / FlashInfer 默认面向自注意力，无法直接覆盖该行为。

● fallback 难以上生产

缺少高效 kernel 会让 cross-attention 多模态模型走慢速路径。

方案：扩展 FlashInfer 自定义 Mask

专用 mask kernel

性能与 self-attn backend 同档位。

多轮对话可见性

正确处理视觉帧与历史上下文约束。

视频流增量推理

新帧到达时增量计算，避免重算历史。

已合入 SGLang 主分支

任意 cross-attention 架构多模态模型均可受益。

意义：填补开源社区在 cross-attention 推理路径上的工程空白

■ 优化 ② 长请求 mm_features 显存释放

优化前：显存隐形瓶颈

- **Prefill 构建大 tensor**
mm_features 编码视觉帧的中间表示。
- **Decode 已不再引用**
每一步只用文本 hidden state，原始 mm_features 不再参与计算。
- **但仍持续驻留显存**
长视频 / 多图请求显存高位，并发下降且 OOM 风险显著。

优化后：精确生命周期管理

- **Prefill 完成即释放**
cross-attention K/V 缓存就绪后，立即释放原始 mm_features。
- **Decode 只保留必要缓存**
不再驻留视觉大 tensor，保留推理所需 K/V。
- **并发能力提升**
长视频、多图、多轮场景显存压力下降，长请求更稳定。

收益：降低生产环境中长请求的显存压力，提升并发能力与稳定性

性能效果与一键部署

性能效果

4.57×

vs 原生 Transformers

5.48×

vs Qwen3-VL

视频推理 E2E TPS · 同硬件、同输入规模

● 显存

mm_features 精确释放，长视频 / 多图场景压力明显缓解。

● 并发

长请求不再独占显存，单卡并发能力显著提升。

● 开箱即用

SGLang 主分支已合入

一键部署

```
python3 -m sglang.launch_server \  
  --model-path $MODEL_PATH \  
  --host 0.0.0.0 --port 30000 \  
  --dp 1 --tp 1 \  
  --mem-fraction-static 0.7 \  
  --trust-remote-code \  
  --prefill-attention-backend flashinfer \  
  --decode-attention-backend fa3
```

部署提示：Prefill 必选 flashinfer；Decode 可选 FA3 以追求更低延迟

03

MOSS-Audio

通用音频理解、评测、Audio 推理适配

MOSS-Audio

面向真实世界复杂音频的**统一开源音频理解模型**

在同一个模型框架内完成 **六类音频理解任务**

01 语音内容识别

ASR + 字 / 句级时间戳对齐

03 场景与背景声

环境声 · 噪声 · 非语音线索

05 音频问答 & 摘要

播客 · 会议 · 访谈 · 录音

02 说话人 / 情感

音色 · 情绪 · 关键声学事件

04 音乐理解

风格 · 情绪走向 · 乐器


06 复杂推理

多跳推理 · 复杂分析



模型架构 & 关键设计

Architecture



MOSS-Audio-Encoder · 12.5 Hz 超低帧率音频表征

关键设计

DeepStack: 跨层特征注入

多层投影注入 LLM 浅层。

保留声学细节 + 高层语义

低层声学细节与高层语义共同建模。

Time-Aware: 显式时间标记

支持 timestamp ASR / 时间定位。

模型家族

4B / 8B × Instruct / Thinking; 已开源。

架构重点: 用低帧率音频表示和跨层注入, 把声学细节与语义推理同时带入 LLM

评测：通用音频理解

核心结果

71.08

MOSS-Audio-8B-Thinking 平均分

MMAU 77.33


MMAU-Pro 64.92

MMAR 66.53

MMSU 75.52

以小搏大：在通用音频理解基准上，4B 优于多数 7B / 9B 模型，8B 反超部分 30B / 33B 模型

Benchmark 排名



结果说明：小模型规模下获得强通用音频理解能力，体现 encoder 与训练数据协同收益

■ 评测：ASR · Speech Caption · Timestamp

三项关键结果

● ASR

12 维度综合 CER 11.30，开源最低；方言、歌唱、中英混读、非语音音频上显著领先。


● Speech Caption

13 个细粒度维度 11/13 第一；MOSS-Audio-8B-Instruct 全维度平均分 3.73，超越 Gemini-3.1-Pro。

● Timestamp ASR

中文 AAS 35.77，英文 AAS 131.61；时间感知大幅领先开闭源模型。





Speech Caption · 13 维度雷达



雷达对比：13 维度分数

时间戳对比：Qwen3-Omni 833.66 / 646.95；Gemini-3.1-Pro 708.24 / 871.19

对比 Audio-Flamingo-Next (NVIDIA)



通用理解 · ASR · Speech Caption · Timestamp ASR 四类任务上整体领先



多说话人语音识别 MOSS-Transcribe-Diarize

跟穆琉影一起来追剧呀 bilibili 寒战经典之双雄吵架



1:34 / 4:05

MOSS Transcribe Diarize			Gemini 3.1 Pro	
01:25.92	SO2	我现在是ATCP0906		去！
01:29.13	SO2	刘杰辉	01:18.00	SO1 我当警察那么久，还没见过这种场面。如果发生在前线，这就是一场战争。
01:30.55	SO2	我正式解除你的职务	01:26.00	SO1 我现在是Acting CP, 0906 刘杰辉。我正式解除你的职务！
01:35.94	SO1	李Sir	01:36.00	SO2 刘Sir！警队规矩，纪律程序，即使有亲属涉案，都要利益申报，避嫌退出。既然你这么清楚，跟哪一个部门规矩都没有关系！你质疑我的工作能力！我客观认为，应该
01:37.01	SO1	警队规矩		

寒战经典双雄吵架片段，多说话人高语速重叠对白，展示 MOSS Transcribe Diarize 在复杂影视场景下的细粒度转录与说话人分离能力。

在处理长音频和复杂对话时优势显著

03

MOSS-Audio 推理优化

长请求显存释放、thinking budget 与服务化吞吐

MOSS-Audio × SGLang 推理适配

长请求显存释放 · 沿用 VL

● 机制复用

与 VL 同一套 mm_features 生命周期管理：Prefill 完成即释放，decode 不再占显存。

● 音频侧效果

长音频 / 长对话显存压力下降，OOM 风险降低。

● 并发收益

并发能力与上下文长度进一步提升。

Thinking Budget 控制

采样级思考长度控制，采用指令注入方案

budget	效果
0	立即注入过渡句并闭合 <think>
50	允许 ≤ 50 tokens 思考
200	允许较长思考链
none	不限制，自由思考

目标：既控制思考链长度，又降低长音频 / 长对话请求的显存驻留成本

MOSS-Audio Family



MOSS-Music

Open-source music understanding model

在 MOSS-Audio 基础模型上对专业音乐理解进行增强，专门面向：


- 歌词 ASR + 时间戳对齐
- 音乐 caption / tagging (情绪 · 风格 · 乐器)
- 调式 / 节拍 / 和弦推理 · 结构分析
- **8B Instruct + 8B Thinking 已开源**

更多系列模型

敬请期待

Stay Tuned

MOSS-Speech: 端到端语音对话模型



模态分层切分 + 冻结预训练

真·语音到语音

端到端 speech-to-speech, 完全不经文本中介, 保留语气、情绪与说话人等副语言信息。

保留文本智能

模态分层切分 + 冻结预训练: 学会“说话”的同时, 保住文本 LLM 原有的推理与知识。

实时·强表现

Spoken QA 达 SOTA、比肩文本引导系统; 具备 GPT-4o 级实时语音对话能力。

04

MOSS-TTS

语音生成、Tokenizer/RVQ、高效离散化建模、高表现力

MOSS-TTS Family

覆盖从高保真克隆到实时语音智能体的生成模型族

MOSS-TTS: 高保真零样本音色克隆与长文本语音合成


MOSS-TTS-Local-Transformer: 更高效的离散化建模、低延迟场景

MOSS-TTS-Nano: 主打端侧，轻量、可在CPU上实时生成

MOSS-TTSD: 面向多角色长对话，表现力更强

MOSS-VoiceGenerator: 基于文本描述的音色与说话风格设计


MOSS-SoundEffect / Realtime: 音效生成与多轮实时语音智能体



<https://github.com/OpenMOSS/MOSS-TTS>



<https://github.com/OpenMOSS/MOSS-TTS-Nano>

VQ & RVQ



RVQ 多级码本降低重构误差，同时带来更深的 token 解码链路

MOSS Audio Tokenizer: 低帧率、高语义的音频表示



对比维度	MOSS-Audio-Tokenizer	其他公开 audio tokenizer / codec 常见情况
压缩效率	24 kHz 音频压缩到 12.5 Hz 超低帧率	常见为 40/50/75 Hz, 或以 kbps 为主叙事
码率灵活性	0.125-4 kbps 可变码率	多数提供固定或少数几个带宽档位
量化结构	32-layer RVQ, 支持不同 RVQ 层数解码	RVQ 常见, 但层数、码率弹性与 LLM 适配能力不同
架构可扩展性	CNN-free, 纯 Causal Transformer blocks	多数采用 CNN encoder-decoder、RVQGAN 或混合结构
训练数据规模	3M 小时多样化通用音频	公开模型常见数据规模较小, 或主要聚焦 speech
音频域覆盖	语音、音效、音乐统一建模	很多 tokenizer 更偏 speech 或 audio codec 单一目标
语义能力	semantic-rich discrete tokens, 适配 ASR/TTS/generation/understanding	传统 codec 更偏声学重建; 语义 tokenizer 又常牺牲重建
训练方式	完全从零训练, 不依赖 HuBERT / Whisper / teacher distillation	部分路线依赖预训练语义 encoder 或 teacher model
系统优化	Encoder、Quantizer、Decoder、Discriminator、语义对齐 LLM 联合优化	常见为 codec 单独训练, 或语义与声学模块分阶段组合
生态联动	直接支撑 MOSS-TTS Family 与 MOSS-TTS-Nano	多数 tokenizer 与下游生成模型耦合较弱或生态分散

■ MOSS Audio Tokenizer v2: 48 kHz、双通道、通用音频

1 48 kHz 高保真采样

面向 48 kHz 高采样率音频设计，在保留细节的同时，将音频压缩到 12.5 Hz 低帧率离散 token。

2 双通道立体声

原生支持 stereo 双通道输入输出，更适合音乐、环境声、空间感音频等复杂场景。

3 通用音频编解码


基于 300 万小时多样音频训练，覆盖语音、音效、音乐等领域，兼顾高质量重建与语义表征。

MOSS-Audio-Tokenizer-v2 提供 48 kHz 双通道通用音频 tokenizer，将高保真音频压缩为低帧率、语义丰富的离散 token，为原生音频大模型提供统一接口。


Tokenizer 统一音频 token，支撑 MOSS-TTS / Nano / Realtime 的生成与理解复用

RVQ 建模对比：从展平到 Local Transformer


1 Flatten




2 Multi-head Parallel



3 Delay Pattern



4 Local Transformer



Local Transformer 保留全局自回归，把每帧 RVQ 深度交给局部模型

Local vs Delay: 面向低延迟语音生成




Table 3 Zero-shot voice cloning on Seed-TTS-eval. We report English WER (↓), English speaker similarity (SIM, ↑), Chinese CER (↓), and Chinese SIM (↑). The evaluation results are from technical reports of other models, such as VoxCPM [61] and SparkTTS [72].

Model	Mode	Params	Open	EN WER ↓	EN SIM ↑	ZH CER ↓	ZH SIM ↑
DiTAR	—	0.6B	✗	1.69	73.50	1.02	75.30
FishAudio-S1	—	4B	✗	1.72	62.57	1.22	72.10
CosyVoice3	—	1.5B	✗	2.22	72.00	1.12	78.10
Seed-TTS	—	—	✗	2.25	76.20	1.12	79.60
MiniMax-Speech	—	—	✗	1.65	69.20	0.83	78.30
CosyVoice	—	0.3B	✓	4.29	60.90	3.63	72.30
CosyVoice2	—	0.5B	✓	3.09	65.90	1.38	75.70
CosyVoice3	—	0.5B	✓	2.02	71.80	1.16	78.00
F5-TTS	—	0.3B	✓	2.00	67.00	1.53	76.00
SparkTTS	—	0.5B	✓	3.14	57.30	1.54	66.00
FireRedTTS	—	0.5B	✓	3.82	46.00	1.51	63.50
FireRedTTS-2	—	1.5B	✓	1.95	66.50	1.14	73.60
Qwen2.5-Omni	—	7B	✓	2.72	63.20	1.70	75.20
FishAudio-S1-mini	—	0.5B	✓	1.94	55.00	1.18	68.50
IndexTTS2	—	1.5B	✓	2.23	70.60	1.03	76.50
VibeVoice	—	1.5B	✓	3.04	68.90	1.16	74.40
HiggsAudio-v2	—	3B	✓	2.44	67.70	1.50	74.00
GLM-TTS	—	1.5B	✓	2.23	67.2	1.03	76.1
GLM-TTS-RL	—	1.5B	✓	1.91	68.1	0.89	76.4
VoxCPM	—	0.5B	✓	1.85	72.90	0.93	77.20
Qwen3-TTS	—	0.6B	✓	1.68	70.39	1.23	76.40
Qwen3-TTS	—	1.7B	✓	1.50	71.45	1.33	76.72
MOSS-TTS	Clone	8B	✓	1.92	69.31	1.46	76.21
	Continuation	8B	✓	1.84	70.86	1.37	76.98
MOSS-TTS-Local-Transformer	Clone	1.7B	✓	1.87	71.74	1.33	77.24
	Continuation	1.7B	✓	1.93	73.28	1.44	79.62

Local Transformer 保持 voice cloning 质量，同时降低流式语音生成路径延迟


MOSS-TTS 客观评测

Audio Similarity SIM

Seed-TTS-Eval zero-shot subsets | higher is better

Similarity landscape

Top-right means stronger similarity on both English and Chinese subsets.



Average SIM ranking

Average of EN and ZH SIM (%)

MOSS-TTS-Local-Transformer

Qwen-TTS

MOSS-TTS

Fish-audio S2


Vocu V3

MiMo v2.5 TTS

Inword-TTS 1.5 Max



MOSS-TTS 主观评测




04

MOSS-TTS 推理优化


流式输入与输出、极致压缩参数、MTP

推理优化：流式输出与文本流式输入



关键收益：降低 first-audio latency，并让 LLM 文本流、TTS 解码、音频播放形成流水线

推理优化：极致的小模型




开源易用：infer.py / app.py / CLI

对比维度	MOSS-TTS-Nano	其他 100M 级小模型
模型规模	0.1B，轻量部署	多数 15M-160M，但能力边界差异大
音频规格	48 kHz Stereo 原生输出	常见 22.05/24 kHz，或未明确高采样率双声道
语言覆盖	20 种语言	Pocket 约 6，Kokoro 约 8，Marvis 约 3；Kitten 偏少量 voices
推理方式	Streaming，低首音频延迟	部分支持 streaming，但常绑定特定硬件或生态
CPU 友好	4 核 CPU 可流式生成	Pocket / Kitten / Piper 支持；Vui 更强调 GPU/CUDA streaming
Voice cloning	支持，且 transcript free	Pocket / Marvis / Vui 支持；Kokoro / Kitten / Piper 通常不是核心能力
架构路线	Audio Tokenizer + LLM + RVQ；自回归 next-token prediction	连续音频、VITS/ONNX、Llama-style codec 等路线；MOSS 更适合承接大模型语音生成范式

推理优化：MTP（Multi-Token Prediction，多 token 预测）

MTP Accelerates Local Transformer RVQ Depth Decoding



每帧 32 次 local 解码可压到约 8-18 次，端到端加速 1.1-1.25x

05


总结

能力体系、工程落地与后续方向

■ 面向情境智能的多模态基础模型

看得懂

MOSS-VL · 视频理解多模态




超越 Qwen3-VL-8B-Instruct

■ VSI-Bench +8.3 pts;
MMBench 等多项 SOTA

+8.3 pts VSI-Bench

听得清

MOSS-Audio · 通用音频理解



8B 越级反超 30B，比肩
闭源前沿

■ MOSS-Audio-8B-Thinking
Avg 71.08; 覆盖六类能力

71.08 MOSS-Audio-8B

说得自然

MOSS-TTS · 高表现力音频生成




主客观评测效果 SOTA

■ GitHub Star >3K, MOSS-TTS
Family 总下载量突破百万

100 万+ HF 下载

生成同步内容

MOVA · 视音频联合生成



视频 + 音频原生同步生成

■ Verse-Bench 唇同步 LSE-D
7.0948s 360p 显存低至 12

12 GB 最低显存

开源影响力

20,000+

GitHub 累计 Stars
OpenMOSS 组织合计

300 万+

HuggingFace 累计下载量
全组累计 · 截至 2026.6

150+ / 30+

开源模型 / 数据集
学界工业界广泛使用

30+ 基准

领先 Qwen3-VL-8B-Instruct
MOSS-VL 平均 +2.0 pts

■ 机遇与挑战：尚未解决的开放问题

对齐与安全

多模态偏好数据与安全对齐尚未收敛

长视频的能力边界


超长视频的时序一致性与精准动作定位仍随时长下降
容量与精度尚难完全兼得

实时交互

多模态实时交互是大模型的下一个重要机遇

统一多模态（MOSS-Omni）

多模态统一表示与联合训练仍是开放问题



OpenMOSS Github