

Qoder CLI

终端里的全栈工程师

从 Coding Agent 到企业级 AI 应用基础设施

演讲人：邓忠阳

阿里巴巴 / Qoder 技术专家

AiCon

全球人工智能开发与应用大会

目录



为什么需要企业级AI应用基础设施

01



Qoder CLI的技术架构解析

02



Qoder CLI SDK 能力解析

03



典型集成场景

04

01 企业级AI应用基础设施

AI应用迫切需要全新的基础设施

当模型足够强、Agent 足够好、环境足够安全，AI 才能真正交付生产力

① 隔离的工作环境

Agent 需要真实的文件系统、终端、网络——但必须与用户环境隔离，支持快照回滚和权限控制，让 AI 放心试错、人类放心放权

② 企业级 Agent 实现

负责把模型的想法变成真实的动作，从“能聊天”到“能做事”的跳跃。包括工具调度、上下文管理、错误恢复、多 Agent 协作——这些工程能力决定 AI 能否可靠落地

③ 高性能模型

智能的上限由模型决定。但是单一模型很难覆盖所有任务，所以需要多模型路由和策略编排



不同应用/场景对模型的诉求不同


不同场景对模型能力的要求截然不同，单一模型无法覆盖所有需求

为什么不能只用一个模型？

- 复杂推理类任务 → 大语言模型（GPT / Claude / Qwen / DeepSeek 等）
- 图片理解类任务 → 多模态模型（支持视觉输入）
- 高频轻量类任务 → 小参数模型（快速响应、低成本）

三大核心特性

- 模型按任务类型 / 复杂度 / 成本 自动选择最优模型
- 模型不可用时自动降级切换，保障服务连续性
- 统一计费体系，用户无需关心底层模型差异



在实际任务中根据场景不同路由到最合适的模型

Coding Agent 成为行业赋能的关键

通用的执行底座 —— 把自然语言需求转换成可执行动作


为什么 AI Coding 能赋能各行各业？

AI Coding 的本质是：理解意图 → 规划步骤 → 调用工具 → 交付结果。

这套能力可复用到任何「理解需求+自动化执行」的数字化场景。

各行各业的落地场景：

- DevOps 基础设施编排 · 故障自愈 · 监控自动化
- 金融风控 规则引擎配置 · 报表生成 · 合规检查
- 数据分析 SQL 生成 · ETL 搭建 · 可视化报表
- 运营增长 活动页面 Vibe Coding · A/B 实验自动化
- 企业 IM 智能问答 · 任务执行 · 知识库管理
- IoT 嵌入式 固件脚本生成 · 设备配置批量下发



跨平台 · 本地与远端无差异执行

一套 CLI，同一份能力，跑在任何地方

跨平台原生支持


macOS / Linux / Windows 全平台原生运行，同一套 CLI 交互方式，无需适配

本地/远端无差异执行

CLI 在本地终端和远端服务器上的运行行为完全一致，相同的命令、相同的工具链、相同的 Agent 能力，无需任何环境适配

任务自由迁移

运行中的任务可随时从本地推送至远端继续执行，也可从远端拉回本地，任务状态完整保留，迁移对 Agent 透明



■ 三层基础设施 × 三款 Qoder 产品

模型能力 + Agent 框架 + 运行环境，一站式企业级AI基础设施

需要多模型支撑

Qoder Models

Model Inference

- 内置海内外前沿模型，开箱即用
- 智能路由 + 策略分级，性能与成本平衡
- 支持 BYOK，企业密钥灵活接入

需要生产级 Agent

Qoder CLI

Agent Framework

- 生产级 Agent 引擎，稳定可控
- 细粒度工具权限 + 审计回放
- 一行 SDK 接入，嵌入任意应用

需要独立运行环境

Cloud Agents

Secure Environment

- 安全沙箱，隔离执行边界清晰
- 快照式会话隔离，状态可恢复
- 弹性算力，按任务自动伸缩

一套 CLI · 三层能力 · 让每个产品都能内嵌 Agent


Qoder CLI 和 Qoder 产品家族

一套 CLI 内核 · 支撑 Qoder 全产品家族

For Developers · 开发者侧



Qoder
IDE



JetBrains Plugin
IDE 插件



Cloud Agents
云端 Agent



QoderWork
办公场景



QoderWake
数字员工

For Knowledge Workers · 工作场景

Qoder CLI

Coding Agent · 工具集 · SDK · 沙箱接口

大语言模型 LLM Layer

编排 统一调度多 Agent，跨产品复用能力

集成 SDK 一行接入，快速嵌入 Agent 能力

进化 共享内核，一处升级，全家族受益

Qoder CLI SDK: 让每个应用都能内嵌智能体

统一模型接入 · 本地嵌入 · 云端委派 —— 三种集成模式覆盖全场景

01

统一模型接入

Model API

一套 API 接入海内外主流模型，智能路由 + BYOK

适用：需灵活切换模型的应用

02

本地 SDK 嵌入

In-Process Agent

Agent 跑在你的应用进程内，本地执行、全程可控

适用：强隐私、高定制场景


03

云端 Agent 委派

Cloud Task Delegation

把任务交给云端，由 Qoder 调度执行，零基础设施

适用：长任务、弹性算力场景



“不是聊天机器人，不是补全工具 —— 是能自主完成任务的 AI 智能体。”

02 Qoder CLI 技术架构解析

Qoder CLI 整体技术架构


三层主干 + 两根横切：一个 Agent Loop 为核心，被知识层供给、被可观测层监控



基于事件驱动的 Agent 执行循环


模型输出即事件 · 事件类型决定路径 · 同一个循环 × N 个 Agent

A. 单 Agent 内部 · 事件循环



↓ 同一个循环 × N 个 Agent ↓

B. 在循环之上 · 主 / 子 Agent 派生



```
# event_loop.py
Master Agent Loop · 伪代码
while True:
    event = model.infer(context)

    if event.type == "end_turn":
        return event.response # 本轮结束

    elif event.type == "tool_use":
        result = execute(event)
        context.append(result) # 结果回流
        continue
```

为什么用事件驱动?

✗ 同步函数调用

模型 → 工具 → 模型, 调用链耦合死

✓ 事件驱动

模型只产事件, 调度由 Event Bus 决定

→ 可插拔 · 可观测 · 可并发

解耦的力量 模型、工具、宿主三者解耦 — 加工具、加审批、加审计、加子 Agent 都有稳定扩展点

工具实现架构 20+ 个核心工具

流式输出处理 · MCP 协议扩展 · 细粒度权限控制，三大能力支撑工具安全高效执行

工具家族图谱

5 类内置工具 + MCP 协议扩展，能力面持续生长



文件操作

ReadFile · WriteFile · Edit · Glob · Grep



命令执行

Shell · BackgroundTask



网络 / 媒体

WebFetch · WebSearch · ImageGen



任务 / 协作

Agent · AskUser · WriteTodos · Plan · ActivateSkill



MCP 扩展

任意外部工具 —— Slack · Jira · Database · API · 自研服务

26 个内置 + MCP 扩展 = N 个核心工具

1 流式工具输出处理

边跑边渲染 · 用户实时感知 Agent 在做什么


tool 执行结果按 chunk 推送 ——> UI 实时更新

2 MCP 协议扩展外部连接

Model Context Protocol 标准 · 数据库 / API / 内部平台无缝接入



3 细粒度权限三档

按工具粒度配置 · Auto 模式可由 AI 助手代为授权

L1	Read-only	只读访问 · 自动放行
L2	Approve-each	每次操作均需用户审批
L3	Full Trust	完全信任 · 全速执行

工具不是写死的清单，而是可插拔的能力面 — 内置 20+，MCP 接 万物

■ 面向复杂长程任务的上下文管理机制

隐式系统提醒避免信息遗忘 + 智能压缩保证长程任务持续执行不中断

1 Reminder · 隐式系统提醒

- 触发时机：每次推理前



每一轮都注入：当前任务状态 · 工具结果 · 文件变更 · 关键路径

- **Reminder 类型 · 4 类分组**

1 执行状态

工具状态 · 文件变更

2 规划

Plan · Todo

3 能力

Skill · Sub-Agent

4 记忆

Memory

→ 数百轮后仍能**准确感知**任务目标 · 中间决策 · 关键路径

2 Compression · 系统压缩

- 触发时机：上下文使用率接近阈值



- 多层递进方案

Session Memory

完整对话历史

→ **Auto Summary**

智能摘要压缩

→ **Micro Memory**

关键信息提炼

→ 保留关键决策 · 工具结果 · 代码片段 · 错误信息 · 砍掉冗余

长程任务不是靠模型硬扛上下文，而是靠 **Reminder** 主动注入 + **Compression** 智能压缩 共同维护任务连续性

03 Qoder CLI SDK能力解析

数行 SDK 代码 完成 Agent 能力集成

提供 TypeScript / Python SDK · 把完整 Agent 能力开放给所有开发者

```
example.ts · 最小可运行示例 TypeScript

import { accessTokenFromEnv, query } from '@qoder-ai/qoder-agent-sdk';

for await (const message of query({
  prompt: 'Analyze the codebase, find functions without
  test coverage, and write unit tests for them.',
  options: {
    auth: accessTokenFromEnv(),
    allowedTools: ['Read', 'Write', 'Edit', 'Glob', 'Bash'],
    permissionMode: 'acceptEdits', // 自动确认文件修改
  },
})) {
  if (message.type === 'assistant') {
    for (const block of message.message.content) {
      if (block.type === 'text') console.log(block.text); // AI 回复
      else console.log(`Tool: ${block.name}`); // 工具调用
    }
  }
  else if (message.type === 'result') {
    console.log(`Done: ${message.subtype}`); // 完成
  }
}
```

集成只要 4 步

与左侧代码 4 个区域一一对应

- 1 导入 SDK
@qoder-ai/qoder-agent-sdk
- 2 给 prompt + options
tools · permission · auth
- 3 for await 流式消费
text · tool_use
- 4 拿到 result
subtype = success → 任务完成

Agent 能力不是黑盒 CLI，而是 SDK 是 积木 — 任何产品都能嵌入完整 Agent 能力

模型使用策略 集成方自主决策

固定模型 · 动态选择，业务侧按场景灵活控制每次 LLM 调用

4 档模型矩阵

ultimate 最强	performance 平衡	efficient 高效	lite 极简
复杂推理 · 多步规划	日常开发 · 主线编码	大批量调用 · 流水线	简单查询 · 低延迟
能力 速度 成本	能力 速度 成本	能力 速度 成本	能力 速度 成本
●●●●	●●●●●	●●●●●	●●●●●
●●●●	●●●●●	●●●●●	●●●●●
●●●●	●●●●●	●●●●●	●●●●●

1 固定模型

▶ 适用 · 场景稳定 · 调用成本/质量已知 · 无需运行时调整

```
fixed.ts
import { qodercliAuth, query } from '@qoder-ai/sdk'

const q = query({
  prompt: 'Analyze this code',
  options: { auth: qodercliAuth(), model: 'performance' }
})
```

★ 代码最简 · 一行选档 → 上线后行为高度可预期

2 动态选择

▶ 适用 · 不同任务用不同档位 · 成本与质量动态权衡

```
dynamic.ts
import { type ModelPolicyProvider } from '@qoder-ai/sdk'

const policy: ModelPolicyProvider = ({ purpose }) => {
  if (purpose === 'planning') return { model: 'ultimate' }
  return { model: 'performance' }
};
```

★ 规划用 ultimate · 编码用 performance → 按需调配，成本可控

SDK 不替你选模型 — 4 档摆出来，集成方按场景自主决策 · 不锁定，成本可控，质量可调

模型使用策略 SOTA 模型随意切换

三种模型来源协同 · 集成方不被单一供应商锁死

①

Auto 智能档

SDK 内置 5 档 · 智能调度 · 无需关心模型名

策略池

★ Auto · 推荐

智能选档 · 均衡成本

1.0x

Ultimate · 最强

专家级深度推理 · 峰值质量

1.6x

Performance · 平衡

高级推理 · 高质量输出

1.1x

Efficient · 高效

标准推理 · 低成本执行

0.3x

Lite · 极简

基础推理 · 免费可用

Free

②

前沿池 · 持续追新

厂商发新模型 · 自动接入 · 无需自管订阅

SOTA 系列

Qwen-Plus/Max

AUTO UPDATE

通义千问 · 增强推理与 Agent 可靠性

DeepSeek-V4

AUTO UPDATE

DeepSeek · 卓越 Agent 能力与推理

GLM 系列

AUTO UPDATE

智谱 · 长程任务工程级输出

Kimi K 系列

AUTO UPDATE

月之暗面 · SOTA 编码与 Agent 群控

MiniMax M 系列

AUTO UPDATE

MiniMax · 自进化模型迭代能力

③

BYOK · 自带密钥

对接三方服务 · 走自己账户 · 合规可控

三方服务商

阿里云百炼

API KEY

Bailian

通义千问全系列模型

智谱 Z.ai

API KEY

Z.ai

GLM 全系列模型

月之暗面

API KEY

Moonshot

Kimi 系列模型

MiniMax

API KEY

MiniMax

MiniMax 自研系列

DeepSeek

API KEY

DeepSeek

DeepSeek 全系列模型

一套 SDK 接入三种模型来源 — 自主决策 · 不锁死 · 应对丰富多样的商业模式

五道关卡实现细粒度权限控制

从静态规则到运行时审批，全方位管控 Agent 工具能力

Tool Call

① 工具范围

② 权限模式

③ 运行时审批

④ 声明式规则

⑤ Hooks 审计

✓ Execute

① 工具范围

`allowedTools`
`disallowedTools`
静态白/黑名单 · 一刀切

② 权限模式

`plan / auto`
`dontAsk / bypass`
一次性预设模式 · 全局生效

③ 运行时审批

`canUseTool(tool, input)`
回调宿主 · 可注入审批 UI

④ 声明式规则


`settings.permissions`
项目级配置 · 团队共享

⑤ Hooks 审计

`PreToolUse`
`audit`
细粒度日志 · 行为可追溯

③ `canUseTool` · 把决定权交给宿主应用

```
approval.ts
query({ prompt, options: {
  permissionMode: 'default',
  canUseTool: async (tool, input) => {
    // 把审批请求展示在宿主 UI 中
    const ok = await showApprovalDialog({ tool, input });
    return ok
    ? { behavior: 'allow', updatedInput: input }
    : { behavior: 'deny', message: 'Rejected' };
  }
}})
```



五层纵深防御 — 细粒度可观可控 · 满足企业风控合规要求

灵活扩展、按需组合的插件体系

五类扩展点相互正交，可独立使用也可协同工作，构建专属 AI 工程师

①

Output Style

自定义 AI 输出风格 · 适配团队表达规范
system prompt · Markdown / JSON / 表格 / 自然语言

输出层

②

MCP

接入任意外部工具与数据源 · 无限扩展 Agent 能力边界
数据库 · API · 监控系统 · 公司内部系统

输入层

③

Subagent

按场景创建专属子 Agent · 各司其职并行协作
安全审计 Agent · 测试 Agent · 评审 Agent

编排层

④

Skill

封装可复用工作流 · 一行 /slash 命令触发复杂任务链
/release · /review · /onboard · 团队内共享最佳实践


流程层

⑤

Hook · 通用拦截器

在工具执行前后注入自定义逻辑 · 通用拦截器
PreToolUse · PostToolUse · 安全扫描 · 审批 · 日志

拦截层



● 示例Hook点位，支持数十种类型Hook操作

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 8月 📍 深圳 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海 🧑 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

AiCon

全球人工智能开发与应用大会

深圳站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 8 月 21-22 日 / 深圳湾万丽酒店



参会咨询

专题: Harness Engineering: 模型之外的智能体工程

专题出品人: 柴思远

智谱 / 副总裁



专题: 超级个体与蜂群智能的共生进化

专题出品人: 张昊阳

EvoMap / 创始人



专题: AI Agent 高价值商业场景实战

专题出品人: 李响 博士

平安科技 / 智能两核 AI 部总经理



专题: 超级 App 的 AI 原生化: 端智能、端云协同与用户体验重构

专题出品人: 黎三平

京东 / 端技术负责人



专题: AI 原生新范式: Coding Agent 重构软件研发全流程

专题出品人: 林香鑫

网易游戏 / 高级技术经理



专题: 智能体时代的数据供给与治理

专题出品人: 陈廷梁 (王赟)

数新智能 / 创始人兼 CEO



04 典型集成场景



集成场景

第一幕 · 救火

跨境支付应急 · 22 分钟闭环

凌晨 02:17 · 跨境清算链路告警 · 自动值守 Agent 接管

「凶手不是 DB， 是清算域少了一行配置。」

— 误判 DB 锁 → 跨域复核 → 根因平反 → 写回应急平台

▶ 时间轴 · 22 分钟 4 个关键节点

告警涌入

T+00

拉取证据

30 trace · 18 机器

T+08

跨域复核

三 Subagent 串行

T+15

闭环写回

根因 + 补配动作

T+22

22

min

闭环耗时
vs 人工 ~2h

0

笔

资损
无误付 · 无延迟

30

trace

证据规模
× 18 机器 · MCP 聚合

▶ 集成姿势 · 这一幕用到了什么

MCP 应急平台

告警 · 闭环

MCP 日志检索

trace · grep

MCP 业务 DB

只读 SQL

MCP RAG 知识库

历史故障

Main Agent

headless · 常驻待命

跨域 Subagent 分派

Subagent

收单域

Subagent

清算域

Subagent

入账域

◆ 根因 清算域缺失一项跨境能力配置 · 非 DB 故障

✓ 写回应急平台 close_emergency · 附根因 + 补配

集成姿势 — MCP 接企业系统 · 跨域 Subagent 分派 · headless 容器常驻待命



集成场景

第二幕 · 值守

顶会理论实验 · 10 小时无人值守

周五下班离开工位 · durable Cron 接管 · 次日早晨实验全 PASS

「会话退出了， 实验还在跑。」

— 写 POC → 提交训练云 → Cron 轮询 + 失败重试 → 3/3 PASS

▶ 时间轴 · 10h10m 跨夜值守 4 个关键节点



10h 10m

无人值守
0 人盯 · 跨夜

3 / 3

理论 PASS
首轮即达成

1

次自愈
OOM 重启
降 batch · 续跑

▶ 集成姿势 · 这一幕用到了什么

durable Cron 定时唤醒 Agent

会话退出也能跑 · 断点续推 · 跨夜不掉

MCP 训练云

提交 · 轮询

state 进度文件

qoder_progress.json

state 失败 ledger

OOM · 重启日志

MCP RAG 知识库

理论 / 配方

Main Agent

headless · 持久状态机

◆ 自愈 OOM → 降 batch → 重启续跑

✓ 3/3 理论 PASS $lr=6e-7$ · 进度文件归档

集成姿势 — durable Cron 唤醒 · 进度文件持久化 · 训练云 MCP 调度

集成场景

第三幕 · 远征

端到端仿真评测 · 多 GPU 远征

SDK 嵌入业务调度器 · 多 GPU 切片 · 仿真场景 rollout 自动评测

「不是工具， 是同事。」

— SDK 嵌业务 → Cron 切片 → 多 GPU 远征 → 视频回传归档

▶ 时间轴 · 一次评测远征 4 个关键节点

SDK 接入

嵌业务调度器

Day 0

场景注册

10+场景 · 切片

Day 1

GPU 远征

多GPU 并发 rollout

Day 2

视频归档

回传 + 自动评分

Day 3

N

GPU

并发远征
切片 · 隔离

12

场景
一次评测
rollout · 全程录像

1

条 SDK
嵌入调度器
Qoder 成为同事

▶ 集成姿势 · 这一幕用到了什么

SDK 业务调度器 · Agent 嵌入为同事

Recurring Cron 触发 · 按 GPU/进程切片场景

SDK 嵌入业务进程

Qoder Agent

被业务进程调用

Cron 切片 · 多 GPU 远征

GPU-0..2

Shard A
城市道路

GPU-3..5

Shard B
高速路况

GPU-6..7

Shard C
极端场景

◆ 产出 rollout 视频回传 · 自动评分 · 归档

✓ 调度器收单 eval_report · 继续下一轮远征

集成姿势 — SDK 嵌入业务调度器 · Recurring Cron 切片 · 多 GPU 并发远征

核心架构



业界领先
多智能体架构

- 多模型架构：通过主子 Agent
- TUI / Headless 双命令行交互方式
- 多模型动态路由 · 200K 上下文窗口
- 多智能体架构：子智能体调度编排
- 灵活扩展：MCP（工具扩展）+ Skills
- 三方集成：SDK、ACP、Headless 三种集成方式
- 企业级安全、管控，细粒度权限控制 · 沙箱隔离

方法论体系

红线 通过 AGENTS.md 约束执行边界

Skills 注入私域知识 · 消除幻觉

Hooks Agent循环确定性检查点

SPEC 驱动需求→设计→代码→测试

异步委派 任务委派远端，充分释放AI潜力



代码生成 冲突检测 代码审查 远端沙箱 人类审核


工具是手段 · 方法论是灵魂

产品家族

CLI Qoder CLI
底座 / 发动机 · Qoder Agent 核心引擎

Qoder IDE
面向专业开发领域 · AI 原生 IDE 产品

QoderWork
面向泛工作场景 · 非开发者 AI 工作助手




IDE / QoderWork 是 CLI 不同场景下的 GUI 形态

被集成形态

SDK TS / Python 语言，数行代码轻松集成

Headless 执行过程无界面，适配 CI/CD 流水线

ACP 标准 ACP 协议实现，对接各类客户端



自定义 Subagent 扩展业务
标准 MCP 协议接入外部服务
任意工具细粒度权限控制
轻松定义 Agent 执行行为
支持打包成任意产品形态

专业 AI Coding Agent 实现，轻松集成先进能力


多模型路由

LLM 复杂推理

SLM 简单抽取

VLM 图片理解

- 一站式整合海内外 SOTA 大语言模型
- 支持个人 / 企业级 BYOK，按需接入
- 按任务类型 / 复杂度 / 成本自动路由
- 模型不可用时支持自动降级
- 统一信用计费，不绑定单一模型
- 不绑定单一供应商，支持多云部署



Task Input

Smart Router

LLM SLM VLM

AI 友好基础设施

从人类工具思维到 AI-Native 思维

- 一条命令快速安装，无任何开发平台依赖
- 适配主流操作系统、Docker、Kubernetes
- 云上 Agent 7x24 独立工作，异步执行
- 本地、云端随意切换，满足不同场景任务诉求
- 分布式架构执行，并行提升 Team 任务效率
- 自由、灵活高度扩展，轻松接入传统基础设施



注：支持 macOS、Linux、Windows 及容器、K8s 环境

应用场景

代码智能审查
CI/CD · PR 评论

Spec 驱动开发
Quest Mode 全流程

故障自动诊断
运维流水线

远端异步协作
Git → 审查 → MR

DevOps 自动化
部署 · 监控 · 日志

Vibe Coding 平台
钉钉开放平台

IM 智能机器人
对客答疑 · 助手


冲突检测修复
沙箱隔离 · 闭环

竞品优势

vs Claude Code
多模型 · 不绑定单一供应商 · 企业安全

vs Cursor / Copilot
不绑 IDE · 可被集成 · Headless CI/CD

vs 开源方案
企业支持 · 统一计费 · 完整方法论



打造企业级 Agent 实现的核心引擎

THANKS

Q&A

AiCon
全球人工智能开发与应用大会