

如果一个 Token 值 0.001 元
万亿参数模型每刻至少烧掉一辆特斯拉

效率，是智能体时代的第一问题

从 Token 数量到 Token 密度

千亿参数规模下的高效智能体智能

周俊

蚂蚁集团副总裁

AiCon

全球人工智能开发与应用大会

目录



架构设计



预训练&智能体数据



评测结果——能力释放·效率突破·现有差距



定位与展望

今天的 LLM 开发者面临一个不可能三角



快 —— 推理成本低，但参数有限做不了复杂任务

强 —— 能力顶配，但 GQA 注意力成本指数级增长

智 —— 智能体能力 $\neq$ 聊天能力 + 工具调用

三者不是独立问题——共享同一个根源：架构·训练·智能体的割裂设计

修任意一个，另外两个会反过来限制你

GQA 注意力的隐性成本



注意力复杂度= $O(n^2)$ → 上下文翻倍，成本翻四倍

32K 上下文: > 60% FLOPs 花在注意力上

256K 上下文: > 85% FLOPs 花在注意力上


万亿参数规模下，这是结构性问题——不是加算力能解决的



85% 的算力 不在思考

GQA 注意力在 256K 上下文下的 FLOPs 占比

注意力 FLOPs 占比: GQA vs 混合线性



聊天 ≠ 智能体



一次工具调用错误的后果 = 10 次聊天幻觉

聊天幻觉：可追问纠正，过程可逆

工具调用错误：API 已发出，后果不可逆

指令微调是"水中加盐"，不是"大海"

对聊天模型说"请做智能体" = 对短跑运动员说"请跑马拉松"



仅在模拟器里训智能体 = 在游泳池里练高山滑雪

197 个 MCP 服务器 · 2,400+ 真实工具 · 真实执行→验证→过滤

■ 三重矛盾的共享根源



注意力瓶颈 → 压制能力释放



Token 低效 → 智能体失败



聊天训练 → 无法获得智能体能力

解法：协同设计——从架构到训练到智能体，系统性重新设计

01

架构设计

■ 7 份线性注意力 + 1份 MLA



7层 Lightning $\rightarrow O(n^2)$ 降为 $O(n)$, 处理全局上下文

1层 MLA $\rightarrow$ 低秩KV压缩, 捕捉关键信息

效果: 256K 上下文

不可用 $\rightarrow$ 标准配置

成本从指数级降至线性级



不可用→标准配置

7:1 混合线性注意力让 256K 上下文成为标配

缩放定律：M=8 是最优甜点



M=2

1:1比例，效果等同纯MLA小模型

M=4

等价参数减半的纯模型

M=8 ★

最优甜点——不失精度，最大降成本

M=16

出现明显退化

两个规模，同一架构



Ling-2.6-flash

32 层 · 4096维 · 104B参数 · 1稠密+31MoE

Ling-2.6-1T

80 层 · 8192维 · 万亿级激活 · 4稠密+76MoE

共享：256 专家 · 每 8+1 激活 · 256K 上下文

MoE without the pain

① 无辅助损失路由

专家偏置 + FP32路由
+ sigmoid 评分

路由输出 2.5 倍缩放
→ 更纯净梯度, 更稳定训练

② 前端稠密层

Flash: 1 稠密 + 31 MoE

1T: 4 稠密 + 76 MoE

底层稳定语义, 上层稀疏提供容量

■ 四步迁移法：从 Ling-2.0 原地升级



Step 1 注意力转换

扩展投影矩阵 + 随机初始化门控
+ 保留 QK Norm

Step 2 线性预热

冻结未修改参数，小学习率恢复损失


Step 3 MLA 转换 最危险

移除 QK Norm，引入MLA

Step 4 MLA 预热

再次固定参数，恢复训练超越基线

步骤3：最危险的时刻





阵痛是暂时的 架构红利是永久的

PPL: 6.65 → 11.13 → 5.98 | 迁移后超越 GQA 基线

02

预训练&智能体数据

■ 9.6T Token 训练策略



关键决策：激进策略优于保守策略

从第0个 Token 就引入高质量数据

高质量梯度比短期稳定更重要

三阶段：

迁移 400B → 继续训练 8T → 长上下文扩展 1.2T

真实环境，不是模拟器



197

MCP服务器

2,400+

真实工具覆盖12领域

2,500+

真实编码样本 · 1550 仓库 · 30+ 语言

每一条数据：真实执行 → 验证 → 过滤

KPop: 万亿参数模型的稳定RL训练



IcePop 的问题: 统一 KL 约束

工具调用 Token 约束不足 → 危险行为

自然语言 Token 约束过度 → 抑制表达

Kpop 解法: Binary KL 自适应约束

接近参考分布 → 松弛 | 偏离 → 收紧

奖励 0.54→0.68 SWE-bench 70.8%→76.3%

Token 效率 $\neq$ 能力压缩



四个使能器 $\rightarrow$ 约4x效率提升，能力不降反升

Evo-CoT 演化式思维链剪枝，找最短正确路径

LPO 语言级策略优化，避免词级硬切换

Bi-Pref 双向偏好对齐，同时学习好与坏

Distill 最短正确蒸馏，少 Token 表达同能力



Token 效率 $\neq$ 能力压缩

4x效率提升 + 能力不降反升 | 少而精的 Token 本身就是一种能力

■ 基座模型全面提升



LongBench v2

30.02 → 43.54 (+45%)

SimpleQA

10.01 → 38.26 (+280%)

MMLU / GPQA

全线提升

LiveCodeBench

全线提升

03

评测结果

——能力释放·效率突破·现有差距

LongBench v2 — 所有基准中最大提升



+45%

30.02 → 43.54

架构优化不仅是"更快"
更是解锁被压制的能力

当注意力不再是瓶颈
模型处理长文档的自然能力被释放

Ling-2.6-flash — 104B 打出万亿体量



104B 参数 vs 竞品 300B+

BFCL-v4 66.81 (竞品 35.12 的近2倍)

PinchBench 81.30

tau2-bench 76.36

SWE-bench 61.20

小模型的天花板不是参数量，而是架构和训练策略



104B > 300B+

Ling-2.6-flash BFCL-v4 66.81 vs 竞品 35.12 | 训练方式 > 参数数量

Ling-2.6-1T — 即时模型



ClawEval 51.00

即时模式第一 · 无推理预算

BFCL-v4 70.64

即时模式第一 · 无推理预算

tau2-bench 78.36

即时模式第一 · 无推理预算

AIME26 87.40

超同梯队13+分

Ring-2.6 — 思考模型



✦ 领先的领域


PinchBench 87.60 全局第一

ClawEval 63.82 开源第一

ARC-AGI-2 66.18 开源第一

AIME26 95.78 全线提升

现有差距




差距来源是RL计算量，非架构缺陷——增加RL计算量是可预期的改进路径

从 Token 数量到 Token 密度

AA指数 34 ≈ GPT-5.4 (即时模式)

约 16M 输出 Token, Ling-2.0-1T 的4倍

更少 Token = 更低成本 + 更快响应 + 更多并发



从 Token 数量到 Token 密度



2.4x

Flash吞吐 vs Qwen3.5

10x

五轮对话成本差异

智能体是多轮的

Token 效率优势会累积

效率不是优化指标

是商业模型能否跑通的前提



效率就是能力

五轮对话成本差 10x — 服务效率是智能体落地的生死线

04

定位与展望

2026年三股浪潮



从 Scaling 到 Architecture

DeepSeek-V3.2 MoE · MiniMax-M1 Lightning · Ling 7:1 混合线性
行业用架构创新继续 Scaling 的红利

从 Chat 到 Agent

六成企业 AI 以智能体部署 · KPop + RLEF = 原生 Agent 训练

从 Token 数量到 Token 密度

AA 指数成为核心 KPI · Evo-CoT+LPO 等让模型内化推理

三个核心结论



效率与规模可以共存

混合线性注意力让 256K 上下文在万亿参数下可行

智能体能力必须原生训练

你不能在模拟器里训智能体

就像你不能在游泳池里练山地自行车

开源是方法论，不是选项

给社区一个可竞争、可改进的开放基线



2023

能不能做出来？

2024

能不能做得快？

2025

能不能用起来？

2026

每个 Token 值多少钱？

从 Token 数量到 Token 密度



效率与能力不再是对立面

协同设计是出路

Ling & Ring 2.6 是范式转移的先行实践

它不是终点，而是新范式的起点

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 8月 📍 深圳 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海 🧑 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

AiCon

全球人工智能开发与应用大会

深圳站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 8 月 21-22 日 / 深圳湾万丽酒店



参会咨询

专题: Harness Engineering: 模型之外的智能体工程

专题出品人: 柴思远

智谱 / 副总裁



专题: 超级个体与蜂群智能的共生进化

专题出品人: 张昊阳

EvoMap / 创始人



专题: AI Agent 高价值商业场景实战

专题出品人: 李响 博士

平安科技 / 智能两核 AI 部总经理



专题: 超级 App 的 AI 原生化: 端智能、端云协同与用户体验重构

专题出品人: 黎三平

京东 / 端技术负责人



专题: AI 原生新范式: Coding Agent 重构软件研发全流程

专题出品人: 林香鑫

网易游戏 / 高级技术经理



专题: 智能体时代的数据供给与治理

专题出品人: 陈廷梁 (王赟)

数新智能 / 创始人兼 CEO



THANKS

探索 AI 应用边界

huggingface.co/inclusionAI/Ling-2.6-flash

huggingface.co/inclusionAI/Ling-2.6-1T

huggingface.co/inclusionAI/Ring-2.6-1T

github.com/inclusionAI/Ling-V2.5

arXiv: <https://arxiv.org/abs/2606.15079>

Ling & Ring 2.6

AiCon

全球人工智能开发与应用大会