

从唤醒到陪伴

——多模态 Agent 如何重构手机交互范式

刘鹏

OPPO AI中心 高级算法工程师

AiCon

全球人工智能开发与应用大会

目录



手机 AI 助手的范式演进



持续感知型 Agent—小布伴随



执行型移动 Agent—X—OmniClaw



落地经验与未来展望

01 手机 AI 助手的范式演进

从“听懂一句话、看懂一张图”，到“理解一段旅程、完成一个目标”

用户对手机助手的期待，正在变得更多元

今天天气怎么样？

总结一下我刚刚
刷到的几个攻略




这道题怎么做？

打开这个 App 的订
票页面

今天的手机助手，不只要答得上，还要看得懂、记得住、做得到

手机AI助手的演进




应用形态变化的背后，是模型、记忆与 Agent 能力的共同演进

持续感知型 Agent—小布伴随

从单帧理解到提问瞬间重建，从屏幕流到语义时间轴

什么是小布伴随？




小布伴随不是一次性识屏问答，而是持续在线的手机使用陪伴

■ 伴随 Agent 的设计原则：快而可控



Accompany Agent System Architecture · 小布伴随系统架构

Intervention Gate · 规则干预 / 安全兜底



四个核心设计

输入层-提问瞬间重建

用户开口那一刻，如何回溯重建完整上下文

记忆层-屏幕语义时间轴

流式 Caption、噪音过滤、可检索的时序记忆

感知 · 记忆 · 编排 · 生成
四层协同，驱动伴随智能

编排层-候选式链路编排

多候选路由、重分流、安全兜底

生成层-场景应答策略

如何根据场景，把上下文、记忆、工具结果融合成高质量的伴随式回答

提问瞬间重建

屏幕帧流



ASR 时间窗口




瞬间重建模块



输出



屏幕语义时间轴



更适合伴随助手的流式记忆 (1/2)

实验一：Video Caption 去噪实验

Caption 生成时显式区分：

- ◆ 重点信息：页面主体、用户关注对象、任务状态
- ◆ 非重点信息：导航栏、底部按钮、重复控件、无关 UI

根据场景来选择是否使用非重点信息，在全场景上有1.7个点的提升。

【主要信息】画面显示江西旅游攻略内容，其中包括“江西旅游住宿指南”、“江西旅游美食推荐”、“江西精华景点介绍”三个板块，分别列出南昌、庐山、景德镇、三清山、婺源、井冈山等地的住宿选择、特色炒菜与小吃、推荐菜馆及景点介绍，如“南昌：景点市区扎堆！住八一广场、滕王阁或万寿宫附近最方便”、“特色炒菜：蟹粉豆腐、藜蒿炒腊肉、黄豆炒鸡丝”、“景点：滕王阁、八一起义纪念馆、庐山、景德镇、三清山、婺源、井冈山”等具体信息。

【次要信息】该内容由“旅行算法师”发布，页面背景显示“江西5天4夜爆肝攻略 景美·吃爽·不踩坑！”标题，以及“448”点赞、“21”收藏、“16”评论等互动数据。

画面展示由“旅行算法师”发布的“江西5天4夜爆肝攻略 景美·吃爽·不踩坑！”旅游攻略内容，包括“江西旅游住宿指南”、“江西旅游美食推荐”、“江西精华景点介绍”三个板块，分别列出南昌、庐山、景德镇、三清山、婺源、井冈山等地的住宿选择、特色炒菜与小吃、推荐菜馆及景点介绍，例如“南昌：景点市区扎堆！住八一广场、滕王阁或万寿宫附近最方便”、“特色炒菜：蟹粉豆腐、藜蒿炒腊肉、黄豆炒鸡丝”，以及“景点：滕王阁、八一起义纪念馆、庐山、景德镇、三清山、婺源、井冈山”等具体信息，页面还显示 448 点赞、21 收藏、16 评论等互动数据。


实验二：持续Memory总结

时序问答数据集构造：

- ◆ 实时问答：依赖短时视频信息面
- ◆ 记忆问答：依赖历史局部记忆
- ◆ 回溯问答：需要对过去的总结回溯信息
- ◆ 图文无关问答：问题与画面弱相关
- ◆ 完全无关问答：不依赖屏幕内容

问题类型	Baseline	+ Mem总结	变化量
回溯问答	0.7087	0.8867	+0.1780
记忆问答	0.7241	0.8276	+0.1035
图文无关问答	0.8611	0.8958	+0.0347
实时问答	0.9167	0.9372	+0.0205
完全无关问答	0.9182	0.8302	-0.0880

更适合伴随助手的流式记忆 (2/2)



无需训练，低成本，可插拔的层级记忆检索框架 OASIS：


将不断增长的视频历史 fold 成层级化事件记忆，而不是把所有帧或片段平铺保存。它先把短时间内的连续观察聚合为局部事件，再将相关事件进一步压缩成更高层的语义摘要，形成从细粒度片段到粗粒度事件的层级结构。

在推理时，模型先根据问题判断需要哪类证据，再沿着这棵层级记忆从粗到细定位相关时间区域。这样既保留了长视频中的关键信息，又避免了把大量无关历史都塞进上下文。OASIS 因此把“记住更多”转化为“按需展开正确的记忆”。


Model	frames	Perception							Backward			
		OCR	ACR	ATR	STU	FPD	OJR	Avg	EPM	ASI	HLD	Avg
Qwen2.5-VL-7B [‡]	0.5fps	76.51	57.80	68.10	46.63	66.34	56.52	60.93	49.83	58.11	44.62	50.24
+ OASIS	-	85.23	72.48	66.38	52.25	67.33	64.67	67.26	51.85	58.78	48.92	52.61
Qwen3-VL-8B [‡]	0.5fps	83.89	58.72	70.69	56.18	69.31	64.13	66.79	51.18	60.81	43.55	51.19
+ OASIS	-	91.95	80.73	81.03	67.42	67.33	79.89	78.14	61.95	60.14	47.31	57.21

Liang et al., “OASIS: On-Demand Hierarchical Event Memory for Streaming Video Reasoning,”
CVPR 2026.

候选链路式编排



规则驱动 vs 模型驱动：从分类问题到受约束决策问题



约束编排器：规则驱动 vs 模型驱动？

混合决策 = 语义估计 + 约束投影 + 候选搜索

模型给“语义假设”，规则做不了

- 用户想做什么？
- 当前场景是什么？
- 是否依赖屏幕 / 历史上下文？

规则做“可行性裁剪”，模型有风险

- 屏幕是否可用？
- 安全 / 隐私是否通过？
- 能力开关是否允许？
- 参数是否可执行？

编排做“候选链路排序”

- 统一的标准编排优先级
- 场景条件给到下游
- 下游链路的退出/失败的链路顺延

■ 场景应答策略

不同链路和场景条件下，模型需要的信息和约束不同。

核心影响要素是：

- ◆ Prompt要素设计
- ◆ 选帧策略
- ◆ 历史记忆策略

对应几个核心设计理念：

- ◆ 时序信息有选择的保留
- ◆ 多源上下文按需注入
- ◆ 退出、兜底机制
- ◆ 特殊场景特殊设计


System Prompt设计要素

- 1. 身份认知层
 - | 1. 核心身份设定：角色定义，性格基调，品牌归属
 - | 2. 场景变体身份：标准助手模式，特殊场景模式
- 2. 场景指引层
 - | 1. 实体具体化要求：按场景标签动态注入细化规则
 - | 2. 上游信息采纳规则：结合来源回答，冲突时忽略
- 3. 画面理解层
 - | 1. 用户问题
 - | 2. 多帧画面理解：时间顺序排列，串联完整使用场景
- 4. 历史记忆层
 - | 1. 多源上下文注入：RAG，历史视频记忆，记忆仓，用户画像，工具结果
 - | 2. 采纳原则：注意代词指代，与画面冲突时无视
- 5. 行为约束层
 - | 1. 表达风格：语气基调约束，禁用表达范围限定
 - | 2. 模态来源隐藏：屏蔽内部信息结构，统一对外表述口径
 - | 3. 隐私安全：敏感信息统一拒绝
- 6. 判断规范层
 - | 1. 禁止模糊/消极/自我质疑表述
 - | 2. 动态限制追加：根据上下文类型按需注入额外约束
- 7. 输出控制层
 - | 1. 字数五档自适应：确认 10-20字 → 攻略 150-300字
 - | 2. 内容策略：拓展场景 vs 精简场景
 - | 3. 质量标准：信息密度高，数据具体，贴合画面


场景应答策略-教育场景为例

教育场景是线上用户意图最多的场景，这个场景也有其特殊性。

- ◆ 模型输入prompt长度（条件限制）和输出长度限制，对结果影响非常大
- ◆ 越接近query时间的帧越重要，个别问题不需要视频帧
- ◆ 长时记忆通常是副作用




模型prompt长度 — 满意度



模型输出长度 — 满意度

场景拓展-旅游出行场景



伴随范式 + 垂域子链路：增强垂域问答执行能力

场景拓展-直播辅助场景




Figure 1: Framework of Click-to-Ask. The upper half illustrates the offline copywriting module, including product information integration, copywriting generation, prohibited-term purification, and the structured product database. The lower half shows the online interactive Q&A module on the left, responsible for real-time bullet-chat responses, and the event-based history memory module on the right, which asynchronously segments the video stream and accelerates historical caption generation.




伴随范式 + 任务前处理：助力直播带货文案生成+在线问答

Yu et al., "Click-to-Ask: An AI Live Streaming Assistant with Offline Copywriting and Online Interactive QA,"
WWW 2026 Demos.

03 执行型移动 Agent—X-OmniClaw

从理解用户目标到规划、操作、验证真实手机任务

X-OmniClaw整体架构



三大要点

Omni Perception

屏幕 + 相机 + 语音统一进入

Omni Memory

工作记忆 + 本地长期记忆

Omni Action

观察 → 推理 → 执行 → 验证

真实 Android 设备运行

X-OmniClaw 是一个集多模态感知、记忆与执行于一体的 多模态安卓端Agent。


X- 强调跨模态融合，将多源感知信号组织为统一的任务输入，并进一步驱动真实移动端环境中的跨应用执行；

Omni 表示系统整合三类感知来源：屏幕内的 UI 状态、屏幕外的真实世界视觉上下文，以及语音输入。

Omni Perception: 全感官统一感知




Omni Perception



Omni Memory: 全时空个性化记忆




Omni Memory




Omni Action: 全场景智能执行




Omni Action



DEMO展示



相机识物
↓
电商询价




屏幕伴侣更随
↓
多步读屏
自动作答

DEMO展示



主题找图
↓
一键成片



轨迹克隆
↓
一句话直达
目标页面

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 8月 📍 深圳 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海 🧑 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

AiCon

全球人工智能开发与应用大会

深圳站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 8 月 21-22 日 / 深圳湾万丽酒店



参会咨询

专题: Harness Engineering: 模型之外的智能体工程

专题出品人: 柴思远

智谱 / 副总裁



专题: 超级个体与蜂群智能的共生进化

专题出品人: 张昊阳

EvoMap / 创始人



专题: AI Agent 高价值商业场景实战

专题出品人: 李响 博士

平安科技 / 智能两核 AI 部总经理



专题: 超级 App 的 AI 原生化: 端智能、端云协同与用户体验重构

专题出品人: 黎三平

京东 / 端技术负责人



专题: AI 原生新范式: Coding Agent 重构软件研发全流程

专题出品人: 林香鑫

网易游戏 / 高级技术经理



专题: 智能体时代的数据供给与治理

专题出品人: 陈廷梁 (王赓)

数新智能 / 创始人兼 CEO




落地经验与未来展望

从工程踩坑到用户心智模型与系统级 Agent OS Runtime

从 Assistant 到 AgentOS

Evolution of Mobile AI Assistants




AI 从助手入口，走向系统级任务调度层

AgentOS 正在成为手机系统的新方向

Google — Android Intelligence System

Microsoft — Project Solara

Apple — Apple Intelligence & Private Cloud Compute



底座层-端侧智能

端侧模型成为系统基础能力，意图理解、摘要改写、隐私上下文处理本地完成。低延迟、弱网可用、数据不离设备。

能力层-执行能力

用户表达目标，系统负责拆解、调用、执行与验证。能力调度单元从 App 升级为 Function，敏感操作通过权限与审计保障安全。

行业层-生态重构

App 角色分裂：沉浸体验保留，核心功能注册为 Agent 可调用接口。能力的可发现性与可调用性，与 UI 同等重要

THANKS

探索 AI 应用边界

Explore the limits of AI applications

AiCon

全球人工智能开发与应用大会