

阿里云PAI打造云上大模型训练新基建

云上稳定·高效·高性价比AI平台

贾珂 | 阿里云PAI训练产品负责人



AI的发展趋势

从感知AI, GenAI升级到Agentic AI, 最终通往AGI的路径




PAI 发展里程碑

阿里云AI产品里程碑



全球AI市场里程碑

AGI:大模型参数激增驱动高性能算力发展



Major Large Language Models (LLMs)

ranked by capabilities, sized by billion parameters used for training

CLICK LEGEND ITEMS TO FILTER

anthropic chinese google meta mistral openAI other xAI

Parameters (Bn) open access

search... show only: all

100 MMLU

89.8 = human expert

70+ IDEAL

David McCandless, Tom Evans, Paul Barton
Informationisbeautiful // Sep 2025

MMLU = benchmark for measuring LLM capabilities
* = parameters undisclosed // source: LifeArchitect // data

LLM云上 AI PaaS平台的“iPhone时刻”到来

核心解决2个效率的问题

资源成本：分布式AI怎么跑

人力成本：AI怎么写




200,000 USD

X 64

X 7 CNY/USD

89,600,000 CNY





SQL

```
SELECT COUNT(amount) AS sales
FROM order_table
GROUP BY vendors
ORDER BY sales DESC
LIMIT 100;
```



在线服务


app.py:

```
server = tornado.HTTPServer(...)
server.listen(port)
IOLoop.instance().start()
```



AI

无比复杂，也看不懂代码)





阿里云人工智能平台 PAI · 产品架构

PAI = 1算力平台 + 2个核心引擎 + n个 LLM 工具与应用



大模型的挑战



大规模分布式深度学习系统难度大

- AI芯片型号那么多，换代快，怎么架集群？异构混布集群难管理
- 超高性能网络建设难？以太网更难，拥塞如何控制？延时如何极致？ RDMA如何稳定？
- GPU硬件，网络复杂度高，稳定性不够，如何管理？
- 如何把训练分布式化，高效化？特别是没有静态图的 Pytorch
- 分布式训练本质上缺乏容错能力，难度随着规模指数增加
- 公共云进一步复杂，安全隔离Vs执行效率，云其他服务连通

调度	框架
存储	容器
异构	网络

AI平台的机遇

计算任务的
稳定

硬件故障、网络抖动导致无法**长周期**运行计算任务；传统容错方式，时间和算力**资源浪费**严重

并行计算的
性能

GPU服务器之间，GPU集群的网络性能导致**模型计算效率**（MFU）远低于理论计算效率

研发和应用
效率



人力成本高，技术门槛高，需要提升模型**开发和应用效率**，降低模型的**使用门槛**

大模型的算力基础设施**不是简单的硬件堆砌**

模型训练需要**高效的**算力，模型流程需要**在线**快速反馈迭代，所以**云上的AI训练平台是大模型的最优产品方案**

PAI · 高稳定

昂贵的故障



source: Rise of Distributed Deep Learning Training in the Big Model Era: From a Software Engineering Perspective

Component	Category	Interruption Count	% of Interruptions
Faulty GPU	GPU	148	30.1%
GPU HBM3 Memory	GPU	72	17.2%
Software Bug	Dependency	54	12.9%
Network Switch/Cable	Network	35	8.4%
Host Maintenance	Unplanned Maintenance	32	7.6%
GPU SRAM Memory	GPU	19	4.5%
GPU System Processor	GPU	17	4.1%
NIC	Host	7	1.7%
NCCL Watchdog Timeouts	Unknown	7	1.7%
Silent Data Corruption	GPU	6	1.4%
GPU Thermal Interface + Sensor	GPU	6	1.4%
SSD	Host	3	0.7%
Power Supply	Host	3	0.7%
Server Chassis	Host	2	0.5%
IO Expansion Board	Host	2	0.5%
Dependency	Dependency	2	0.5%
CPU	Host	2	0.5%
System Memory	Host	2	0.5%

Table 5 Root-cause categorization of unexpected interruptions during a 54-day period of Llama 3 405B pre-training. About 78% of unexpected interruptions were attributed to confirmed or suspected hardware issues.

source: The Llama 3 Herd of Models

PAI 稳定性体系：事前 · 事中 · 事后

事前检测

SanityCheck

- 千卡网络分钟级检测
- 识别 10 大类数百种 GPU/网络错误
- 快速定位慢节点
- 性能基线预检

事中容错

AI Master + 节点自愈

- 任务级监控与自动容错
- Hang/OOM/硬件故障自动响应
- 节点无感分钟级自愈
- 异常信息自动化响应

事后恢复

EasyCKPT

- 秒级 Checkpoint 保存恢复
- 精度无损，参数/数据完整恢复
- 训练代码仅需 5 行改动
- 与调度结合自动销毁前保存


事前检测：为什么不能等故障发生再处理？

痛点：大模型训练 GPU ECC/NVLink 错误超出预期，GPU 掉卡无法预判，网络性能问题难以预先发现

设计理念 将故障发现从「被动响应」转变为「主动预防」——在训练开始前就排除问题节点


PAI–SanityCheck 千卡网络分钟级检测

- 提供算力分布、通信带宽、机间带宽性能、机间带宽分布、全网算力节点通信性能检测。
- 1分钟内完成千卡高性能网络的检测，快速检测慢节点。
- 识别定位可能导致任务训练性能下降的问题元素，整体提升问题诊断效率。



PAI–算力/训练任务监控与告警


- 提供Quota算力、训练任务、GPU维度等多层级200+监控指标，全面掌握资源运行情况。
- 支持自定义灵活配置告警规则，满足常态监控或高峰告警等个性化场景。
- 支持通过SDK/OpenAPI 订阅Quota算力、训练任务资源指标数据和告警监控。



事中容错：为什么用户不应该关心硬件故障？

痛点：大规模分布式任务少量节点报错很难定位；慢节点影响所有训练节点；传统容错需要用户深度参与

设计理念 容错是平台的责任，不是用户的负担——实现用户无感的分钟级自愈



PAI-AIMaster 弹性容错训练引擎

- 任务级监控探查
- 基于用户业务条件
- 自动容错和作业重启
- Hang/OOM/慢节点全覆盖

PAI-节点自愈 无感分钟级恢复

- AI 助手驱动
- 自动隔离/重启/诊断/维修
- 异常信息自动化响应
- 任务稳定性提升 2X+

组合效果 1+1+1 > 3

AIMaster + 节点自愈 + EasyCKPT
实现节点自愈闭环
保障任务持续运行
降低人工运维成本


事后恢复：为什么不用传统的周期性 Checkpoint?

痛点：大模型 Checkpoint 动辄几十 GB，周期性暂停训练导致 8%+ 时间浪费；恢复时精度难以保证

设计理念 Checkpoint 应该像数据库事务一样秒级完成、精度无损、对训练流程零干扰

PAI-EasyCKPT 训练分钟级保存

- 秒级 Checkpoint，保障训练任务快速恢复——从小时级降低到秒级，速率提升千倍
- 训练精度无损，支持对模型参数、数据读取进度、其他局部变量进行保存和恢复
- 和调度结合，通过 hook 支持任务销毁前自动 Checkpoint
- 上手容易，仅需 5 行左右的代码改动



PAI 高稳定 · 确保系统稳定的运行

训练前、中、后监控、检测、自愈、续跑，维护提升训练任务全生命周期稳定性



指标	传统方案 (Before)	PAI 方案 (After)
故障检测	故障后被动响应，人工排查数小时	事前 SanityCheck + 事中自动检测，分钟级定位
容错恢复	用户自行处理，任务中断需人工重启	AlMaster 自动容错，用户无感分钟级自愈
Checkpoint	周期性暂停，小时级保存，8%+ 时间浪费	EasyCKPT 秒级保存，精度无损 ≈0% 开销
运维成本	需要专职运维团队 7x24 值守	平台自动化响应，人工运维成本大幅降低

分布式训练任务 覆盖GPU占比 50% ；自动发现线上故障节点1000起+， 月检测 240+ ，节点自愈率 98%

累计检测故障节点数量

1025


周检测故障节点数量

87

月检测故障节点数量

246

累计检测故障节点原因分布




自愈检测覆盖率 ⓘ

100.00%


PAI · 高性能

PAI Serverless 多租：从机器复用到容器复用



PAI统一调度引擎，训推一体的高效的调度

数十万卡+算力集群，HPC、训练、推理统一管理和一体化调度， **90%+** 有效算力利用率




分布式训练服务 PAI-DLC

模型在线服务 PAI-EAS

AI 框架（ Custom/TorchAcc/BladeLLM, Cosmos-RL/verRL/Ray/ Megatron/ DeepSpeed/vLLM/Triton）


PAI AI Scheduler（云原生统一调度引擎）

异构算力混合调度




CPU、GPU | ECS、EGS、灵骏裸金属 | 多品牌，多规格，多卡型的混合使用

拓扑亲和性调度




网络拓扑和任务规模智能匹配，性能提升30%~40%

灵活排队调度策略



智能、FIFO、遍历、均衡等多种调度策略；日均提交数百万任务

企业级资源管理





算力资源共享，每月免费供 500万+卡时（相当于1000台 + 8卡GPU服务器）

自动拓扑感知调度：实现计算最佳路径

痛点：随机调度导致 通信跨越多层交换机，网络跳数增加，通信延迟大幅上升

设计理念 让通信模式匹配网络拓扑——将同一 Ring 的 Worker 调度到同一 ASW 下，最小化跨交换机通信




性能差距：512卡 30%~40%
4worker为例：w0->w1->w2->w3->w0（RingAllReduce通信）

QuotaTree：调度效率、资源利用率持续提升

基于QuotaTree，父子Quota、闲时资源，自动实现用户自身自由最优分配，提升利用率

x客户，单月提交闲时资源任务数万，总计30万卡时+，资源提升20%+



父子Quota，父Quota任务调度策略（优先和抢占）




使用闲时资源提交任务，实现资源共享使用；当借用资源要求归还，闲时资源任务会因为资源回收而导致任务停止。

资源、调度和工作空间3层体系：实现算力精细化管理


多引擎、多算力的抽象，简化购买、分配、使用流程，高效完成实现AI算力的可管可控



AI资源组：基于资源组，完成AI算力资源购买



资源配额 (Quota) :基于Quota, 实现算力分配和管理, 资源分配的可管可控



AI工作空间： 基于AI工作空间实现算力资源绑定、算力资源配置、角色管理完成使用的可管可控



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 8月 📍 深圳 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海 🧑 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

AiCon

全球人工智能开发与应用大会

深圳站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 8 月 21-22 日 / 深圳湾万丽酒店



参会咨询

专题：Harness Engineering：模型之外的智能体工程

专题出品人：柴思远

智谱 / 副总裁



专题：超级个体与蜂群智能的共生进化

专题出品人：张昊阳

EvoMap / 创始人



专题：AI Agent 高价值商业场景实战

专题出品人：李响 博士

平安科技 / 智能两核 AI 部总经理



专题：超级 App 的 AI 原生化：端智能、端云协同与用户体验重构

专题出品人：黎三平

京东 / 端技术负责人



专题：AI 原生新范式：Coding Agent 重构软件研发全流程

专题出品人：林香鑫

网易游戏 / 高级技术经理



专题：智能体时代的数据供给与治理

专题出品人：陈廷梁（王赟）

数新智能 / 创始人兼 CEO



PAI · 高效率


框架融合：任务和资源多维度支持训练场景

痛点： AI 框架层出不穷 vs. AI平台使用一致性的矛盾

Serverless Ray on DLC


零改造接入，开箱即用

- 任务级别，无需构建集群，支持Ray框架一键提交，上手0成本。
- 提供Ray Native 能力， 典型如Ray API、自定义角色、AutoScaling、ray dashboard 等能力
- 基于PAI AI调度引擎，通过网络拓扑感知、算力拓扑感知，提升算力利用率。
- 高达10K+节点的扩展规模，满足大模型超大任务的需求，支持独占资源（预付费）、公共资源（后付费）和竞价资源（Spot）使用。



RNQ: Ray Native Quota

高性能，高密度



面向生产级大规模训练任务优化:

- 秒级作业启动、镜像与数据加速（CPFS/OSS等）、常驻集群降低冷启动
- 单节点支持上百任务，资源粒度低至 0.125 卡；
- Head/组件/节点三级容灾，通过状态持久化 + 自动恢复 + 内核级 IO 稳定性优化

GPU计算利用率最大提升25%+, 算力减少1/3产能不变。

CPU&GPU融合：任务多集群协同调度，激活CPU集群


痛点：AI集群中CPU算力欠缺导致GPU算力闲置，最终造成GPU 无法实现大规模的计算问题

场景

模型训练接收的训练数据常常是图片或者视频帧数据，在训练过程中，数据会经过在DataLoader内的数据加载到数据处理过程，再给到训练，而对于图片、视频帧数据的处理常常涉及密集的CPU计算而非GPU计算，CPU和GPU计算不能很好的overlap，进一步导致训练整体效率不高。

特点

一个任务，通用计算和灵骏智算的协同调度，将部分worker offload到独立的PAI通用计算资源上，分离GPU上的CPU计算压力，跨资源类型，实现资源的灵活配比




GPU 计算利用率达到 90%+

多云融合： 计算&管控分离， 实现多集群到多云统一调度管理

痛点： Scaling Law AI 算力快速迭代（多种异构集群） vs. AI平台使用一致性的矛盾

设计理念 管控集群 + 计算集群，实现统一调度、统一管理，使用的统一体验



PAI多云管控的部署架构

- 一套管控：在阿里云中心region，PAI Serverless统一管控纳管一个客户的K8S集群
- 标准化接入：客户的集群通过Vnode方式与三方云k8s同步，阿里云与三方云之间通过专线连接。

PAI平台完成管控与节点的升级

- Super Console：在管控层，用PAI Serverless统一管控纳管PAI单租集群，实现一套管控管理各种集群，对客户提提供一致的用户体验。
- Super Node：在计算层，从RunD升级到“RunD+RunC”，满足客户对拉起速度的诉求，同时保持Serverless的优势。

总结：AI平台成为大模型新基建

更简单、更稳定、更高效

稳定

事前检测 + 事中容错 + 事后恢复

万卡集群月级不间断训练，用户无感自愈

高效

拓扑感知 + Serverless 多租 + Quota 体系

90%+ 有效算力利用率，闲时资源月省 500 万+卡时

易用

框架融合的平台 + 算力融合的平台 + 集群融合的平台

零改造接入，一键提交训练，企业级可观测

THANKS