

小布记忆

全模态碎片化内容的理解与智能整理实践

演讲人：王闯闯

OPPO / 高级算法工程师

AiCon

全球人工智能开发与应用大会

目录

01 问题与背景

02 记 · 全模态理解

03 管 · 记忆整理与自进化

04 用 · 记忆消费


05 工程实践与效果验证

01

问题与背景

碎片化记忆的多模态挑战

用户每天都在产生大量碎片化内容



三大核心难点：从输入到结构化的鸿沟

L0
原始记忆碎片
(异构输入)

理解

01 模态异构理解

单模态语义理解

- 截图：像素级视觉信息
- 语音：时序音频信号
- 文档：结构化文本

本质：表征空间差异大，缺乏统一的语义抽象

诉求 → 统一多模态语义理解

关联

02 跨模态关联

实体级关联

- 一次行程 = 订单截图 + 语音备忘 + 打卡照片
- 同一实体散落在多模态

本质：需在异构数据间建立语义级别的关联

诉求 → 实体级语义关联

治理

03 记忆膨胀与质量衰减

记忆治理

- 记忆只增不减，冗余 / 过期 / 重复
- 碎片化原始记忆缺乏场景化整合
- 低质记忆主导，下游「用」的效果差

本质：记忆库越「重」越「脏」，噪声压制有效记忆

诉求 → 主动记忆管理（去重/合并/遗忘）


跨越鸿沟

结构化记忆
(目标)

统一语义
跨模态关联
高质量可用

跨越三道难点 = 统一语义理解 + 跨模态实体关联 + 主动记忆管理 → 才能从 L0 碎片走向「结构化记忆」

整体架构：记 - 管 - 用 + 记忆分层 L0~L3




02

记 · 全模态理解

碎片(L0) → 结构化记忆单元(L1)

多入口接入，统一记忆出口


用户触达入口分散，后端需要统一抽象的「记忆单元」



多入口接入，统一记忆出口



「一键闪记」端云协同整体架构



端侧引擎核心：为什么是「自研 AndesVL」

① 模型选型逻辑





② 端侧核心定位 | 端侧只做核心抽取 · 云侧中控编排 · 轻量化手段落地 快 · 稳 · 省

分工边界 · 端云职责划分

聚焦	可维护	轻量化手段 · 省资源 / 提效率	
端侧只做核心抽取任务 不承担复杂业务编排	中控业务逻辑在云侧 策略可随业务调整	降本	增效
		Image 特征 Cache ViT 调用次数最小化	Part-Layer / Full-Layer 按任务动态调度

自研 AndesVL = 端侧核心抽取 + 云侧中控编排 + 轻量化手段 (特征 Cache / 动态层调度) → 推理 快 · 稳 · 省

端侧引擎：AndesVL 模型架构



端云任务分流：边界划分逻辑

分流核心逻辑：在 隐私 · 效果 · 成本 · 时延 之间动态平衡（无固定比例，依任务而定）

隐私 数据尽量不出端，云端不留存

时延 端侧实时响应，免网络往返

成本 端侧推理零云端开销

效果 对齐云侧基线；复杂场景上云保效果

端侧天然占优 隐私 / 成本 / 时延，且效果需达标；当 效果要求或任务复杂度 超过阈值 → 切换云侧

简单场景 → 端侧	判定信号	复杂场景 → 云侧
直屏 / 焦点屏（单屏）· 手机	屏幕 / 终端形态	分屏 / 多浮窗 · 平板
≤ 2	任务数	> 2
单标签单实例（单订单 / 火车票 / 日程）	标签结构	多标签 / 多实例（多日程 / 多火车票）
常规单据，规则明确	特定类型	复杂订单 / 复杂 NER / 复杂日程待办

↑ 判定信号即架构图中「分流依据 · 路由策略」的具体化：输入模态与规模、标签复杂度、精度 / 置信度、端侧能力覆盖


收益：降低云侧成本 · 提升隐私安全 · 保障端云一致体验

端侧化解决方案：部署 + 芯片协同 + 应用算法


01 部署架构 · 1 + N LoRA



02 芯片厂商协同 · 推理加速



03 应用算法 · 效果对齐



4B 替换 7B，效果不降 = 部署 (1+N LoRA) × 芯片 (稀疏化 · 解码加速 · PTQ) × 算法 (SFT + 蒸馏 + RL)

小布记忆 App 效果展示



全新系统级 AI 体验
AI 一键闪记 记事毫不费力

一键记录屏幕内容
记餐厅 | 记日程 | 记错题 | 记攻略

一站式记忆管理
摘要 | 记忆关联 | 智能合集

找记忆问小布
专属记忆 快速查找

	分类	总结	结构化信息提取	记账	取餐码	详情页摘要	日程待办	标签
竖屏	✓	✓	✓	✓	✓	✓	✓	✓
横屏	✓	✓	✓	✓	✓	✓	✓	✓
大折叠	✓	✓	✓	✓	✓	✓	✓	✓
平板	✓	✓	✓	✓	✓	✓	✓	✓
分屏+浮窗	-	-	-	-	-	✓	✓	✓
手写笔	✓	✓	✓	✓	✓	✓	✓	✓
文档记	-	-	-	-	-	✓	-	✓
语音记	-	-	-	✓	-	-	✓	-
AI导入	-	-	-	-	-	✓	-	✓
多图记	-	-	-	-	-	✓	✓	✓
长截图	-	-	-	-	-	✓	✓	✓

03

管 · 记忆整理与自进化

RL 记忆管理 + agentic RAG (L1 → L2)

RL 记忆管理智能体：记忆的遗忘 · 更新 · 去重 · 增删改查


① 范式演进（能力逐级提升）




② RL 记忆管理智能体 · workflow (GRPO 闭环)



自进化: policy ↔ tools 协同演化



关联与归纳统一：agentic RAG / plan-execute 智能体



Rerank / Verify 非必走链路：有效检索（高置信/精准）直接产出；仅候选多 / 低置信 / 跨源融合时才精排，且 Verify 只校验缓冲区 / 低置信项

合集应用 Agent：按内容风格与用户指令调用工具



合集应用 Agent = 内容风格识别 + 用户指令理解 + 上下文管理 + 工具编排 → 多类型合集应用

效果指标：三类 Agent 的量化结果

01 记忆管理进化指标

去重 · 合并 · 遗忘判定 全链路准召持续提升

记忆去重 / 更新准召率

↑ 提升

记忆冗余率

↓ 下降

遗忘判定准确率

↑ 提升

指标体系建立中 · 持续迭代优化

02 合集归纳 Agent 指标

改造前（规则 / 工作流） → Agent 化后

合集创建准确率

▲ +14pp

改造前 83%

Agent化后 97%

新记忆加入准确率

▲ +19pp

改造前 76%

Agent化后 95%+

规则工作流 → Agentic：准确率显著跃升，已可量化复现

03 合集总结应用 Agent 指标

摘要质量 · 配图 · 用户侧采纳全面评估

摘要事实一致性

↑ 提升

配图相关性

↑ 提升

用户采纳率

↑ 提升

指标体系建立中 · 持续迭代优化

记 - 管 - 用 各环节均建立量化指标：管（记忆进化）· 归纳（合集 Agent）· 应用（总结 Agent）

04

用 · 记忆消费

长期用户画像 L3 与记忆消费闭环

用：长期用户画像 L3 与记忆消费



L1/L2 → L3: 记忆从「整理好」走向「用得上」, 并经使用反馈回流「管」形成自进化闭环

主动服务示例：记忆驱动的主动价值

L3 长期用户画像

稳定偏好 · 习惯 · 关系 · 历史

饮食偏好（口味 / 常去）

出行习惯（通勤 / 航班）

消费记录（预算 / 品类）

订阅会员（到期 / 比价）

重要日期 · 关系

健康 · 作息

越用越懂你 · 记忆持续沉淀

调用长期记忆
主动触发

餐厅推荐

「您常去的川菜馆今晚有空位，是否帮您预订 19:00? 」

记忆依据：口味偏辣 · 高频到访

消费洞见

「本月餐饮支出已超预算 20%，要查看消费明细吗? 」

记忆依据：消费记录 · 预算品类

纪念日 · 礼物

「下周是妈妈生日，去年送了围巾，今年为您推荐...」

记忆依据：重要日期 · 关系 · 历史送礼

行程提醒

「明早 9:00 航班，建议 7:00 出发，已为您预约网约车。」

记忆依据：出行习惯 · 日程安排

续订提醒

「视频会员 3 天后到期，已为您比价出更优套餐。」

记忆依据：订阅 · 会员记忆

健康提醒

「近期连续晚睡，明日会议多，建议今晚早点休息。」

记忆依据：健康 · 作息规律

记忆从「整理好」到「用得上」：一份长期记忆驱动跨场景主动服务——这正是记忆的价值

AiCon
全球人工智能开发与应用大会

InfoQ 极客传媒

05

工程实践与效果验证


流程化算法开发 + 自动化评测

流程化算法开发 workflow



三段流水线 + Badcase 回灌, 让算法开发从「手工调参」转向「可复制流程」

自动化评测：LLM-as-a-Judge + Badcase 闭环



整体回顾：从「问题」到「解法」



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 8月 📍 深圳 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海 🧑 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

AiCon

全球人工智能开发与应用大会

深圳站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 8 月 21-22 日 / 深圳湾万丽酒店



参会咨询

专题: Harness Engineering: 模型之外的智能体工程

专题出品人: 柴思远

智谱 / 副总裁



专题: 超级个体与蜂群智能的共生进化

专题出品人: 张昊阳

EvoMap / 创始人



专题: AI Agent 高价值商业场景实战

专题出品人: 李响 博士

平安科技 / 智能两核 AI 部总经理



专题: 超级 App 的 AI 原生化: 端智能、端云协同与用户体验重构

专题出品人: 黎三平

京东 / 端技术负责人



专题: AI 原生新范式: Coding Agent 重构软件研发全流程

专题出品人: 林香鑫

网易游戏 / 高级技术经理




专题: 智能体时代的数据供给与治理

专题出品人: 陈廷梁 (王赟)

数新智能 / 创始人兼 CEO



案例复盘：踩坑点 与 重做思考



复盘核心：分层处理 · 端云四维动态分流 · 主动记忆管理 · 策略-工具联合进化 · 评测前置闭环 —— 让方案可复制、可演进

THANKS

探索 Agent 记忆 边界

Explore the Limits of On-device
Memory

AiCon

全球人工智能开发与应用大会