

生成式推荐引擎升级

快手在线参数服务器性能与时延深度优化实践

演讲人：贾荣来

快手 推荐架构高级专家

AiCon

全球人工智能开发与应用大会

目录

业务背景：大模型时代面临的挑战

核心目标：CPU算力失衡下的解决思路

技术方案：RDMA重构通信链路

技术方案：高性能存储引擎


方案总结与项目成果

未来展望


01 业务背景

大模型时代面临的挑战

搜广推模型在线架构现状



- 计算-存储分布式架构



- Infer-Embedding请求路径

大模型时代面临的挑战

- **生成式推荐** 正在深刻重构搜索、广告与推荐（搜广推）系统的核心逻辑，推动其从“精准匹配”迈向“价值创造”，同时也带来了新的挑战。



■ 高密机型可行性分析

内存容量突破

当前高密机型已支持2TB以上内存，满足大规模稀疏参数存储需求，显著减少EmbeddingServer集群数量，缓解木桶效应。

硬件协同瓶颈


内存与网卡性能提升后，CPU易成为系统瓶颈，需通过架构优化避免资源利用率不均衡。

高性能CPU配置

搭载最新多核处理器，单机算力提升3-5倍，但受限于摩尔定律失效，性能无法与内存同步线性增长。

高速网络接口

800G网卡提供超高带宽，理论上可解决InferServer与EmbeddingServer间的数据传输瓶颈，降低延迟。



02 核心目标

CPU算力失衡下的解决思路

CPU“减负”+“提效”

RDMA重构通信链路



☐ Kernel Bypass、零拷贝

☐ RDMA通信库

☐ AZ级RDMA网络环境

高性能存储引擎



☐ 哈希表方案

☐ SIMD（单指令多数据流）

☐ 批量请求下的预取流水

软硬一体协同优化：高密计算存储分布式架构下的通信链路重构+存储引擎极致优化

03 技术方案

RDMA重构通信链路

RDMA软件栈

1. 高易用性


- 协议统一
- 接口统一
- 本地组件支持

2. 高性能


- 无锁全异步模式
- 轮询模式、单边操作
- 零拷贝、RawBytes传输

3. 高鲁棒性

- RC通信模式
- Fallback机制
- 硬件兼容



RDMA通信库整体方案




ThreadResource: 一组资源描述，包括网卡、注册内存、发送队列、接收队列、完成队列、qp对，一个轮询线程+一组工作线程等

请求流程


- ① 服务端准备资源
- ② ③ 客户端提交请求任务到本地网卡(rdma_send)
- ④ 客户端网卡将请求发送到对端网卡
- ⑤⑥⑦ 服务端网卡将接收到的请求写入注册内存，并生成完成任务放入完成队列(rdma_receive)
- ⑧⑨ 轮询线程从完成队列获取任务并交由工作线程处理
- ⑩⑪ 工作线程将返回结果提交到本地网卡
- ⑫⑬ 服务端网卡将返回结果直接写入对端内存(rdma_write)
- ⑭ 客户端轮询本地内存变化获取返回结果

RDMA通信库关键技术点


连接管理




线程模型



内存管理




并发控制




AZ级RDMA网络环境


网络架构示意图



- 传统RDMA网络仅覆盖**POD内**，跨POD通信存在**丢包**风险




- 通过自研拥塞控制算法解决丢包问题，将RDMA通信范围由**POD级**扩展到**AZ级**
 - 多路径能力
 - RDMA、TCP双栈混跑
 - 端到端7跳交换机时延小于**50us**



- 资源实现**亲和调度**
 - 优先POD内RDMA通信
 - 其次AZ内RDMA通信
 - 最后AZ间TCP通信


AZ级RDMA网络环境下流量混跑



04 技术方案

高性能存储引擎

原存储引擎的性能缺陷



Embedding服务特点

- 点查、点更新
- 重读轻写
- 批量查
- Value变长
- 过期回收

该方案存在的缺陷


- Hash冲突严重时大量Cache Miss
- 读路径上多次访存，访存代价高
- 过期回收逻辑冗长

哈希表的选择

哈希类型	查询性能	写入性能	删除性能
链式哈希	中等（缓存不友好）	快（直接追加）	中等（先查找）
线性探测哈希	快（缓存友好）	中等（可能需探测）	中等（墓碑机制）
布谷鸟哈希	最快（O(1) 保证）	慢（可能持续踢出）	最快

布谷鸟哈希

- 最坏情况下只需两次Cache Miss即可找到目标key或确认miss
 - 将查询复杂度转移到了更新阶段
 - 插入时若key的两个候选位置均被占用，会随机踢出已有元素（kick out），直到达到最大递归深度
- 因此该方案是一个应用于读多写少时的场景下的绝佳方案。




Bucket设计与SIMD并行

哈希查找的开销主要集中在 Cache Miss 上，因此如果能尽可能利用一个 CacheLine（通常为 64B）的信息处理更多内容，就能减少查找开销

➤ Bucketized 布谷鸟哈希


- 单个的 CacheLine (64B) 存储多对 key-value，通过缩短关键信息长度提升存储密度
- 用 key 的 1 字节哈希 (Tag) 替代原始 key 存储在 Bucket 中
- 使用 128 位 SIMD 指令即可一次性完成 12 个 Tag 的比对



批量读优化


➤ 常规检索流程

- key串行执行
- 受内存墙制约：CPU因等待内存返回而阻塞




➤ 预取+流水

- 将批量请求切分为minibatch执行
- 基于批量预取的流水线执行模式




过期回收与强制回收

- 数据过期策略普遍采用相对时间 TTL (如 1h/12h/1day/7day)
- 同一 TTL 配置的数据，写入时间越早则过期时间越早
- 将同一 TTL 的数据按写入顺序维护在有序队列中，仅需检查队列头部元素是否过期
- 内存不足时按过期时间强制淘汰队列头部元素



整体方案



05 方案总结与项目成果

技术方案总结

高性能存储引擎

- Cuckoo Hash
- SIMD并行计算
- 预取 + 流水
- RawBytes传输

应用层

通信层

RDMA网络通信库

- 无锁全异步
- 链路感知
- 负载均衡
- 失败回退TCP

网络层

AZ级RDMA网络环境

- 2/4x200G双上联
- 自研拥塞控制算法
- TCP、RDMA混跑
- 多路径逃生能力

项目成果

+270%

Embedding吞吐

单机QPS 275万、KPS 13.7亿，
网卡吞吐746Gb/s

-67%

Infer-Embedding时延

上下游平响106us，P99 300us，
消除长尾效应

-70%

资源成本

集群规模降为原来的1/64，
提升业务迭代上限

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 8月 📍 深圳 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海 🧑 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

AiCon

全球人工智能开发与应用大会

深圳站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 8 月 21-22 日 / 深圳湾万丽酒店



参会咨询

专题: Harness Engineering: 模型之外的智能体工程

专题出品人: 柴思远

智谱 / 副总裁



专题: 超级个体与蜂群智能的共生进化

专题出品人: 张昊阳

EvoMap / 创始人



专题: AI Agent 高价值商业场景实战

专题出品人: 李响 博士

平安科技 / 智能两核 AI 部总经理



专题: 超级 App 的 AI 原生化: 端智能、端云协同与用户体验重构

专题出品人: 黎三平

京东 / 端技术负责人



专题: AI 原生新范式: Coding Agent 重构软件研发全流程

专题出品人: 林香鑫

网易游戏 / 高级技术经理



专题: 智能体时代的数据供给与治理

专题出品人: 陈廷梁 (王赟)

数新智能 / 创始人兼 CEO



06 未来展望

RDMA+UTCP+KTCP

- RDMA无法实现跨AZ、跨地域传输
- 通过UTCP（用户态TCP）链路实现高性能数据传输
- 在不支持RDMA、UTCP的网卡上通过传统TCP进行数据传输

CPU2GPU RDMA

- Infer获取到Embedding数据后，通过PCIE传输到GPU，仍需CPU介入
- EmbeddingServer直写Infer侧GPU显存，避免CPU介入

CXL共享内存池

- Embedding多副本间冗余存储多份模型参数
- 通过CXL2.0共享实现多副本间共享同一份模型参数
- Infer与Embedding之间通过CXL协议实现数据传输

THANKS

探索 AI 应用边界

Explore the limits of AI applications

AiCon

全球人工智能开发与应用大会