

训推一体潮汐弹性

蚂蚁集团在智算基础设施的池化调度实践

演讲人：吴伟

蚂蚁集团 / 高级技术专家

AiCon

全球人工智能开发与应用大会

目录

01 为什么做训推一体潮汐弹性?

02 训推一体潮汐弹性整体架构

03 关键技术：训推集群升级

04 关键技术：推理服务自动弹性

05 关键技术：弹性配额和抢占

06 总结和展望

01 为什么做训推一体潮汐弹性？

蚂蚁集团 AI 业务介绍

AI 业务



百灵大模型

Ling-2.6-1T
Ling-2.6-Flash
Ring-2.6-1T
Ming-Flash-Omni



阿福

AI 诊室
安诊儿
报告解读
就医服务



灵光

闪应用
灵光圈
打电话
开眼



蚂小财

持仓分析
AI 策略
AI 选股



Agents



技术流程

数据处理

预训练
(语言/多模)

后训练
(SFT/RL)

模型评测

模型推理

Agent 应用

资源编排



GPU 资源分配

训练/推理任务调度

集群管理和升级

任务弹性和抢占

AIDC




多 AIDC 集群
(多云多地域)

异构算力
(NV 卡和国产卡)

通智算
(GPU+CPU)

训推分离的资源管理




资源墙


技术栈不同

资源归属不同

业务节奏不同




日常一天训练/推理资源情况



日常情况下，训练任务晚上任务堆积，无法使用推理集群的空闲资源

活动场景下，推理服务无法使用训练集群资源来满足资源需求

训推一体的核心思路



训推一体不是简单的任务混部，
而是在不影响推理 SLO 的同时挤出训练算力。


训推一体潮汐弹性方案

训推一体潮汐弹性整体架构




02 关键技术：训推集群升级

集群训推一体升级: 异构算力池化



不统一就无法实现真正混部：不同版本的库、驱动、内核会让训推任务行为不可预测。

集群训推一体升级：网络冲突




集群训推一体升级：网络QoS+拓扑调度




核心经验： 先看见再优化；逐步灰度，小步慢跑

关键技术：推理服务自动弹性

推理服务自动弹性：架构图




推理服务自动弹性：双反馈链路




推理服务自动弹性：弹性指标

为什么 GPU 利用率不 work?



仅一个 SM 在工作，其余都是空闲
\$nvidia-smi -> GPU util 100%



QPS 降低到 30%，GPU 利用率一直是 100%

副本数 =

多指标综合决策（现状）

max

- 输入 **token** 压力 / 单副本 **prefill token/s**
- 输出 **token** 压力 / 单副本 **decode token/s**
- 并发请求数 / 单副本可承载并发数
- **KV cache** 需求 / 单副本 **KV cache** 容量

× 安全系数



兜底信号（SLO 保障）

- TTFT + TPOT
- 实时链路监控
- 增长超阈值即扩容，不等破线

load_score =

w1 **queue_wait_p95 / queue_slo**
排队等待压力

w2 **TTFT_p95 / ttft_slo**
首 token 响应压力

w3 **TPOT_p95 / tpot_slo**
逐 token 生成压力

w4 **kv_cache_usage_ratio**
KV cache 显存水位

w5 **prefill_tokens/s / prefill_capacity**
输入 token 吞吐压力



w6 **decode_tokens/s / decode_capacity**
输出 token 吞吐压力

多指标加权负载决策（进行中）

模型服务的处理能力受到输入/输出长度*KVCache 命中率*模型架构*引擎 BatchSize * 部署策略*硬件算力等多因素影响影响，不能用简单的线性逻辑来计算。

推理服务自动弹性：极速启动

Deepseek-R1 启动时间对比 (min)



Rfork: <https://www.lmsys.org/blog/2025-12-10-rfork/>

推理服务自动弹性：SLO 保障



- 镜像加速
- 模型预热
- rfork RDMA 分发

极速启动



- 实时 TTFT/TPOT 信号
- 超过阈值直接扩容到最大
- 单独链路，优先级最高

兜底扩容



- 历史流量预测提前扩容
- 实时指标监控，补位 burst 流量扩容

预测+响应




- 新策略线下流量回放模拟
- 策略灰度变更

灰度变更

宁可先扩再缩或者资源浪费，也不要影响业务 SLO。

关键技术：弹性配额和抢占

弹性配额和抢占



分级配额+高低保弹性配额

高保配额

最低保障的资源配额

不可被抢占

来自于集群物理资源



低保/弹性配额

超出高保的额外借用

可以被抢占

来自于高保空闲+库存

弹性配额和抢占



任务抢占流程

Level 1

同机箱 • 同 NVSwitch 域

NVLink 互联
带宽 900 GB/s
延迟 < 10 μ s

Level 2

同机架 • 同 ToR 交换机

RDMA 互联
带宽 100-200 GB/s
L1 不满足时退而求其次

Level 3

同机房 • 同 Spine 交换机

跨机架但同机房
避免跨机房路由
国产芯片拓扑感知插件化

拓扑感知调度

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 8月 📍 深圳 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海 🧑 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

AiCon

全球人工智能开发与应用大会

深圳站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 8 月 21-22 日 / 深圳湾万丽酒店



参会咨询

专题: Harness Engineering: 模型之外的智能体工程

专题出品人: 柴思远

智谱 / 副总裁



专题: 超级个体与蜂群智能的共生进化

专题出品人: 张昊阳

EvoMap / 创始人



专题: AI Agent 高价值商业场景实战

专题出品人: 李响 博士

平安科技 / 智能两核 AI 部总经理



专题: 超级 App 的 AI 原生化: 端智能、端云协同与用户体验重构

专题出品人: 黎三平

京东 / 端技术负责人



专题: AI 原生新范式: Coding Agent 重构软件研发全流程

专题出品人: 林香鑫

网易游戏 / 高级技术经理



专题: 智能体时代的数据供给与治理


专题出品人: 陈廷梁 (王赟)

数新智能 / 创始人兼 CEO



06 总结和规划

总结和规划



+10%
GPU 平均利用率

99%+
推理服务 SLO

↓ 20%
训练任务平均等待时间

总结和规划

总结

1. 公司的 AI 竞争力是全栈的，既包括算法能力，也包括基础设施能力；其中**算力资源效率**不仅决定了推理服务的成本，也决定了训练任务的迭代效率
2. 在真正有业务需求的时候再考虑训推一体（同一种卡型号能同时支持训练和推理任务）
3. **稳定性优先**，训练任务不要影响推理服务（小步灰度，逐步扩大范围在过程中解决干扰问题）
4. 集群的版本合并和统一是基础，重点关注存储和网络的隔离
5. 模型服务的**弹性**要结合业务特征和 SLO 选择合适的指标（没有银弹，选择合适自己的）

总结和规划

规划

1. 提升调度维度：集群→地域→全局的算力资源调度
2. 任务级别弹性：运行过程中 scale out 单个任务的算力资源，加快高优任务的处理速度
3. 异构任务调度：推理的 PD 异构、RL 训推异构
4. 提升弹性效率：万卡/10min 级别的弹性，提升活动的资源效率
5. 弹性策略自动寻优 (Agentic Auto Research)

THANKS

探索 AI 应用边界

Explore the limits of AI applications

AiCon

全球人工智能开发与应用大会

单击此处添加标题



Sadipscing eu at dolore
magna voluptua magna
nisl lorem.

Click to add text



Sadipscing eu at dolore
magna voluptua magna
nisl lorem.

Click to add text




Sadipscing eu at dolore
magna voluptua magna
nisl lorem.


Click to add text




Sadipscing eu at dolore
magna voluptua magna
nisl lorem.

Click to add text





颜色规范



■ 字体规范（内容页）

■ 一级标题 苹方字体 36号字 中粗体 黑色

■ 二级标题 苹方字体 18号字 中黑体 蓝色

■ 三级标题 苹方字体 16号字 常规体 黑色

■ 正文 苹方字体 12-14号字 常规体 黑色淡色 25%
正文 段落间距 多倍行距 1.3 段后间距 12

间距:

之前:	0 pt	行距:
之后:	12 pt	多倍行距 在: 1.3

内容页示意

二级标题 18号字 苹方字体 中黑体

QCon 全球软件开发大会是由极客邦科技旗下 InfoQ 中国主办的综合性技术盛会，自 2007 年 3 月份开始举办以来，已经有超万名有多年从业经验的技术人员参加过 Qcon 大会。

正文少时 建议 14 号字

二级标题 18号字 苹方字体 中黑体

QCon 全球软件开发大会是由极客邦科技旗下 InfoQ 中国主办的综合性技术盛会，自 2007 年 3 月份开始举办以来，已经有超万名有多年从业经验的技术人员参加过 Qcon 大会。

QCon 全球软件开发大会是由极客邦科技旗下 InfoQ 中国主办的综合性技术盛会，自 2007 年 3 月份开始举办以来，已经有超万名有多年从业经验的技术人员参加过 Qcon 大会。

正文多时 建议 12 号字




弹性整体架构 — 三层闭环


感知层 六维指标采集



决策层 弹性决策引擎



执行层 秒级模型启动



 单击此处添加标题