

迈向 Token 服务新范式

——从评测到调度的全链路优化供给


演讲人：冷静文

上海交通大学 计算机学院副院长


AiCon

全球人工智能开发与应用大会

Token 调用量高速增长



来源：基于openai/google/openrouter等平台披露估计



来源：国家数据局 / 国新办公开披露；2026.03月 >140 万亿

Token 调用量增长分析

Token 增长主要来自 AI 工作流的自我消耗

Agent 化、编程智能体、多步骤执行、中国模型供给扩张，共同把 Token 从交互用量推向生产用量



来源：Token 使用增长分析报告，OpenRouter Apps / Rankings，Anthropic 成本预估变化及国家数据局公开讲话

Token 服务形式的优势

通过云平台将大模型封装为 **Token 调用服务**，是人工智能目前的主要服务模式



中国是Token服务发展的沃土—政策支持

国务院发文《关于深入实施“人工智能+”行动的意见》，指出

“培育人工智能应用服务商，发展‘模型即服务’、‘智能体即服务’等，打造人工智能应用服务链”

2026年3月 十五五规划纲要

第四篇 深入推进数字中国建设 提升数智化发展水平

把握数字化、网络化、智能化发展大势，充分发挥我国数据资源丰富、产业体系完备、应用场景广阔优势，激活数据要素潜能，加快数智技术创新，深化拓展“人工智能+”，赋能经济社会发展和治理能力提升，促进生产方式深层次变革和生产力革命性跃迁。

第十二章 强化算力算法数据高效供给

统筹推进算力设施建设、模型算法发展和高质量数据资源供给，筑牢数智化发展底座。

第一节 加强算力设施支撑

统筹布局、有序建设算力设施，推进算力资源规模化、集约化、绿色化、普惠化发展。加快国家枢纽算力设施集群建设，支持有条件地区根据低时延场景需求适度发展算力，推进云边端协同发展。加强高性能高质量智算资源供给，论证建设超大规模智算集群。推进算力设施市场化建设运营，支持通过政府购买算力服务、算力租赁等多种方式满足算力需求，创新发展标准化可扩展的智算云服务。推动绿色电力与算力协同布局。加强全国一体化算力监测调度，提升算力接入和精准匹配能力。加快培育自主可控、协同运行的软硬件生态。提升算力普惠易用水平，降低中小企业用算成本。

第二节 促进模型算法迭代创新

加快突破人工智能基础理论和核心技术，推进人工智能模型架构改进、算法优化，强化“模芯云用”协同创新。构建任务导向、灵活授权、跨域协同的算法创新组织模式，加快研究更加高效的模型训练和推理方法。鼓励多模态、智能体、具身智能、群体智能等技术创新，探索通用人工智能发展路径。推动通用大模型和行业专用模型同步发展，依托高价值场景推动模型应用落地和迭代升级。建立健全模型能力评估体系。

2026年4月：工信部“模数共振”行动

二、重点任务


（一）构建行业通识数据集，打造行业模型

结合各省级地区/各央企特色优势，在“工作目标”列出的行业范围内，选取若干重点行业确定行动范围（每个省级地区至少选择3个，每家央企至少选择1个）。分行业梳理行业内数据资源，明确产数主体、数据类型、资源规模等信息，并通过数据标注、知识工程等手段，提炼形成行业通识高质量数据集（每行业梳理不少于5个），形成《重点行业通识高质量数据集清单》。基于行业通识数据集，聚焦行业内人工智能应用的痛点，研发能够掌握行业技术机理、服务行业共性应用场景的行业模型（每行业研发不少于1个），并在符合法律政策、保障安全要求的前提下，稳妥有序开展应用（每个行业模型应用案例不少于5个）。行动结束时汇总形成《重点行业模型清单》，为行业智能化转型提供共性底座。

（二）梳理高价值场景，构建行业专识数据集，打造特色智能体

围绕所选择的重点行业，梳理、培育一批应用潜力大、推广范围广、可复制性强、适合通过人工智能技术改造的细分人工智能应用场景，凝练形成《重点行业人工智能高价值场景档案》（每个行业凝练不少于30个）。针对各高价值场景实现规模化应用的需要，逐个构建蕴含场景特殊知识的行业专识高质量数据集（每个场景构建不少于1个），并打造能够符合场景特殊应用需要的专用模型或特色智能体（若场景应用需具备自主规划、执行能力，则打造智能体，其他情况打造专用模型，每个场景打造不少于1个）。在符合法律政策、保障安全要求的前提下，稳妥有序开展专用模型/特色智能体的实践落地（每个专用模型/特色智能体落地案例不少于3个）。行动结束时汇总形成《重点行业专识高质量数据集清单》和《专用模型/特色智能体清单》。

中国是Token服务发展的沃土-市场环境



Token 需求旺盛、呈现蓬勃发展状态


中国Token服务现状

「 从一个异常发现说起 」

便宜模型的账单悖论引发警觉

开发者很喜爱的claude code，调用便宜模型，实际费用异常偏高，打破了"单价低则成本低"的直觉认知

按某用户当天计费日志做样本（该模型当天 148 次请求）



反常现象：便宜约4倍的模型，单次花费却和旗舰打平

同为当天真实请求 | 柱高=单次平均成本 | 柱内配色=输入侧缓存构成

输入侧构成

- 缓存未命中（全价）
- 缓存命中（打折）
- 写缓存

一眼看懂

两根柱几乎一样高 = 单次花费打平。
但便宜模型76%是红色全价、
旗舰98%是绿色打折——
单价本该便宜4倍，
全被「未命中缓存」抹平了。

为什么会存在这样的情况？

- 进一步排查发现：同一个会话的多轮请求，缓存命中率极低

–提示词中有计费内容块，其中包含一个每轮都在变化的cch值，导致缓存无法命中

(Claude Code, 自版本 2.1.36 起) 为了计费归因，会在请求的提示词最前面注入一段**计费内容块**

会处理的服务商

- 处理前自动剥离该计费内容块
- 结果：即使 cch 每轮变，服务商看到的缓存前缀仍然稳定
→ 命中正常。

不处理的第三方服务商

- 把含变化的cch的完整前缀当成缓存 key
- 结果：**大量输入未命中缓存，成本提升数倍**

■ 设计对比实验，把问题测成了“可验证事实”

构造多轮会话

取真实请求会话，将其中的消息块打散/脱敏后构造anthropic协议的多轮会话。



对比实验

一路包含计费内容块，一路剥离计费内容块生成对比请求，交织发送请求进行对比。



交叉验证

使用claude code直连服务商进行抽查，作为对比实验的交叉验证，确保实验结论具备统计学意义与行业参考价值。



测试结果：问题具有普遍性

- 共测试 62 个模型 × 服务商组合，覆盖主流国产模型（DeepSeek v4、glm 5.1等）与主流服务商
- 在具备缓存能力的组合中，约 43% 的组合被cch击穿


模型	服务商	剥离计费内容块的缓存命中率	包含计费内容块的缓存命中率	判定
模型A	服务商A	96.2%	96.2%	已处理
模型A	服务商B	36.1%	0.0%	被击穿
模型A	服务商C	44.2%	0.0%	被击穿
模型B	服务商D	49.0%	44.6%	已处理
模型B	服务商E	52.3%	0.0%	被击穿
模型C	服务商F	63.7%	61.7%	已处理
模型C	服务商G	80.4%	0.0%	被击穿

测试结果：问题具有普遍性

- 以DeepSeek-V4-Flash为例，近半数服务商被击穿，缓存命中为0


模型甲（DeepSeek-V4-Flash）· 各服务商 token 级缓存命中（现状）

柱高=token 数；绿色越接近灰色顶端=命中率越高。



横轴：服务商（按命中率降序匿名为 官方/A/B/C...） 红色底线=命中归零（被计费指纹击穿）

■ 优化方案



网关转发前统一剥离计费内容块

在网关层将发往服务商的请求体中计费块整段删除，使服务商重新看到稳定前缀。

算指纹前剔除计费头整行

确保缓存键生成基于干净且稳定的内容，消除cch破坏性同时不误伤正常缓存。

降低实施复杂度与推广门槛

网关层统一处理无需逐个服务商协调，具备强工程可行性与通用适配性。

■ 优化效果实现多重提升

✓ 命中率、缓存量、成本同时改善

命中率从20%跃升至80%

Coding场景下缓存命中率实现四倍增长，从约20%提升至约80%，恢复缓存机制应有作用。

Token成本最高下降75%

该模型token成本最高可下降约75%，使模型单价优势真正转化为成本优势，为企业级AI应用成本控制提供可复制的实践路径。

Token: AI 时代的水电

Token使用场景


场景分类 专业工作 / 个人赋能

场景示例 养龙虾 / 编程辅助 / 图片、视频创作

Token购买来源和决策指标

购买来源 模型原厂 / 第三方服务商

核心决策指标 效果 / 价格 / 性能 / 稳定性



挑战-1：如何选择合适大模型？

模型更新迭代速度快，缺乏有效汇总信息

模型大小

影响精度

上下文窗口长度

影响效果

模型定价

影响成本

模型适用场景不同

不同 Benchmark 评分不一致

面临现状：用户反复切换不同模型，互相对比验证效果

挑战-2：如何选择合适 Token 服务商？



问题

- ▶ Token 服务商的服务各具特色，用户的需求各不相同，如何对齐供需？
- ▶ 面对众多 Token 服务商，对于同样的大模型，用户该选择哪家服务商？

Token 质量参差不齐

Token的购买和使用隐藏陷阱、
前提条件：同样的模型 & 同样价格

陷阱一

不同服务商的
模型效果并不相同




陷阱二

不同服务商的
最终花费并不相同


陷阱三

不同服务商的
服务质量差距巨大



* “慢响应”指大模型推理服务在处理请求时，从接收输入到返回第一个有效字符的时间超过了预期的性能指标

AI 开发者到底需要什么系统?






www.aiping.cn




面向大模型使用者的
全面、客观、真实的信息汇总、AI评测
一站式Token服务平台



接入层全面聚合主流厂商与模型

600+大模型：文本、图片、视频.....



30+家大模型服务商

阿里云百炼	京东云	SCNet
百度智能云	可灵AI	SophNet
百灵大模型	快手万擎	商汤大装置
并行智算云	蓝耘元生代	腾讯云
DeepSeek	零克云	天翼云
硅基流动	MiniMax	UCloud
华为云	Moonshot AI	无问芯穹
火山方舟	模力方舟	讯飞星辰
基石智算	PPIO派欧云	智谱
金山云星流	七牛云	...

■ 评测驱动：让Token服务质量「透明可见」

- AI Ping 的评测体系：从真实用户视角出发，端到端匿名评测

评测维度


- 首字延迟 (TTFT)
- 输出吞吐 (TPM)
- 可靠性 (可用率、错误率)
- 价格透明度 (输入/输出单价、隐性费用)
- Cache命中率 (直接影响实际成本)

评测机制

- 7×24小时不间断运行，非一次性快照
- 北京、深圳、上海、成都异地分布式测试
- 动态输入机制，避免服务商「针对评测作弊」
- 同模型同输入同时段公平对比
- 与云厂商性能监测交叉验证，误差控制在1%以内


- 成果：客观、可验证的性能榜单，让「黑箱」变「白箱」

性能评测：Token 吞吐-延迟坐标图



性能评测：Token 服务性能随时间变化趋势图

7 x 24小时高频率、多时段测试，性能数据实时更新



Token 服务指标信息汇总

多关键字 筛选

Token 价格	上下文长度	延迟	吞吐	
----------	-------	----	----	-------

服务商	上下文长度	最大输出长度	输入价格	输出价格	吞吐	延迟	可靠性	精度
-----	-------	--------	------	------	----	----	-----	----

服务商1	128k	64k	¥2.00/M	¥3.00/M	76.62tps	5.55s	100%	0.85
服务商2	164k	164k	¥2.00/M	¥3.00/M	69.36tps	2.98s	80%	0.81
服务商3	128k	64k	¥2.00/M	¥3.00/M	57.81tps	1.01S	100%	0.83
服务商4	160k	160k	¥2.00/M	¥3.00/M	57.79tps	6.01s	100%	0.85
服务商5	160k	160k	¥2.00/M	¥3.00/M	57.7tips	5.99s	85%	0.80

根据指标筛选、排序

多关键字 筛选

Token 价格

上下文长度

延迟

吞吐

.....

服务商

上下文长度

最大输出长度

输入价格

输出价格

吞吐

延迟

可靠性

精度

服务商1	128k	64k	¥2.00/M	¥3.00/M	76.62tps	5.55s	100%	0.85
服务商2	164k	164k	¥2.00/M	¥3.00/M	69.36tps	2.98s	80%	0.81
服务商3	128k	64k	¥2.00/M	¥3.00/M	57.81tps	1.01S	100%	0.83
服务商4	160k	160k	¥2.00/M	¥3.00/M	57.79tps	6.01s	100%	0.85
服务商5	160k	160k	¥2.00/M	¥3.00/M	57.7tips	5.99s	85%	0.80

排序

■ 智能路由：Token调度的「导航系统」

- AI Ping 智能路由 ≠ 简单的API转发，而是实时路径规划


路由决策维度（多指标动态权衡）

- 价格：输入、输出、缓存的综合成本
- 首字延迟：用户体感响应速度、交互流畅度
- 输出吞吐：生成速度、长文本生成耗时
- 可靠性：调用成功率、故障概率
- 模型效果：任务匹配度、输出质量

路由策略模式


- 默认模式：综合最优平衡
- 成本优先：相同质量下选择最低成本路径
- 性能优先：最低延迟、最高吞吐
- 质量优先：复杂任务路由至最强模型

智能路由：模型路由




模型路由	成本	吞吐	能力
简单模型A	1元/百万tokens	100 TPS	能够回答80%问题
复杂模型B	10元/百万tokens	10 TPS	能够回答95%问题
模型路由	平均2.8元/百万tokens	平均 82 TPS	能够回答95%问题

智能路由：模型路由



智能路由：模型路由原理



核心思想：基于历史数据构建评价模型

智能路由：Token 服务商路由



智能路由：实时感知服务商多维状态

服务商多维状态感知

服务商静态能力感知

实时维护不同服务商的**参数支持状态**，动态映射最大上下文窗口、最大输入/输出长度限制


服务商动态限流监控

解析单模型级和全局级的**并发限制**（RPM/TPM等），监控分钟级/小时级的配额消耗速率


服务商性能时序波动

捕捉同一供应商在**不同时段**的延迟抖动与吞吐衰减特征

服务商	模型	上下文长度	最大输入长度	最大输出长度	RPM	TPM
服务商A	DeepSeek-V3.2	128k	128k	64k	- 8k	7M
服务商B	Qwen3.5-397B-A17B	256k	256k	256k	- 4k	2M
服务商C	Qwen3.5-35B-A3B	256k	256k	256k	- 8k	8M



智能路由：Token 服务商路由原理



智能路由：提供统一路由 API

思考

token 价格

最大输入/输出长度

0s - 3s

40 - 100+ tokens

重置 ×

智能路由策略

输出价格优先

```
response = openai_client.chat.completions.create(
    model="DeepSeek-V3.2",
    stream=True,
    extra_body={
        "enable_thinking": False,
        "provider": {
            "only": [],
            "order": [],
            "sort": None,
            "input_price_range": [],
            "output_price_range": [],
            "input_length_range": [],
            "output_length_range": [],
            "throughput_range": [],
            "latency_range": []
        }
    }
)
```

成本优先

延迟、吞吐

```
response = openai_client.chat.completions.create(
    model="DeepSeek-V3.2",
    stream=True,
    extra_body={
        "enable_thinking": False,
        "provider": {
            "only": [],
            "order": [],
            "sort": "output_price",
            "input_price_range": [],
            "output_price_range": [],
            "input_length_range": [],
            "output_length_range": [],
            "throughput_range": [40, 100],
            "latency_range": [0, 3]
        }
    }
)
```




智能路由效果

效能优势

实现“任务 – 模型”的精准适配（兼顾性能与价格），确保整体泛化能力超越单一模型

模型能力评分



智能路由效果



■ 评测 × 路由：1+1 > 2 的协同效应

没有评测的路由 = 盲飞

- 不知道每条「路」的真实路况
- 只能基于静态价格做决策
- 服务商波动时无法自适应
- 容易陷入「低价陷阱」：
单价低但Cache命中率也低，
最终总成本反而更高
- 无法验证路由决策是否有效



没有路由的评测 = 白测

- 测数据无法转化为实际价值
- 用户看完榜单仍不知该选哪家
- 手动切换服务商成本高、效率低
- 无法应对服务商性能的实时波动
- 评测成为「信息消费品」而非「生产工具」

AI Ping = 评测数据实时驱动路由决策，形成「测-调-优」闭环

如何高效生产Token：大模型推理引擎



赤兔大模型推理引擎 国产算力→高质量 Token 输出

开源大模型推理引擎“赤兔”：构建「国产芯片+国产引擎+国产模型」生态闭环

编译优化	异构调度	模型量化	并行优化	国产算力	
提升计算性能	充分利用资源	降低存储需求	提升模型吞吐	支持多款国产AI芯片 华为、海光、沐曦等	
chitu v0.1.x 激活存量算力	chitu v0.2.x 降低算力门槛	chitu v0.3.x 链接行业生态	chitu v0.4.x 提升推理性能	chitu v0.5.x 超节点开箱即用	chitu v0.6.x 赋能智能体应用
25年3月发布	25年4月发布	25年5月发布	25年8月发布	25年12月发布v0.5.0	26年6月发布
赋能存量算力推理部署 FP8精度原版DeepSeek	支持FP4模型量化 降低75%算力成本 支持单GPU卡推理满 血版DeepSeek2026	支持多种自主算力 支持多种主流模型 GLM4.5模型发布 当天支持 昇腾910B平台部署	深度整合图层优化与 算子优化技术 910B推理速度超越 其他开源方案70% H20推理速度比主流 开源方案快30%	国产算力超节点上 提供开箱即用的 大规模推理部署能力 支持超大规模专家并行、多维度 混合并行、PD分离、AF分离、 动静态负载均衡等特性	面向agent应用的 端到端优化能力 支持感知工作流的调 度策略、跨模型流水 线、多模态混合推理 等特性

中国 Token 服务进入分层时代

焦点从“算力 (FLOPS)”转向“Token (词元)”

2026年，中国AI产业核心焦点已从“技术攻坚”转向“规模化落地”。衡量价值的标尺正从算力(FLOPS)逐步被Token(词元)取代。AI基础设施(AI Infra)的核心任务，也从单纯“提供算力”转变为“构建高效的Token流转网络”。

01 / 底层生产层

- 定位：AI产能核心，解决Token“从无到有”
- 核心：物理算力资源转化为Token产能
- 竞争：规模、稳定性、能耗、适配效率

02 / 中层中转层

- 定位：资源枢纽与连接器，解决“产能分散”
- 核心：整合分散资源，提供统一Token接入
- 竞争：上游资源抢占、渠道与流量运营

03 / 顶层调度层

- 定位：AI基建的“大脑”与智能核心
- 核心：“评测+路由”算法，实现Token价值最大化
- 竞争：评测精度、路由效率、跨Infra适配能力

价值核心凸显

调度层技术壁垒高，引领行业标准制定

竞争逻辑转变：从单一算力比拼 → 全链路Token流转效率

未来趋势：三层协同，推动算力依托Token实现普惠化

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 8月 📍 深圳 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海 🧑 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

AiCon

全球人工智能开发与应用大会

深圳站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 8 月 21-22 日 / 深圳湾万丽酒店



参会咨询

专题: Harness Engineering: 模型之外的智能体工程

专题出品人: 柴思远

智谱 / 副总裁



专题: 超级个体与蜂群智能的共生进化

专题出品人: 张昊阳

EvoMap / 创始人



专题: AI Agent 高价值商业场景实战

专题出品人: 李响 博士

平安科技 / 智能两核 AI 部总经理



专题: 超级 App 的 AI 原生化: 端智能、端云协同与用户体验重构

专题出品人: 黎三平

京东 / 端技术负责人



专题: AI 原生新范式: Coding Agent 重构软件研发全流程

专题出品人: 林香鑫

网易游戏 / 高级技术经理



专题: 智能体时代的数据供给与治理

专题出品人: 陈廷梁 (王赟)

数新智能 / 创始人兼 CEO



Token服务调度层实现逻辑



THANKS

迈向 Token 服务新范式

——从评测到调度的全链路优化供给

AiCon

全球人工智能开发与应用大会