



面向智能体与人类用户的AI记忆系统： 架构设计与核心场景实践

范承工-Charles Fan
MemVerge公司联合创始人 & CEO

Vision

Intelligence = Reasoning + Memory

- AI大模型正在越发强大，处理文本、图片、音视频能力正在快速增强
- AI智能体正在越发真实和贴近人类的生活: Claude Code, Cowork, Codex, OpenClaw, ...
- 更强大的上下文带来更智能的AI
- 没有记忆的AI只是聪明的陌生人 (Genius Stranger)
- 同时，记忆的主权和隐私也极为重要

围绕记忆为重心(Center of Gravity), 来构建AI能力

记忆即自我

You are your memory

记忆不是数据库表，也不是上下文窗口技巧。它是自我的连续性——连接你过去经验、当下思考与未来决策的线索。

记忆属于你

Your memory belongs with you

所有权、隐私、透明度和控制权属于你。它们不属于AI公司的服务器、平台的训练管道或厂商的商业模式。

AI应围绕你运转

AI should orbit you

根植于你自己的记忆，整合不同的AI模型和工具，你获得的体验是真正个性化的——模型为你服务，而非相反。


记忆 — 资产

个人为中心的本地AI记忆助理：尊重个人隐私，跨模型共享，用记忆资产提供复利价值。
作为各大模型的本地记忆外脑。



Memory for Agent


智能体记忆：一种面向agent的记忆系统架构




智能体记忆：典型项目MemMachine

- 开源项目Apache 2 license

<https://github.com/MemMachine/>



<https://www.memmachine.ai/>



- 面向开发者用户，AI辅助工具和AI Agent，提供情景记忆 (Episodic Memory)，语义记忆 (semantic memory) 和用户档案记忆 (Profile Memory) 服务
- 支持所有主流AI大模型如OpenAI, Claude, Gemini, Grok等等
- 支持公有云和私有化部署

智能体记忆：Agent的记性好不好如何衡量

LoCoMo(Long Conversational Memory) 是一个评估AI记忆系统与基础模型质量的领先基准测试。该测试包含长对话数据及500组问答对，通过计算正确率来衡量AI记忆系统的效果和性能。MemMachine以接近85%的准确率，在AI Memory领域占据领先地位



运行记录详情

Mean Scores Per Category:


	llm_score	count	type
category			
1	0.8050	282	multi_hop
2	0.7259	321	temporal
3	0.6458	96	open_domain
4	0.9334	841	single_hop

Overall Mean Scores:

llm_score	0.8487
-----------	--------

dtype: float64

技术实现架构：支持MCP，RESTful和SDK接入访问




基于AI记忆的优秀智能体实践




MemoryCare

了解患者的病情，药物计划的
陪伴机器人



FashionIcon

了解用户穿搭风格的
AI造型师助手




AdaptLearn

熟知你学习进度的
AI教学导师



xCURSOR

让Cursor自动生成的代码
更像是你手写的



Sales Assistant Agent

能基于微信聊天记录来推理
哪些好友是潜在有效客户的
AI客情分析助手



Blog Analyst

具备对海量文献或者文章的
阅读过程中形成摘要性记忆
学术聊天机器人

给单个智能体上记忆：以MemoryCare为例




- 病人信息 → 档案记忆
- 病历信息 → 档案记忆
- 用药计划 → 情景记忆
- 康复习惯 → 档案记忆
- 日常对话 → 情景记忆
- 情绪陪伴 → 情景记忆
- 医患同步 → 记忆共享
- 实时医嘱 → 记忆插入



给OpenClaw上记忆：技术路径对比

How the MemMachine Plugin Works

Hook-based integration — memory capture and recall happen automatically on every turn



给OpenClaw上记忆：技术验证

测试基准：2WikiMultiHopQA

OpenClaw 插件 - @memmachine/openclaw-memmachine

指标	原生 OpenClaw（普通聊天）	集成 MemMachine 的 OpenClaw
模型	gpt-5.1-codex	gpt-5.1-codex
回答准确率	36.8%	81.1%
单问题 Token 消耗	10.3 万	4.2 万
提升 / 优化幅度	—	准确率 +44.3 个百分点（约 2.2 倍） Token 消耗减少约 59%

解决的痛点：

1. OpenClaw 上下文压缩导致的失忆现象
2. 依赖读入md 文件加载记忆，浪费 token
3. 跨代理(Agent) 无法直接共享记忆

WikiMultiHop Answer Accuracy

2WikiMultiHopQA benchmark · 220 questions · gpt-5.1-codex · evaluated by gpt-5-mini




Figure 1. WikiMultiHop Answer Accuracy: OpenClaw vs. OpenClaw + MemMachine Plugin

Token Usage Per Question

Average tokens consumed per WikiMultiHop question



Figure 2. Token Usage Per Question: OpenClaw vs. OpenClaw + MemMachine Plugin

Memory for Human Individuals

个人记忆：AI时代最重要的个人资产，如何用，如何存

记忆是否应该放在"云端"。决定你之所以为你的记忆，
该归谁所有？

**"You are your memory.
Your memory uniquely makes you."**

记忆主权丧失

你的个人偏好和工作习惯被锁定在特定厂商云端

隐私隐患重重

最私密、最深度的个人想法与商业机密不断上传

资产无法复利

凌乱散落在各平台的对话，无法沉淀为个人知识资产

个人记忆主权：记忆即我，记忆属于我，记忆为我所用

底层架构的对决：AI记忆的三种归宿



云端吞噬

- 定位：用超级大模型吞噬所有上下文
- 缺陷：忽视人与人的边界，用户彻底丧失隐私和数据控制权
- 风险：垄断语境权，数据被单一实体控制

封号？ 账号切换？



无状态代理

- 定位：将AI视作执行特定跑腿任务的代码
- 缺陷：缺乏长期交互连续性，忽略了信任背书与记忆沉淀
- 风险：每次对话从零开始，无用户画像积累


健忘？ 交出隐私？



个人记忆主权

- 定位：以个人为中心的igital身份与记忆主权
- 优势：模型无关、隐私物理隔离、记忆可携带，资产可复利
- 愿景：模型可替换，记忆永远属于用户

个人记忆主权的技术架构实践



个人记忆三要素：独立、能管理、隐私安全



跨模型、跨平台的记忆共享




丰富的记忆管理能力
(可搜索,可删除,可迁移)




所有记忆100%本地存储



个人记忆：以MemoryBox为例的典型技术架构



个人记忆：多用户记忆共享和协作



个人记忆：记忆能力带来的个人使用AI的独特场景


场景一：多模型共享上下文同时交互



场景二：每个用户有多个人设



场景三：会话过程中更换模型



场景四：基于本地文档、网盘来构建个人知识库，延伸记忆



Thoughts and Outlook

用户痛点：多模态时代的系统性内耗

从物理高频摩擦、技术真伪盲区，到终极的成本与精力无形流失

01



第一级：体验割裂

高频无效搬运：由于模型分散，用户不得不机械地在多平台间复制粘贴，并耗费大量时间反复同步上下文背景信息。

02



第二级：信任盲区

AI 幻觉频发：将模型同屏整合后，紧接着面临单模型经常性“胡说八道”的缺陷，缺乏权威的即时交叉比对参照。

03



第三级：成本空耗

重复资金与Token：在前两级未解决的状态下，用户被迫重复提问铺垫背景，并且需要反复订阅多平台的高额账单。

体验突破：打破平台割裂，用“一站式同屏”与“记忆上下文”重构人机交互

打通各大模型信息孤岛，用统一上下文终结“复制粘贴”的割裂现状

现状痛点：跨平台高频流转

用户为了组合使用不同AI，要在 ChatGPT, Gemini、Claude 等多个网页窗口间频繁来回搬运提示词，复制粘贴非常麻烦。长对话中上下文极易丢失，极度繁琐。




多模型同屏同步 —— 告别低效的“复制粘贴”

多模型同步使用。一个入口，一套 Prompt 同时发送给多个大模型。无需在各平台间来回倒腾，彻底消灭物理搬运的摩擦感。



独家个人记忆管理 —— 打造真正“懂你”的统一上下文

记忆统一管理。利用底层记忆能力，自动为不同模型注入并同步统一的上下文背景。无论怎么更换模型，AI 都能接得上前文，实现真正丝滑、连贯的深度对话。



成本终结：聚合访问与记忆检索，斩断多平台账单与 Token 重复空耗

发挥“个人记忆”检索本能，避免重复消耗 Token 并在单一入口完成极简订阅

现状痛点：无记忆时代的重复空耗与分散订阅

传统 AI 毫无记忆沉淀。每次重启对话用户均需繁复铺垫行业背景和大量字数，白白损耗大量资金；此外多平台按月高昂收费负担过重。




多付费模型统一入口 —— 彻底免除多平台充值负担

一个工具入口，通达多个顶尖付费模型。最核心的是，目前阶段完全免费！
用户不需要在各家多平台充值，直接一键免费，便利度与低成本率拉满。



历史记忆精准查询 —— 拒绝背景资料的 Token 重复浪费

基于记忆省 Token。MemoryBox 能够精准查询和调取之前的历史回答与知识沉淀。
无需重新解释背景，直接承接记忆继续提问，从底层大幅减少不必要的 Token 消耗。



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 8月 📍 深圳 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海 🧑 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

AiCon

全球人工智能开发与应用大会

深圳站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 8 月 21-22 日 / 深圳湾万丽酒店



参会咨询

专题: Harness Engineering: 模型之外的智能体工程

专题出品人: 柴思远

智谱 / 副总裁



专题: 超级个体与蜂群智能的共生进化

专题出品人: 张昊阳

EvoMap / 创始人



专题: AI Agent 高价值商业场景实战

专题出品人: 李响 博士

平安科技 / 智能两核 AI 部总经理



专题: 超级 App 的 AI 原生化: 端智能、端云协同与用户体验重构

专题出品人: 黎三平

京东 / 端技术负责人



专题: AI 原生新范式: Coding Agent 重构软件研发全流程

专题出品人: 林香鑫

网易游戏 / 高级技术经理



专题: 智能体时代的数据供给与治理

专题出品人: 陈廷梁 (王赟)

数新智能 / 创始人兼 CEO



MemVerge.ai

MemVerge.ai

Mission


Help every individual and every organization safekeep, curate and recall their own memories, and deliver superior human-centric AI experiences to everyone

~\$100M investments from VCs and these industry leaders:



Select Customers





我的记忆， 我做主

官网链接: <https://cn.memorybox.ai/>



产品内测申请



市场合作