



高效大模型技术创新 与应用发展观察

演讲人：

井晨哲

面壁智能 / OpenBMB 开源社区


AiCon

全球人工智能开发与应用大会

以 ChatGPT（GPT-3.5）、GPT-4 为代表的超大规模语言模型（深度神经网络）在众多任务中取得了优越的成绩，通用人工智能曙光初现



注：困惑度常用于反映大语言模型的能力，其值越低模型性能越好；圆圈大小表示模型训练计算量




GPT-4 在多项专业考试中的排名 已经超越大部分人类 [2]

模型性能随计算量不断提升 [1]

大模型发展面临资源受限难题

进入2025年，规模定律面临 **训练数据** 和 **计算资源** 方面的可持续发展问题



以计算资源为例

Llama-3	405B	1.6万	H100
	1000B	4万	H100
	10000B	40万	H100
	100000B	400万	H100



2023年全部H100 GPU产能**近十倍**^[1]
用电功率超过美国一座**1000万人**城市^[2]
人类计算集群并行数量**上限40倍**^[3]


[1] Nvidia is estimated to sell over half of a million of its high-end H100 compute GPUs worth tens of billions of dollars in 2023, reports Financial Times.

[2] 微软数据中心技术和战略部门首席电气工程师保罗·楚诺克 (Paul Churnock) 预测：“英伟达的 H100 GPU 峰值功耗为 700 瓦，按照 61% 的年利用率计算，相当于一个家庭的平均功耗（假设每个家庭 2.51 人）”。
[3] 目前已知最大规模并行计算集群为 XAI 的 100000 张 H100 GPU

■ 启示：算力普惠带来信息革命

未来**5台主机**足以满足整个世界市场。

—— IBM董事长沃森(Thomas J. Watson)



2024年 全球预计接近

13 亿 个人计算机（PC）^[1]

70 亿 部手机 ^[2]

180 亿 接入互联网的IoT设备 ^[3]

2000 亿 正在运行的CPU ^[4]

数据来源：

[1] https://stats.areppim.com/stats/stats_pcxfcst.htm


[2] <https://explodingtopics.com/blog/smartphone-stats>

[3] <https://iot-analytics.com/number-connected-iot-devices/>

[4] <https://www.ibm.com/think/topics/cpu-use-cases>

■ 启示：芯片行业的摩尔定律

半导体行业在摩尔定律指引下，持续改进制造工艺，提升芯片制程，核心是提升芯片**电路密度**而非芯片尺寸，实现计算设备**小型化普惠化**



摩尔定律 vs 密度法则

摩尔定律



$$\text{电路密度} \approx \frac{\text{计算单元数量}}{\text{芯片面积}}$$




芯片电路密度
每 18 个月 翻倍

密度法则



$$\text{知识密度} \approx \frac{\text{智能水平}}{\text{模型参与计算参数}}$$



大模型知识密度
每 100 天 翻倍


InfoQ 极客传媒

■ 高效技术思想：从大力出奇迹到高效低成本

能力密度：兼顾效果与效率的评测指标

$$\rho = \frac{\text{同能力的标准模型激活参数量}}{\text{目标模型激活参数量}} = \text{单位参数中蕴含的智能水平}$$

使用 Predictable Scaling 技术估算模型相对密度




标准模型能力密度


GPT-3 相对能力密度

$$1 = 2.4B / 175B = 0.0137$$


行业意义：洞察大模型高效能发展规律



信息革命
迈向
智能革命



■ 高效技术思想：从大力出奇迹到高效低成本



- 首次 **系统性揭示了大模型高效化发展** 的必然趋势
- 与清华大学联合发表在 Nature Machine Intelligence¹ **封面文章**

发布一周后受到国内主流媒体新闻报道（2025年11月）

- 新华社采访报道首周阅读破 60 万；《科技日报》要闻刊发
- 人民日报客户端、光明网、中国日报等第一时间均转载刊发
- 学习强国、中国科协、北京市科委及中关村管委会、上海“模速空间”等产业学术官方平台主动发布与推荐



科技日报



北京市科委、中关村管委会




人民日报



新华网

■ 案例：实现特定水平智能的模型参数指数下降

随着数据-算力-算法的协同发展，实现**用更少参数实现相同智能水平**：在相同能力前提下，**模型参数量每3.5个月下降一半**




Mistral-7B

Avg Score: 36.27

2023-09-27

时隔4个月用35%的参
数，实现相当能力



MiniCPM-1-2.4B

Avg Score: 37.67

2024-02-01



LLaMA 3-405B

GPT4水平能力

2024-04-18

时隔240天用近1/10的激
活参数，实现相当能力




DeepSeek V3

670B 激活 37B

2024-12-26

■ 推论：模型推理开销随时间呈指数级下降

- 密度定律表明，达到相同能力的模型参数指数递减，2023年以来每3.3个月减少一半，相应模型推理速度提升一倍
- 此外，芯片算力水平遵循摩尔定律持续增强（稍慢），模型推理算法持续取得改进突破（模型量化、投机采样、显存优化）
- 印证：GPT-3.5级模型在过去20月内API价格下降至1/266.7，约2.5个月下降一倍



性能超越GPT-3.5的模型的API价格

■ 推论：模型训练开销随时间迅速下降

- 大模型训练计算开销 $\text{Compute} \approx 6 \cdot N \cdot D$

N 模型参数量：达到相同能力，参数量指数下降

D 训练数据量：高质量文本数据趋于耗尽，存在上限

达到相同能力的模型
训练开销呈指数下降

Scaling Law – 模型上限估算
高质量互联网数据：15T¹
可训练的模型最大参数：**750B**

Densing Law – 模型高效化进程估算
一年后，仅需 **58B** 参数模型可实现相同能力，所需训练算力下降 **12.8** 倍

国外已知最大的AI算力集群：10万 H100 GPU，约等于 70万 昇腾

一年后所需算力：7812 H100GPU，约等于 5.5万 昇腾


910B

[1] Fineweb：从96个CommonCrawl镜像中，清洗得到的预训练语料，规模为15T tokens

[2] 2024年，H100年产量约150万片，910B年产量约40万片

■ 高效技术思想：从大力出奇迹到高效低成本

OpenAI 等海外人工智能巨头也纷纷观察到 **高效低成本的趋势**



2025 年 2 月 OpenAI

The cost to use a given level of AI falls about 10x every 12 months, and lower prices lead to much more use. You can see this in the token cost from GPT-4 in early 2023 to GPT-4o in mid-2024, where the price per token dropped about 150x in that time period. Moore's law changed the world at 2x every 18 months; this is unbelievably stronger.

使用特定水平AI的成本大约每12个月下降10倍，而更低的价格会带来更多的使用。你可以从2023年初的GPT-4到2024年中期的GPT-4o的token成本变化中看到这一点，在这一年半的时间里，每token的价格下降了大约150倍。**摩尔定律每18个月使性能翻倍，从而改变了世界；而AI的成本下降速度比这还要令人难以置信。**



2025 年 10 月 OpenAI

Jakub


当OpenAI开发出新一代模型（比如GPT-5）时，它代表了智能的新前沿，也就是目前AI能达到的最高水平。达到这个前沿后，**很快就能找到更便宜的方法来复制这种能力。**

Altman

过去几年，**特定单位智能的价格每年下降约40倍。**

这里出现了一个看似矛盾的情况，为什么仍需要大量基础设施？他们**AI越便宜，人们越想使用，最终总的成本预计只会增加。**

模型知识密度增强揭示端侧智能巨大潜力



智能普惠带来智能革命

信息革命

算力高效



智能革命

智能高效



端侧智能的核心特征

特征	端侧大模型	云端大模型
部署位置	终端设备本地（如手机、PC、IoT设备、车载系统）	远程数据中心或云服务器
算力要求	资源受限，需在有限硬件（如NPU、GPU、CPU）上高效运行，对芯片能效比要求高	拥有大规模、集中式的计算资源，支持超大模型运行
数据处理方式	数据在设备本地处理、存储，不上传或加密上传云端，确保隐私和安全	数据需传输至云端进行处理，可能面临隐私风险和传输带宽限制
网络依赖	弱依赖或可离线运行	强依赖网络连接
功耗	功耗严格受限，强调低功耗设计和高能效比	功耗相对较高，但可通过规模化部署降低单位计算成本
成本	单次推理成本低，通过减少云端交互节省带宽和算力费用	大模型训练和运行成本高昂，依赖云服务付费模式
模型规模	参数量通常较小，通过轻量化技术优化，如数十亿至数百亿参数（如苹果3B模型，LocalLLM MoE 230亿）	参数量庞大，通常达千亿甚至万亿，如GPT-3的1750亿参数
应用优势	高隐私性、实时响应、离线可用、成本效益、个性化体验	强大通用能力、处理复杂任务、海量知识库、易于更新迭代

端侧智能：由大模型原生驱动的新型智能终端必将逐步问世

从甲骨、马车到个人电脑、手机，硬件形态始终被当时最高效的信息处理和传递范式所定义。大模型带来的“自然语言/意图”交互，是对“触控/图形”交互的根本性颠覆。

约前1300年—前1100年

约公元600年

19世纪40年代

20世纪末

21世纪初

今日

石器时代

农业时代

电力时代

信息时代

移动互联时代

智能时代

文字系统

邮驿系统

电力系统

有线网络

无线网络

大模型和智能体

信息首次可被
固化和传递

信息首次被大规模
体系化复制和传播

信息可以转化为电
讯号传播和接收

及时交互的出现和
操作可视化

信息传播脱离距离约
束，多点触控出现

自然语言意图交互
的出现

甲骨、竹简、笔墨

印刷术、造纸术

电话、电报

个人电脑、键鼠系统

手机、平板电脑

新型智能硬件



■ 端侧智能具有在用户体验上的优势

端侧智能相较云端的三大优势




隐私性

数据不出端 最大可
能保护个人隐私



实时性

全天候陪伴 实时倾听
用户最真实的需求



可靠性

守候不掉线
不在用户最需要的时候缺席

■ 端侧智能天然适配硬件产业的商业逻辑

商业模式	按量付费	免费获客	一次性买断
适用场景	水电、算力等基础设施	移动互联网应用 APP	硬件设备如汽车、家电、手机
用户体验	能省则省	有丰富的应用内引导消费	购买决策成本高 使用黏性强
场景特性	资源导向的刚需性投资或消费 	以用户注意力为核心的商业 	以产品功能创新为更新驱动力 

杰文斯悖论

随着技术进步提高资源利用效率，该资源的总消耗量反而会增加，而不是减少

端侧智能相对于云端的商业优势



用户侧


持续使用成本低
黏性强



厂商侧


功能设计不算力
天花板

■ 价值链视角：端侧大模型会成为智能终端的通用大脑




Apple WWDC 2026: 成为入口，开启系统之争

Apple 的 AI 战略不是正面拼“最强大模型”，而是把 AI 变成 Apple 生态的系统接口和流量入口。未来在 Apple 平台上，真正有价值的 AI 应用不是外挂一个聊天框，而是深度调用 OS 上下文、原生交互和端云能力，成为用户完成任务的默认路径



AI 能力平台化：Apple 不再只发布单点 AI 功能，而是通过 Foundation Models framework 把 AI 封装为 iOS/macOS 的底层开发能力

统一模型调用接口：开发者可用同一套 Swift API 调用端侧模型、Private Cloud Compute 云端模型，以及 Claude、Gemini 等第三方大模型



端云协同成为默认架构：轻量任务在端侧完成，复杂推理交给 Private Cloud Compute，在性能、隐私和成本之间做系统级调度


AI 与 OS 深度绑定：App Intents、Siri AI、屏幕感知、个人上下文、Vision/OCR/RAG 等能力，让 AI 从“App 内功能”变成“跨 App 的操作入口”

开发者生态被重新组织：Apple 不追求所有模型自研，而是把模型供应商纳入自己的协议和分发体系，强化平台控制力


■ 总结：端侧大模型及系统整体沿着“高效”的思路前进

端侧智能以“高效”为核心思想的面向未来六大议题

架构高效
承载智能的“容器”




数据高效
模型学习的“教材”




部署高效
端侧生态的“基石”



训练高效
能力成长的“规律”



推理高效
效能增长的“引擎”



开发高效
应用繁荣的“核心”



面向智能的产生和迭代

面向智能的应用和生态

面壁智能 MiniCPM 小钢炮，高效端侧大模型全球领先

文本基座模型

MiniCPM 2.4B

世界首个端侧基座大模型

GitHub 1st
Hugging Face 1st

2024.2

MiniCPM-S 1.2B

首发高稀疏推理架构

GitHub Top
Hugging Face Top

2024.7

MiniCPM-3 4B

端侧文ChatGPT 时刻

GitHub 1st
Hugging Face 3rd

2024.9

MiniCPM-4 8B | 0.5B

开启端侧长文本时代

GitHub Top
Hugging Face 2nd

2025.6

MiniCPM-4.1

长文本深思考高效上端

Hugging Face Top

2025.9

多模态模型

2024.5

美国套壳抄袭出圈

GitHub 1st
Hugging Face 1st

MiniCPM-V 2.5

2024.8

端侧全面对标GPT-4V

GitHub 1st
Hugging Face 3rd

MiniCPM-V 2.6

2025.1

全球首个端侧全模态模型

GitHub 1st

MiniCPM-o 2.6

2025.8

首个高刷视频理解
多模态模型

GitHub Top
Hugging Face 2nd

MiniCPM-V 4.5

2025.9

极高真实度
语音生成

Hugging Face 1st

VoxCPM

2026.2

即时自由对话
全模态全时感知

GitHub Top
Hugging Face 2nd


MiniCPM-o 4.5

MiniCPM 模型全系列

18 次发布 - 18 次登顶



HUGGING FACE




34,000,000+ 次下载

140,000+ Stars¹

■ 高效大模型主线技术



摩尔定律
电路密度倍增




主线技术
「现代光刻机」

提升分辨率提高芯片电路密度

厘米 → 纳米 缩小千万倍



密度法则
知识密度倍增




主线技术
「高效大模型科学化制备」
架构-数据-学习协同优化提高
模型能力密度

PB → GB 压缩百万倍


「超高能力密度大模型」 高效制备技术体系

超高能力密度端侧模型高效制备


承载智能的“容器” 架构高效：模型功能分区



训练和推理计算量大幅降低 90% 以上，
模型参数有望实现可复用、可拓展



模型学习的“教材” 数据高效：数据治理提质



UltraChat
对话数据集

• 800+ 模型使用，
位列全球第 5

UltraFeedback
偏好数据集

• 1200+ 模型使用，
位列全球第 3


UltraInteract
对齐数据集

• 格式标注错误减少
90%

RLAIF-V
多模态偏好数据集

• 登上 HF 热门数据集
榜单

能力成长的“规律” 实验高效：模型风洞技术




自研“模型风洞”平台，快速制定适配不同参数规模、数据条件的最优训练方案

- 超参稳定的模型规模扩增
- 最优学习率
- 最优训练批大小
- 最优学习率调度器

多阶段学习率调度器 WSD：根据模型风洞提出，成为 Hugging Face Transformers 内置算法，被 LLaMA、DeepSeek 开源模型广泛采用

150 万+ 日均下载量 **14 万** GitHub 星标 **2.8 万** GitHub 复刻

硅基智能的“基础” 计算高效：算法创新提效



训练加速

• 细粒度流水线并行，细粒度序列并行

推理加速

• 投机采样，1.6-2x 加速
• 衔尾蛇解码，相较自回归解码 3.9x

低位宽加速

• 超低位宽参数表示
• 通过 QAT 实现 INT-1 量化，存储降低 90%，可在智能手机上部署



如何让多模态大模型更像人？

Interactivity should scale alongside intelligence
—— Thinking Machines Lab

■ 为什么我们要实现人类水平的互动智能？

- 朴素的直觉
 - AGI至少应该达到人类水平 -> 多模态动态世界强交互能力
- Point1: Context and Bandwidth
 - 上下文越多，模型（越聪明）越有帮助
 - 传统交互模式带宽极窄，类似发邮件
 - 上下文 = 用户全感知 + 客观环境？
- Point2: The Bitter Lesson
 - 手工构建的系统会被基础模型的通用能力取代
 - For interactivity to scale with intelligence, it must be part of the model itself

■ MiniCPM-o 4.5: 类人多模态感知交互

- 能力探索
 - 「边看-边听-主动说」的端到端全模态能力
 - 「即时自由对话」，弱化一问一答的轮次对话概念
 - 真人感语音对话能力
- 技术探索
 - 首个全双工全模态大模型
 - 全模态自主交互机制
- 基础能力
 - 9B参数量，全模态能力、视觉能力、语音能力同尺寸领先



了解更多

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 8月 📍 深圳 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海 🧑 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京 🧑 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

AiCon

全球人工智能开发与应用大会

深圳站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 8 月 21-22 日 / 深圳湾万丽酒店



参会咨询

专题: Harness Engineering: 模型之外的智能体工程

专题出品人: 柴思远

智谱 / 副总裁



专题: 超级个体与蜂群智能的共生进化

专题出品人: 张昊阳

EvoMap / 创始人



专题: AI Agent 高价值商业场景实战

专题出品人: 李响 博士

平安科技 / 智能两核 AI 部总经理



专题: 超级 App 的 AI 原生化: 端智能、端云协同与用户体验重构

专题出品人: 黎三平

京东 / 端技术负责人



专题: AI 原生新范式: Coding Agent 重构软件研发全流程

专题出品人: 林香鑫

网易游戏 / 高级技术经理



专题: 智能体时代的数据供给与治理

专题出品人: 陈廷梁 (王赟)

数新智能 / 创始人兼 CEO





THANKS

探索 AI 应用边界

Explore the limits of AI applications

AiCon

全球人工智能开发与应用大会

关注
OpenBMB



联系演讲人

